

Reconnaissance automatique de cartes Pokémon

Projet PRONTO #83 — Recette et valorisation

Elias HASNAOU (*chef de projet*) Christian TRANDAFIR Ayoub DAOUDI
Sami GUESSOUM Walid CHAABANE Salomé GOULIN

IMT Atlantique — Campus de Brest
Encadrant technique : Bastien Padeloup

28 mai 2026

Destinataires : encadrant technique, équipe pédagogique PRONTO.



Un pipeline capable d'identifier une carte Pokémon prise en conditions réelles parmi plus de 20 000 variantes, avec un temps de réponse compatible avec une démonstration interactive.

Plan oral

- 1 Besoin et contraintes terrain
- 2 Architecture du pipeline
- 3 Résultats scientifiques et techniques
- 4 Démonstration et validation
- 5 Bilan projet et perspectives

Messages clés

- Le problème est **fine-grain** : les détails d'édition comptent.
- La qualité du dataset a été aussi importante que le choix du modèle.
- L'identification finale repose sur la vision, l'OCR restant un complément.

Contexte : un problème simple en apparence, difficile en pratique

Cas d'usage cible

- Collectionneur ou revendeur qui photographie une carte.
- Images issues de Vinted, eBay ou CardMarket.
- Fonds encombrés, reflets holographiques, flou, angle, captures d'écran.

Pourquoi l'OCR seul ne suffit pas

- Le texte disparaît vite avec le flou ou les reflets.
- Deux variantes peuvent partager le même nom et une illustration proche.
- Les indices discriminants sont parfois minuscules : numéro, extension, logo.



EDITION
1


Exemple : deux Dracaufeu visuellement très proches, mais d'éditions différentes.

- Détecter et redresser automatiquement la carte.
- Identifier la bonne variante parmi un grand catalogue.
- Rester sous 5 secondes en bout de chaîne.
- Fournir une interface démontrable.
- Ajouter une visualisation explicative.

Critère	Seuil	Statut final
Détection P1	> 90%	atteint
Recall@1	> 80%	atteint
Recall@5	> 95%	atteint
Temps end-to-end	< 5s	atteint
Démo	opérationnelle	atteint

La priorité a été donnée à la robustesse sur photos réelles plutôt qu'à un benchmark artificiel (augmentations artificielles).

Architecture retenue : pipeline modulaire en six étapes



- P1 → P2 : image normalisée 512×715 .
- P2 → P3 : embedding $\mathbb{R}^{512}$ normalisé L2.
- P3 → P5 : top- k candidats + score + métadonnées.

- P4 : OCR pour validation future des cas ambigus.
- P6 : Affichage map d'attention pour comprendre les zones utilisées par le modèle.
- LightGlue abandonné : le gain attendu devenait marginal après P2.

P1 — Détection et redressement : passer du synthétique au terrain

Limite de la première version

- Dataset initial surtout artificiel.
- Modèle YOLO26m-Seg correct, mais lourd pour une classe unique.

Itération finale

- Annotation semi-automatique avec SAM3.1.
- Nettoyage puis fusion avec rotations et dataset initial.
- Passage à YOLO26n-Seg : plus petit, plus rapide, plus précis (grâce au nouveau dataset).



	Ancien YOLOm	Nouveau YOLOn
Paramètres	23,51 M	2,69 M
Mask mAP50-95	0,750	0,851
CPU / image	622 ms	78 ms

Problème traité

- Transformer une carte en vecteur visuel discriminant.
- Rapprocher les vues réelles d'une même carte.
- Éloigner les variantes très proches mais incorrectes.

Évolutions majeures

- 1 SimCLR retenu à la place d'ArcFace.
- 2 Résolution 224 → 518 pour préserver les détails fins.
- 3 Hard negative mining pour séparer les confusions proches.
- 4 SupCon multi-positifs sur photos terrain.
- 5 Distillation vers ViT-S+ et ConvNeXt-Small.



Le modèle ne doit pas seulement reconnaître « Dracaufeu » : il doit reconnaître la variante exacte.

P2 — Résultats : gain massif sur le cas d'usage réel

Étape	R@1	R@5	Signal principal	Décision
SimCLR 224	70,00%	84,40%	base contrastive viable	garder SimCLR
SimCLR 518	98,23%	99,84%	détails fins préservés	garder 518
Dino Large SimCLR	79,29%	89,01%	gap galerie/terrain	ajouter multi-positifs
Teacher SupCon	98,59%	99,99%	vues terrain alignées	distiller
ViT-S+ distillé	98,68%	99,99%	qualité préservée	modèle déployable

Le gain ne vient pas seulement d'un modèle plus gros, mais de l'adéquation entre la loss, la résolution et les données terrain.

Le modèle étudiant conserve quasiment le R@1 du teacher tout en étant environ dix fois plus léger.

Principe

- 1 Chaque carte de référence est encodée en embedding.
- 2 Les embeddings sont normalisés L2.
- 3 FAISS recherche les plus proches voisins par produit scalaire.
- 4 Le système retourne un Top- k de candidats avec score.

L'index **FlatIP** est suffisant à l'échelle du projet : environ 18 900 cartes de référence, avec une recherche exacte très rapide.

Le reranking géométrique avec LightGlue a été abandonné :


- le Recall@1 de P2 était déjà très élevé ;
- le gain attendu devenait marginal ;
- cela simplifie le pipeline final.

On ne conserve pas un module parce qu'il était prévu initialement, mais parce qu'il apporte une valeur mesurable.

Utiliser le texte comme validation complémentaire de l'identification visuelle :

- nom de la carte ;
- points de vie ;
- attaques ;
- numéro / extension.

- Seuillage fixe, Otsu, adaptatif, inversion.
- Amélioration du contraste par CLAHE.
- Découpe en zones : nom, PV, attaques, bas de carte.
- Vote entre plusieurs sorties OCR.




Prétraitements multiples + OCR par zones.

- Sorties OCR trop bruitées pour fiabiliser la décision.
- Causes : polices stylisées, texte petit, fonds colorés, symboles parasites.
- Module conservé comme piste future, mais non intégré au pipeline final.

Pipeline final fondé sur l'identification image seule :

P1 → P2 → P3

P5 – Interface et démonstration



Interface Gradio : résultat Top-5 retourné par FAISS.

- **Top-1 correct** : xy3_13.
- **Score élevé** : **0,9359**.
- Les autres candidats restent cohérents : mêmes Pokémon, mais éditions différentes.

Upload
image

Détection
+ redressement

Embedding
visuel

Recherche
FAISS

Affichage
Top-5

L'interface permet de valider le pipeline complet en conditions utilisateur : prédiction finale, score de confiance et cohérence des candidats retournés.

P6 — Explicabilité : vérifier ce que le modèle regarde



Image analysée



Heatmap d'attention

L'explicabilité sert à vérifier que l'attention se concentre sur l'illustration et les zones discriminantes, plutôt que sur le fond.

Critère	Mesure	Décision
Détection P1	95,4%	validé
Recall@1	98,68%	validé
Recall@5	99,99%	validé
Temps end-to-end	3 s	validé
Robustesse holo	dégradation 0.7%	validé
Démo fonctionnelle	oui	validé
OCR	exploratoire	non bloquant

Limites restantes

- OCR encore fragile sur polices stylisées, texte petit et fonds colorés.
- Cas extrêmes à approfondir : cartes pliées, abîmées ou très réfléchissantes.
- Industrialisation à poursuivre : export ONNX, quantification, mise à jour FAISS.

- 1 Carte isolée : cas nominal.
- 2 Photo Vinted : reflets, angle, fond réel.
- 3 Page de classeur : détection multi-cartes.

Le modèle nano permet le crop et redressement en temps réel des cartes ce qui permet l'utilisation du flux vidéo en plus des images.

Les objectifs principaux du cahier des charges sont atteints ; l'OCR reste une piste complémentaire, mais ne bloque pas le pipeline

Principaux écarts

- P1 prolongé : reconstruction terrain via SAM3.1.
- P2 réorienté : ArcFace → SimCLR → SupCon.
- LightGlue abandonné : valeur ajoutée insuffisante après les progrès de P2.
- OCR ramené à un complément non bloquant.

- Interfaces inter-modules figées tôt.
- Benchmarks réguliers pour arbitrer expérimentalement.
- Réallocation du temps vers les modules à fort impact.
- Documentation continue utile pour le rapport final.

Les changements de trajectoire n'ont pas été des échecs : ils ont permis d'augmenter fortement la performance réelle tout en simplifiant le pipeline final.

- Pipeline complet : détection, crop, embedding, retrieval, interface, explicabilité.
- Objectif Recall@1 largement dépassé : 98,68% contre 80% attendu.
- Modèle final plus léger, adapté à une démonstration interactive.

- OCR ciblé pour départager les Top-2 ambigus.
- Export ONNX et quantification INT8.
- Mise à jour incrémentale de la galerie FAISS.
- Évaluation sur cartes abîmées, pliées ou très holographiques.

Merci pour votre attention.

Questions / démonstration

Annexe A — Détails des livrables

ID	Livable	Statut
L3/L3b	Détection YOLO + modèle terrain SAM3.1 tiny	livré
L4/L4b	Embeddings contrastifs + modèles distillés	livré
L6	Index FAISS + script de retrieval	livré
L7	OCR + base de métadonnées	partiel
L8	API + interface de démonstration	à finaliser / démo
L9	Attention	livré
L10	Rapport final	livré
L11/L12	Slides	(ce rendu)

Annexe B — Détails P1 : comparaison YOLO

Modèle	Params	GFLOPs	Box mAP50	Mask mAP50-95	CPU/img
YOLO26m-Seg	23,51 M	121,2	0,9546	0,7504	622 ms
YOLO26n-Seg	2,69 M	9,0	0,9909	0,8512	78 ms

Le nouveau modèle n'est pas seulement plus léger : il améliore aussi la finesse des contours segmentés, indispensable pour un crop propre.

Modèle	R@1	R@5	Rang moy.	Commentaire
Teacher DINOv3-L	98,586%	99,994%	1,015	référence lourde
ViT-S+ distillé	98,680%	99,991%	1,014	meilleur compromis
ConvNeXt-Small	98,497%	99,986%	1,017	alternative convolutionnelle

$$L = 0,50L_{metric} + 0,35L_{relation} + 0,15L_{embedding} + 0,10L_{edition}$$