




Groupe Data Science Brest
de Maxime Havez

Un meetup organisé dans le cadre de la démarche Brest is AI
du Technopôle Brest-Iroise



<jeudi 25 novembre 2021>
<18h30 – 20h00>

< au Totem de la French Tech Brest+ aux Capucins >

“Explicabilité des systèmes d’IA : état des lieux et cas pratiques”

- Quelles sont les approches actuelles et les progrès récents ?
- Quelles sont les limites et les verrous toujours présents ?
- Comment disposer d’explicabilité dans un système IA aujourd’hui ?



Ikram Chraïbi Kaadoud,
Chercheuse Post-doctorale
en IA explicable
IMT Atlantique



Aymeric Poulain Maubant
fondateur de Nereÿs




TECHNOPÔLE
BREST-IROISE





Groupe Data Science Brest
de Maxime Havez

Un meetup organisé dans le cadre de la démarche Brest is AI
du Technopôle Brest-Iroise



<jeudi 25 novembre 2021>
<18h30 – 20h00>

< au Totem de la French Tech Brest+ aux Capucins >

Programme

1. Mot d'introduction par Frédéric Nicolas
2. L'actualité IA par Aymeric Poulain
3. "IA explicable : une petite introduction"
présentation par Ikram Chraibi Kaadoud
4. **Table ronde** : "Explicabilité des systèmes d'IA,
des chercheurs en parlent !



Lina Fahed

Maitre de
conférences en
IA Explicable

#Data_Science
#Data_Mining
#Explainable_AI
#Temporal_Modeling
#Anomaly_Detection



Romain Billot

Chercheur en
Machine
Learning et
Data mining

#Machine_learning,
#Deep_learning
#Data_Science
#Data_Mining



Bastien Padeloup

Maitre de
conférences en
Deep Learning

#Graph_signal_processing,
#Machine_learning,
#Deep_learning,
#Few-shot,
#Health.



TECHNOPÔLE
BREST-IROISE



Lab-STICC



IMT Atlantique
Bretagne-Pays de la Loire
Ecole Mines-Télécom

Quatre matières à réflexion



références & détails sur :

<https://medium.com/@AymericPM>

Régulation de l'IA x Europe : une approche trop techno-centrée ?

- Un rapport intitulé « *Beyond Debiasing : Regulating AI and its Inequalities* », publié par l'EDRi (réseau européen de défense des droits et libertés en ligne) 
- Contexte : la proposition de la Commission européenne en avril 2021 d'un « *Artificial Intelligence Act* »
- Constat : il y a un paradoxe à confier aux fournisseurs de services la lutte contre la discrimination et l'inéquité
- 6 propositions reposant sur 3 constats initiaux
- Un rapport qui aide à mieux comprendre la question des biais

Peut-on concevoir des modèles de moralité pour les systèmes d'IA ?



- Un article scientifique, et un démonstrateur en ligne : <https://delphi.allenai.org/>
- Des réactions, notamment sous forme d'autres articles scientifiques
- Une réponse de l'auteure principale
- Un débat toujours en cours

Entretien avec Gary Marcus



- L'entretien mène vers un point essentiel : un mouvement de refondation des objectifs de l'IA vers des systèmes plus riches et robustes
- 4 étapes préconisées : les systèmes hybrides neurosymboliques, des bases de connaissance de grande ampleur, des systèmes de raisonnement, la capacité à comprendre ce qui est « *en train de se passer* »
- Nombreux travaux de Gary Marcus cités
- Beaucoup d'exemples sont des cas d'usage autour du traitement du langage. Nombreux échanges sur les questions éthiques et le sujet des biais.



Travaux du Comité national pilote d'éthique du numérique

- Le CNPEN agit au sein du CCNE (Comité consultatif national d'éthique pour les sciences de la vie et de la santé)



- Avis n°3, « *Agents conversationnels : enjeux d'éthique* », 9/11/21

- 13 préconisations, 10 principes de conception, 11 questions de recherche



- Consultation en cours : « *Questions d'éthique relatives aux technologies de reconnaissance faciale, posturale et comportementale* », (jusqu'au 31/12/21)



THIS MEANS VICTORY,
THIS MEANS PEACE,
IT ALSO MEANS
TWO HAMBURGERS PLEASE.

-SHEL SILVERSTEIN

IA explicable (IAX) : une petite introduction

Ikram Chraibi Kaadoud

@IkramChraibiK

<https://www.linkedin.com/in/ikramchraibik/>

Novembre 2021



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom



Lab-STICC




UMR CNRS 6285




Groupe de recherche



DECIDE Research team: <https://www.labsticc.fr/en/teams/m-570-decide.htm>
LAB-STICC Laboratory: <https://www.labsticc.fr/en/index/>
IMT-atlantique: <https://www.imt-atlantique.fr/>



IA... Un bref rappel



Adapted from (Lecue et al, 2020)



<https://incidentdatabase.ai/>



People built AI bots to improve Wikipedia. Then they started squabbling in petty edit wars, sigh

theregister.co.uk · 2017

that bots behave differently depending on which *language* version of Wikipedia they work on: some



Facial Recognition Tells An Asian Man His Eyes Are Closed
digitaltrends.com · 2016

Facial recognition is cool technology, but it's not perfect. It's used in many




Facial recognition system mistakes bus ad for jaywalker
cnet.com · 2018

NurPhoto China is increasingly dependent on *facial recognition* systems to name and shame citizens

Story

Google apologizes after its Vision AI produced racist results



AI technologies — like police facial recognition — discriminate against people of colour

24 août 2020, 22:56 CEST

Facial recognition algorithms are usually tested using white faces, which results in the technology being unable to differentiate between racialized individuals.



A 'Good Morning' Reportedly Gets Man Arrested After Facebook Translate Error

supernewsworld.com · 2017

Twitter to investigate racial profiling algorithm after users say auto-feature favours white faces

Posted Tue 22 Sep 2020 at 1:44pm, updated Tue 22 Sep 2020 at 1:37am



Twitter has cooped criticism for an algorithm that appears to favour white faces, such as US senator Mitch McConnell, over black ones like former US president Barack Obama. (AP: Julia Cortez; Reuters: Tom Rønneberg)

Introduction

Definition


«l'IA explicable vise à rendre les modèles d' IA plus intelligibles et accessibles ou à concevoir directement des modèles et des résultats explicables. » (Kaadoud et al, 2021)

Objectifs

1) Concevoir directement des modèles et des résultats explicables


2) Rendre les modèles d'IA plus intelligibles et accessibles

c.-à-d. pour une question donnée sur les mécanismes et/ou les résultats d'un modèle d'IA, fournir une explication à un public cible.



- Le domaine de l'IA explicable va au delà du Machine Learning... il concerne l'IA dans son ensemble !!
- Les questions posées en explicabilité existent depuis les années 1960 !!

Public cible



Adapted from (Arrieta et al, 2019)

Quel public dans notre contexte?


- Néophyte ou expert
- Utilisateur lambda ou expert du domaine
- Enfant ou adulte
- Décideurs politique, conseils administratifs ou citoyens lambda
- Industriels ou institutions publiques

Les **connaissances préalables** du public ciblé influencent le **choix de l'explication** à fournir ainsi que **sa perception** (Ehsan et al, 2021)

L'explication... un intermédiaire adaptée et adaptable



L'explication... un intermédiaire adaptée et adaptable



Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., ... & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82-115.

Cassens, J., & Wegener, R. (2021). Intrinsic, Dialogic, and Impact Measures of Success for Explainable AI. In *Twelfth International Workshop Modelling and Reasoning in Context* (

Miller, T. (2019). Explanation in artificial intelligence: Insights from the social sciences. *Artificial intelligence*, 267, 1-38.


Walton, D. (2004). A new dialectical theory of explanation. *Philosophical Explorations*, 7(1), 71-89.

Pictures adapted from (Arrieta et al, 2019)

Dimension(s) à expliquer

Expliquer une prédiction


“Pourquoi un image a été classée dans une catégorie particulière?”



Expliquer les données

“Quelle caractéristique des données est la plus pertinente pour la tâche donnée réalisé par le modèle IA ?”


Tabular data, mushroom classification



<https://github.com/marcotcr/lime>

Expliquer le modèle IA et/ou ses mécanismes internes en lui-même

“A quoi ressemblerait un pattern appartenant à une certaine catégorie selon le modèle?”




Holzinger A. (2018), <https://human-centered.ai/wordpress/wp-content/uploads/2018/09/5-METHODS-EXPLAINABLE-AI-MAKE-Decision-20180920-2x2.pdf>

Sebastian Bach, et al. 2015. On pixel-wise explanations for non-linear classifier decisions by layer-wise relevance propagation. PloS one, 10, (7), e0130140, doi:10.1371/journal.pone.0130140.

Samek, W., Binder, A., Montavon, G., Lapuschkin, S., & Müller, K. R. (2016). Evaluating the visualization of what a deep neural network has learned. IEEE transactions on neural networks and learning systems, 28(11), 2660-2673.

XAI* Techniques : Ante-hoc vs. Post-hoc

*XAI : eXplainable AI





Representation Learning

RL - and synonyms **Data RL or Feature Learning** - focuses on “*learning representations of the data that make it easier to extract useful information when building classifiers or other predictors*” (Bengio et al., 2013).

Related to machine/deep learning algorithms

A machine-oriented domain

Representation *i.e.* features that express priors about the data in latent space of neural network



Exemples d'IAX

Explainability: Saliency Masks for Deep Neural Network (DNN)

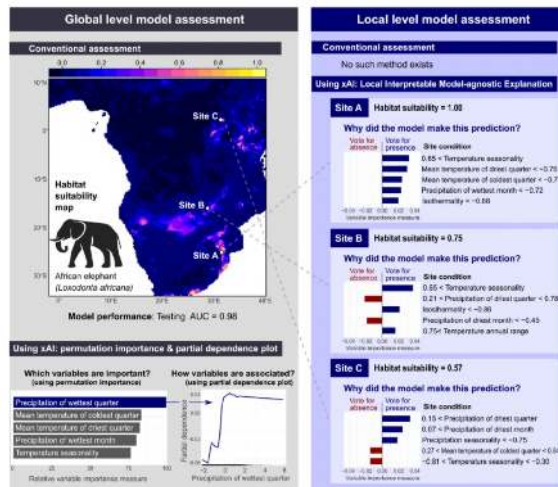



Figure 2: Interpreting the species distribution model of the African elephant *Loxodonta africana*, using explainable AI (xAI) tools: permutation importance and a partial dependence plot for the global level and local interpretable model-agnostic explanations at the local level (see Table 1 for the description of the techniques).

Explore, Exploit, and Explain: Personalizing Explainable Recommendations with Bandits

James McInerney, Benjamin Lacker, Samantha Hansen, Karl Higley, Hugues Bouchard, Alois Gruson, Rishabh Mehrotra, Spotify
jamesm.benl@spotify.com, karlhigley@spotify.com, algruson@spotify.com, rishabh@spotify.com

ABSTRACT

The multi-armed bandit is an important framework for balancing exploration with exploitation in recommendation. Exploitation recommends content (e.g., products, movies, music playlists) with the highest predicted user engagement and has traditionally been the focus of recommender systems. Exploration recommends content with uncertain predicted user engagement for the purpose of gathering more information. The importance of exploration has been recognized in recent years, particularly in settings with new users,

and recommendations are a popular way to help them navigate this choice. But recommendations without context lack motivation for a user to pay attention to them. Adding an associated explanation for a recommendation (abbreviated as *rexpplanation* [16]), is known to increase user satisfaction and the persuasiveness of recommendations [6, 13, 34].

Explanations in recommender systems have the goals of both providing information about recommended items and encouraging better outcomes such as higher user engagement resulting from

SPOTIFY

Utiliser XAI avec l'apprentissage par renforcement pour expliquer les choix des musiques recommandées et des listes de lecture aux clients en fonction de leurs goûts.



"Explore, Exploit, Explain: Personalizing Explainable Recommendations with Bandits" J. McInerney, B. Lacker, S. Hansen, K. Higley, H. Bouchard, A. Gruson, R. Mehrotra. RecSys 2018.

Explainable AI and Reinforcement Learning – A Systematic Review of Current Approaches and Trends

Lindsay Wells¹ and Tomasz Bednarz^{1,2*}

¹ Expanded Perception and Interaction Center, Faculty of Art and Design, University of New South Wales, Sydney, NSW, Australia, ² Data61, Commonwealth Scientific and Industrial Research Organisation, Sydney, NSW, Australia






FIGURE 2: Categorization of papers by domain. Note that some papers were in multiple domains.

Interpretability: feature map in Convolutional Neural Networks (CNN)

Deep neural networks learn hierarchical feature representations: Feature map in CNN



LRP model: Layer-Wise Relevance Propagation



Servén-Bach et al. 2015. On pixel-wise importance for machine classification by relevance selection property. Servén, D., Bredt, A., Montané, L., Lepoint, L., & Müller, S. R. (2015). Evaluating the evaluation of what a deep net

Que retenir ?

Public cible

- Peut être tout le monde : **experts, utilisateurs néophytes, collègues chercheurs, etc**

Les challenges techniques en IAX

Explication

Generation/Adaptation/
Acceptation/
Evaluation, etc.

Contexte

Compréhension/
Représentation/
Adaptation, etc.

Biais

Algorithmiques /
Cognitifs/
Statistiques

Temps réel ? Reproductibilité ?
Accessibilité technique ?
Few-shot Learning ?
Etc.

Objectif de l'IAX :

- Une **meilleure compréhension** des modèles IA, de leur fonctionnement et donc favoriser leur développement et acceptation
- Une **IA transparente** pour limiter/prévenir/détecter les cas de discriminations potentielles
- Une **IA éthique & responsable**pour une **société éthique & responsable**




Src: geralt on pixabay




IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

Merci de votre attention !



Src : <https://www.digite.com/pt-br/blog/xai-explainable-ai-contextual-introduction/>

Explicabilité des systèmes d'IA, les chercheurs en parlent !



Maitre de conférences en IA Explicable

- #Data_Science
- #Data_Mining
- #Explainable_AI
- #Temporal_Modeling
- #Anomaly_Detection



Chercheur en
Machine
Learning et
Data mining
#Machine_learning,
#Deep_learning
#Data_Science
#Data_Mining



Maitre de conférences en Deep Learning

#Graph_signal_processing
#Machine_learning,
#Deep_learning,
#Few-shot,
#Health.



Groupe Data Science Brest
de Maxime Havez

<jeudi 25 novembre 2021>

<18h30 - 20h00>

< au Totem de la French Tech Brest+ aux Capucins >

TABLE RONDE

Explicabilité des systèmes d'IA, les chercheurs en parlent !



Lina Fahed : Maitre de conférences en IA Explicable

Enseignante-chercheuse en informatique spécialisée en Intelligence Artificielle (IA) et fouilles de données. Dans ses activités de recherche, Lina s'intéresse à la fouille de données hétérogènes et temporelles, à l'intégration des préférences et connaissances utilisateur dans des systèmes d'Intelligence Artificielle, et à l'Intelligence Artificielle eXplicable (XAI) via la proposition de modèles explicables, transparents et éthiques.

[#Data_Science](#), [#Data_Mining](#), [#Explainable_AI](#), [#Temporal_Modeling](#), [#Anomaly_Detection](#).



Romain Billot : Chercheur en Machine Learning et Data mining

Professeur en *data science* à IMT Atlantique, Romain dirige des recherches en data mining et optimisation avec différents terrains d'applications dans les systèmes complexes comme la mobilité intelligente et la santé connectée. Responsable d'enseignements en statistiques et machine learning (filière *data science*), il est également responsable de l'équipe DECIDE (UMR CNRS 6285 Lab-STICC) et adjoint à la recherche du département LUSI.

[#Machine_learning](#), [#Deep_learning](#), [#Data_Science](#), [#Data_Mining](#),



Bastien Pasdeloup : Maitre de conférences en Deep Learning

Enseignant-chercheur en Deep Learning spécialisé dans le Few-Shot Learning et les graphs signal processing. Bastien s'intéresse à la compréhension et l'amélioration de l'apprentissage de modèles de deep Learning à partir de corpus de données de volumétrie basse, ainsi que l'utilisation de graphes. Ses recherches s'appliquent essentiellement au domaine de la santé.

[#Graph_signal_processing](#), [#Machine_learning](#), [#Deep_learning](#), [#Few-shot](#), [#Health](#).



Groupe Data Science Brest
de Maxime Havez

<jeudi 25 novembre 2021>

<18h30 – 20h00>

< au Totem de la French Tech Brest+ aux Capucins >

“Explicabilité des systèmes d’IA : état des lieux et cas pratiques”

Merci aux organisateursAurelie bouguen, Maxime Havez, Francoise Duprat, Muriele Couchevellou, & Frederic Nicolas

Merci aux chercheursLina Fahed, Romain Billot & Bastien Padeloup
du LAB-STICC & IMT Atlantique

Merci aux participants les 30n de passionnés presents et à tous ceux qui n’ont pas pu être des nôtres

***Au prochain meetup
Ikram & Aymeric***

- THE END -



meetup **Groupe Data Science Brest
de Maxime Havez**
<jeudi 25 novembre 2021>
<18h30 – 20h00>
< au Totem de la French Tech Brest+ aux Capucins >



**Groupe Data Science Brest
de Maxime Havez**

<jeudi 25 novembre 2021>

<18h30 – 20h00>

< au Totem de la French Tech Brest+ aux Capucins >



**Groupe Data Science Brest
de Maxime Havez**

<jeudi 25 novembre 2021>

<18h30 – 20h00>

< au Totem de la French Tech Brest+ aux Capucins >