




IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom


FINE-TUNING DE LLMS POUR LE BRETON

UE H : PML

GR. 4 - SUJET 8

Loïc Derrien
Théodore Diers
Jihad Ouard





SOMMAIRE

01 MOTIVATIONS

02 ETAT DE L'ART

03 PROCESSUS DE FINE-TUNING

04 RÉSULTATS

05 PERSPECTIVES

Motivations


- **Préservation** linguistique
- Proposer un outil de **traduction français-breton performant** pour :
 - Apprentissage du breton
 - Traductions de textes bretons
- **Défi technologique**

État de l'art

- **Papiers :**

- *Final Report - Fine Tuning Methods for Low-resource Languages", Johansson et al. (2025)*
- *The Fine-Tuning Paradox: Boosting Translation Quality Without Sacrificing LLM Abilities", Stap et al. (2024)*

- Pour les langues sous-représentées, le **Fine-Tuning (LoRA)** sur **datasets alignés** à démontrer des **améliorations significatives** en performances
- Pour les **données** : la **qualité**, la **quantité** et la **diversité** améliorent les résultats
- Le **gain en qualité de traduction** peut entraîner des **pertes de capacité** (style, compréhension du contexte)
- Le **gain du fine tunig** est **meilleur** sur les directions "**hors anglais**"




PROCESSUS DE FINE-TUNING

- DATASETS
- MODÈLES
- CONFIGURATIONS TECHNIQUES
- MÉTRIQUES D'ÉVALUATION

Processus de fine-tuning


Datasets

Jendersen




- Contributeur huggingface
- Langage **varié**
- Aligné **fr - br - en**
- **9k** entrées

Ofispublik



- Office Public de le Langue Bretonne
- Langage **soutenu**
- Aligné **fr - br**
- **60k** entrées

OpenSubs



- Sous-titrage communautaire
- Langage **familier**
- Aligné **fr - br**
- **15k** entrées

Processus de fine-tuning

Modèles

Gemma



- Famille de **modèles légers** pour usage générique
- Modèles **text-to-text**
- Usage des versions **2B** et **7B**

Translate
Gemma




- Famille de **modèles** experts en traduction
- Fine tuned à partir de Gemma
- Modèles **text-to-text**
- Usage de la version **4B**
- Entraîné sur **55 langues** (mais **pas le Breton**)

Processus de fine-tuning

Configurations techniques : LoRA

- **LoRA** = Low Rank Adapters
- Fine-tuning efficace par **décomposition de la matrice** de mise à jour des **poids**
- Passage d'une matrice **$d \times k$** à deux matrices **$d \times r$** et **$r \times k$**
- **Moins de poids** à entraîner
- **Calcul plus rapide** à l'entraînement



Processus de fine-tuning


Configurations techniques : Hyperparamètres

Hyperparamètres à considérer en priorité:

- **Learning Rate**
- **nombre d'epochs**
- **Optimizer**
- **Scheduler** du Learning Rate
- **rang** du LoRA
- **alpha** du LoRA (la matrice de mise à jour des poids est **pondérée** par **α / r**)

Processus de fine-tuning

Métriques d'évaluation



BLEU (%)

- **Approche** : Similarité exacte
- **Mécanisme** : Calcule le taux de chevauchement des n-grammes
- **Limite** : Très rigide, non sémantique

ROUGE (0 à 1)

- **Approche** : Similarité interne
- **Mécanisme** : Mesure de la plus longue sous-séquence commune
- **Limite** : Rigide, favorise les textes longs

BERT Score (-1 à 1)

- **Approche** : Sémantique
- **Mécanisme** : Utilise un modèle BERT pour comparer la similarité cosinus des embeddings
- **Limite** : Capture faible de la syntaxe


RÉSULTATS

- CONFIGURATIONS OPTIMALES
- ANALYSE DES RÉSULTATS DE TRADUCTION
- COURBES D'APPRENTISSAGE

Configurations optimales

Tuning Hyperparamètres : Rank


Effet du Rank LoRA sur les scores de traduction



Configurations optimales

Tuning Hyperparamètres : LR

Effet du Learning Rate sur les scores (Gemma 2B · r=64 · AdamW)



Configurations optimales

Que veut dire cette évolution concrètement ?

gwelet e veze oa meho.

on pouvait voir qu'il était saoul.

J'avais vu qu'il était malade.

gwelet e veze oa meho.

on pouvait voir qu'il était saoul.

On voyait qu'il était saoul.

gwelet e veze oa meho.

on pouvait voir qu'il était saoul.

On voyait qu'il était saoul.

ur paour-kaezh maltouter a
Bariz

Un pauvre douanier de Paris

un vieux-homme de Bariz

ur paour-kaezh maltouter a
Bariz

Un pauvre douanier de Paris

**un pauvre gars mal loti à
Morlaix**

ur paour-kaezh maltouter a
Bariz

Un pauvre douanier de Paris

**Un pauvre enfant roux de
Paris**

Gemma 2B : BLEU 6.92 Rouge 0.24


Translate 4B : BLEU 20.45 Rouge 0.37

Gemma 2B : BLEU 33.77 Rouge 0.49

Configurations optimales

Convergence du training : **Optimizer**

Comparaison AdamW vs SGD (Gemma 2B · r=64)



Configurations optimales


Convergence du training : **Optimizer**



Configurations optimales

Convergence du training : Scheduler

Training Loss — Linear vs Cosine with Restarts



Résultats

Test intra-dataset : Scores

	Gemma 2B	Gemma 7B	TranslateGemma 4B
Jendersen	BLEU 33.77 Rouge 0.491	BLEU 35.93 Rouge 0.537	BLEU 20.45 Rouge 0.377 BERTScore 0.8996
OpenSubtitles	BLEU 18.48 Rouge 0.414	BLEU 21.33 Rouge 0.447	BLEU 26.15 Rouge 0.492 BERTScore 0.9020
Ofispublik	BLEU 12.59 Rouge 0.408	BLEU 15.94 Rouge 0.451	BLEU 20.18 Rouge 0.453 BERTScore 0.9042

Résultats




Test intra-dataset : Performance selon le sens de la traduction

	TranslateGemma 4B Vanilla	TranslateGemma 4B fine tuned	Gain Fine-Tuning
Breton → Français	BLEU 2.6 Rouge 0.1365 BERTScore 0.7086	BLEU 20.18 Rouge 0.4526 BERTScore 0.9042	x 7.8 x 3.3 x 1.28
Français → Breton	BLEU 1.19 Rouge 0.1119 BERTScore 0.7043	BLEU 2.67 Rouge 0.0647 BERTScore 0.8140	x 2.2 x 0.58 x 1.2

Résultats

Test inter-dataset

Évaluation croisée inter-datasets (Gemma 7B · $r=128$ · $\alpha=128$ · LR=1e-4)




Résultats

Test inter-dataset : hypothèses

- C'est surtout dû à la différence de **registre de langues** entre les datasets...

Ofispublik



Les affaires européennes

Les deux régions souhaitent inscrire leur coopération dans le cadre global de l'Union européenne.

À cet effet, elles renforceront leur coopération sur l'axe suivant :

Le nautisme : 80 entreprises - 500 emplois

Possibilités d'implantation

La commune de Vannes concentre au sein de 15 pôles d'activités près de 900 entreprises et 17 000 emplois.

Il est interdit de déposer les ordures sur la voie publique les dimanches et les jours fériés.

Pour connaître le détail de la tournée en centre ville, vous référez au dépliant de présentation.

OpenSubs



À toi de voir.

C'est lui.

Avec la veste noire.

Allez, barre-toi de là !

Il a dit que si on avait le fric, on pourrait choisir.

Donc, qui est le premier ?

Bande de froussards. J'vais le faire.

Résultats


Test post-fusion de datasets

	Gemma 7B	TranslateGemma 4B
Jendersen	BLEU 10.4 → 13.1 Rouge 0.272 → 0.326 BERTScore 0.879 → 0.8896	BLEU 12.59 Rouge 0.301 BERTScore 0.8860

Résultats

Taille du Dataset & Performance


Évolution des scores avec la taille du dataset merged (Gemma 7B)



Résultats

Taille du Dataset & Performance


Évolution des scores avec la taille du dataset merged (TranslateGemma 4B)



Pour un modèle déjà spécialisé en traduction, le fine-tuning est très data-efficient : 10K samples suffisent pour atteindre ~95% de la performance maximale.


Résultats

Taille du Dataset & Performance




Résultats

Taille du Dataset & Performance



Résultats

Taille du Dataset & Performance : En exemples



PERSPECTIVES


- Tester sur des plus gros modèles (**27b**)
- Tester sur d'**autres modèles** que des gemma (LLama, NLLB)
- Ajouter un **dataset dictionnaire** français $\Leftrightarrow$ breton
- Inclure un mélange de **données monolingues** bretonnes durant le fine-tuning
- Tester la **Küllback-Leibler** loss pourrait améliorer la généralisation, et casser le plateau des scores



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

MERCI POUR VOTRE ATTENTION

TRUGAREZ



RÉFÉRENCES

- **opensubtitles** : <http://www.opensubtitles.org/>
P. Lison and J. Tiedemann, 2016, OpenSubtitles2016: Extracting Large Parallel Corpora from Movie and TV Subtitles. In Proceedings of the 10th International Conference on Language Resources and Evaluation (LREC 2016)
 - **ofispublik** : <http://www.opensubtitles.org/>
Tiedemann, J., 2012, Parallel Data, Tools and Interfaces in OPUS. In Proceedings of the 8th International Conference on Language Resources and Evaluation (LREC 2012)
- Tyers, F. M. (2009) "Rule-based augmentation of training data in Breton-French statistical machine translation ". Proceedings of the 13th Annual Conference of the European Association of Machine Translation, EAMT09. pp. 213--218