



Matis FELLER
28 mars 2020

Classification de patients atteints de cancer du poumon

Rapport - Projet S5

TAF - Healthcare engineering

Tuteur de stage - Bastien PASDELOUP



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

TABLE DES MATIERES

1 - RESTITUTION DU STAGE DANS SON CONTEXTE

1.1 Objectif du projet

1.2 Répartition du travail à faire

a) Avril : Analyse du microenvironnement tumoral à l'aide d'histogrammes

b) Juin : - Écriture d'un papier de recherche et analyse des résultats

- Travail sur différentes distances entre histogrammes

c) Juillet : Création de la nouvelle base de données

d) Aout : Traitement de la base de données et interprétation des résultats

2 - ANALYSE DE L'ENVIRONNEMENT TUMORAL DE LA PREMIERE BASE DE DONNEES ET ETUDE DE DISTANCES.

2.1 - La procédure

2.2 - Les variables

2.3 - Les résultats

2.4 - Les différentes distances

3 - SEGMENTATION, LABELISATION DE LA DEUXIEME BASE DE DONNEES

3.1 - La base de données

3.2 - La procédure de labélisation

3.3 - La segmentation des cellules et la classification

4 - ANALYSE ET COMPARAISON DES RESULTATS

4.1 - Les résultats de la deuxième base de données

4.2 - Comparaison avec la première base de données

4.3 - Conclusion

1

RESTITUTION DU STAGE DANS SON CONTEXTE

1.1 - Objectif du projet

Le cancer est la première cause de mortalité chez les hommes en France et la deuxième chez les femmes : cette maladie pourtant connue biologiquement, il n'existe pas encore de traitement général pour tous les types à part la chimiothérapie et la radiothérapie qui sont des thérapies très destructives et pas optimales. On sait cependant que plus il est pris à temps, plus les chances de survie sont augmentées. Le but est donc de gagner du temps dans l'administration du traitement. En effet, l'approche du projet est de classer les patients atteints de cancer du poumon en deux groupes : si l'on constate que l'un des deux groupes a une survie significativement plus élevée que l'autre, c'est que la classification a marché et que l'algorithme pourrait aider les médecins en classant un nouveau patient pour prédire sa survie et ainsi prendre des mesures en amont comme une opération ou une chimiothérapie plus forte par exemple. L'algorithme de classification servirait avant tout au médecin pour son diagnostic et ses décisions pour, par exemple, adapter au patient un traitement qui a bien marché pour les patients du même groupe. Pour ce faire, nous avons travaillé sur des coupes histologiques de patients atteints du cancer du poumon au stade IA et IB puis IIA et IIB disponibles sur une base de données internationale qui autorise dans un cadre de recherche scientifique l'utilisation de données de patients malades. Le but dans un premier temps a été de faire du traitement d'image sur les coupes pour extraire l'information intéressante : savoir si un noyau est un lymphocyte, une cellule saine ou une cellule cancéreuse. Grâce à ces informations, pour chaque coupe de patients, on a pu en extraire des histogrammes qui est une nouvelle technique pertinente pour décrire un patient. Au final, nous avons réussi à faire une classification et nous avons séparé les patients de la base de données en deux groupes.

1.2 - Répartition du travail à faire

Le projet a commencé en octobre 2019, dans le cadre du projet de dernière année. J'ai travaillé avec Yassine EL OUAHIDI sur le projet jusqu'en Avril 2020 avec comme encadrant Mr. PASDELOUP. Le but de ce rapport est de détailler mon travail sur le projet à partir du 1er Avril.

Début Avril, le traitement d'image sur les coupes de cancer pour extraire l'information intéressante sur la première base de données avait déjà été réalisé par Yassine, et le travail de recherche et développement sur la classification des patients grâce à des variables sous forme d'histogramme effectué par moi-même.

a) **AVRIL : Analyse du microenvironnement tumoral à l'aide d'histogrammes**

Dès le début de mon stage, nous connaissions la procédure que nous allions utiliser pour classer les patients atteints du cancer du poumon : Grâce à la nouvelle base de données que Yassine venait de créer, il fallait maintenant trouver des variables intéressantes sous formes d'histogramme pour chaque patient pour ensuite calculer une matrice de distance entre tous les patients dans l'espoir de les classer en deux groupes distincts. Il fallait ensuite tracer les courbes de survie des deux groupes et regarder la significativité de la classification.

J'ai donc essayé de trouver des variables intéressantes qui non seulement séparent les courbes de survies des deux groupes au maximum mais aussi qui sont cohérentes avec les attributs significatifs d'un mauvais diagnostic chez un patient que nous avions appris Mr. TALAGAS.

b) **JUIN : Ecriture d'un papier de recherche / Travail sur différentes distances**

Dès début juin, des premiers résultats intéressants commençaient à aboutir. Nous avons trouvé plusieurs variables significatives qui séparaient efficacement les courbes de survies des deux groupes. Nous avons donc décidé d'écrire un papier de recherche pour expliquer la méthode et les résultats que nous avons obtenus. Une fois le papier fini, je me suis intéressé à la notion de distance qu'on utilisait pour comparer les patients entre eux. En effet, chaque variable représente des histogrammes qui sont comparés deux à deux entre chaque patient et on regarde la distance entre ces histogrammes pour révéler la proximité des patients. Nous utilisons la distance de Wasserstein qui était pertinente, mais j'ai découvert l'existence d'autres distances qui semblaient intéressantes pour la comparaison des patients pour certaines variables, j'ai donc fait un travail approfondi sur cette thématique.

c) **JUILLET : Création d'une deuxième base de données**

A partir de Juillet, mon travail sur les distances entre histogrammes se termina et j'avais donc bien approfondi la méthode de classification des patients en ayant optimisé toutes les étapes du processus pour pouvoir avoir deux classes de patients les plus éloignées possible.

J'ai donc eu l'idée de tester cette méthode sur une autre base de données pour pouvoir comparer les résultats pour ainsi conclure certaines déductions. Malheureusement je n'ai pas trouvé d'autre base de données que TCGA, j'ai donc choisi de prendre les patients du stade IIA et IIB de TCGA pour voir la différence de classification entre les différents patients du même stade de la même base de données. J'ai donc travaillé tout le mois de Juillet pour créer cette base de données en utilisant en partie la méthode que Yassine avait élaborer.

d) **AOUT : Traitement de la base de données et interprétation des résultats**


Durant toute la période du mois d'Aout, il a fallut transformer les données recueilli pendant le mois du Juillet pour pouvoir les traiter avec les algorithmes qu'on avait développé pour la première base de données. Une fois cette tache terminé, il a fallut faire tourner tout les algorithmes déjà créés pour chaque variable, chaque distance modélisée précédemment, avant de pouvoir comparer la classification entre les deux bases de données pour pouvoir émettre des comparaisons et des conclusions à notre travail.

2

ANALYSE DE L'ENVIRONNEMENT
TUMORAL DE LA PREMIERE BASE DE
DONNEES ET ETUDE DE DISTANCES.


2.1 - La procédure

Partant d'une coupe histologique pour chaque patient sur la première base de données, grâce a l'algorithme de Deep learning que nous décrivons dans la partie 3, nous sommes capable pour chaque patient d'extraire plusieurs ROI (régions of Interest) d'une coupe histologique avec une photo des noyaux de différents phénotypes (lymphocyte, stroma ou tumeur) et un tableau xlsx représentant les coordonnées et le phénotype des noyaux pour chaque ROI.




1	Name_of	Location	Location	Category
2	ROI1_TC	27183	11064	3
3	ROI1_TC	27199	10777	2
4	ROI1_TC	27336	10992	3
5	ROI1_TC	28798	10708	3
6	ROI1_TC	28798	11021	3
7	ROI1_TC	28799	10628	2
8	ROI1_TC	28800	10727	3
9	ROI1_TC	28806	10864	2
10	ROI1_TC	28808	10623	2
11	ROI1_TC	28809	10608	3
12	ROI1_TC	28809	10883	3
13	ROI1_TC	28809	10994	3
14	ROI1_TC	28810	10639	2
15	ROI1_TC	27341	11057	3
16	ROI1_TC	28810	10663	3
17	ROI1_TC	28810	10791	3
18	ROI1_TC	28810	11022	3


On extrait donc un nombre variable de ROI pour chaque patient dépendant de la qualité de l'extraction et la pertinence des ROI




Pour les données à extraire de ces ROI, nous avons choisi de les représenter sous forme d'histogramme. En effet, cette forme de données complexe nous permet de garder beaucoup d'informations issues du ROI et c'est donc un élément plus riche pour comparer les patients entre eux. Prenons pour exemple la première variable « distance minimum entre lymphocyte et tumeur ». L'algorithme va parcourir tout les lymphocytes du ROI et calculer la distance minimum entre chaque lymphocyte et sa cellule tumorale la plus proche : on obtient donc pour un patient, un histogramme pour chacune des variables.




Or, un patient possède plusieurs ROI : on fait donc une agrégation de tous les ROIs dans un seul histogramme final. Un patient possède donc X histogrammes pour les X variables que nous trouvons pertinentes à calculer.



On a donc vu précédemment qu'un patient était représenté par ses X variables. Il faut maintenant comparer ces patients, donc ces histogrammes entre eux. On a choisi d'utiliser en premier lieu la distance de Wasserstein qui est une distance entre deux distributions mathématiques :
 Intuitivement, si chaque distribution est considérée comme une quantité unitaire « sable » empilée, la métrique est le « coût » minimum de transformation d'une pile en une autre, qui est supposée être la quantité de sable à déplacer multipliée par la distance moyenne à déplacer.



Distance de Wasserstein entre une distribution $f(x)$ et $g(x)$.




On peut conserver toutes ces distances entre patients 2 à 2 pour ainsi avoir pour chaque variable, une matrice symétrique de taille $N \times N$ avec N le nombre de patient. On peut maintenant commencer la classification en essayant les X matrices de distance correspondantes au X variables différentes dans le but de déterminer la significativité de chaque variable. On peut notamment effectuer la classification avec une combinaison des X matrices pour obtenir une matrice finale, le but étant alors de trouver les meilleurs poids pour chaque matrice pour avoir une matrice finale qui donne une classification la plus significative possible : celle qui écarte le plus les 2 courbes de survie.

$$\text{Distance Feature 1} = \begin{matrix} & \begin{matrix} 1 & 2 & 3 & 4 & \dots & \text{(patients)} \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \\ \dots \end{matrix} & \begin{pmatrix} D_{11} & D_{12} & D_{13} & D_{14} & & \\ D_{21} & D_{22} & D_{23} & D_{24} & & \\ D_{31} & D_{32} & D_{33} & D_{34} & & \\ D_{41} & D_{42} & D_{43} & D_{44} & & \\ \dots & & & & \dots & \end{pmatrix} \end{matrix}$$

$$\text{Distance Feature X} = \begin{matrix} & \begin{matrix} 1 & 2 & 3 & 4 & \dots \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \\ \dots \end{matrix} & \begin{pmatrix} D_{11} & D_{12} & D_{13} & D_{14} & \\ D_{21} & D_{22} & D_{23} & D_{24} & \\ D_{31} & D_{32} & D_{33} & D_{34} & \\ D_{41} & D_{42} & D_{43} & D_{44} & \\ & & & & \dots \end{pmatrix} \end{matrix}$$


Pour la classification, nous avons adopté une classification ascendante hiérarchique qui prend en entrée une matrice de distance à N paramètres pour les N patients. La classification ascendante hiérarchique regroupe entre eux les patients les plus proches sous forme d'un arbre avec des branches. On peut choisir de couper l'arbre à une distance D pour ensuite regrouper les patients en autant de groupes qu'il y a de branches à l'arbre à cette distance D . Intuitivement, plus la distance est élevée, plus on coupe haut dans l'arbre. Ainsi, il y a moins de groupes et les patients du même groupe ne sont pas forcément très proches. Plus la distance D est basse, plus on coupe bas dans l'arbre. Ainsi, il y a plus de groupe différents ou les patients se ressemblent beaucoup dans chaque groupe. Notre but ici est de regrouper les patients en deux groupes à peu près de même taille pour pouvoir les interpréter : Un groupe de patients qui se ressemblent beaucoup et un autre groupe constitué de patients qui sont très éloignés de ce premier groupe.

Pour ce faire, on coupe l'arbre à une distance D tel qu'il fait apparaître un groupe de patients qui comporte à peu près la moitié des individus. On regroupe ensuite les autres groupes de patients qui ne font pas parti de ce groupe en un deuxième gros groupe : on obtient donc à la fin deux groupe : un groupe de patient qui se ressemblent beaucoup et un groupe de patient qui ne se ressemblent pas.



Ici on remarque que le groupe vert contient 76 patients : il forme donc le premier groupe homogène, et le groupe rouge ainsi que les autres petits groupes bleus sont rassemblés dans l'autre groupe dit hétérogène.

L'étape d'après est le tracé des courbes de survies. En effet, la survie en nombre de jour est connu pour chaque patient, on peut donc tracer sur un axe temporel la survie en pourcentage de la population des deux groupes. On peut voir ci-dessous le tracé des deux courbes de survie des population 0 et 1 après une classification faite sur la première base de données : à chaque mort d'un groupe, le pourcentage de la population vivante baisse et on peut voir cette baisse par la formation d'un échelon.



Courbes de survie d'une population 0 d'une population 1


Pour évaluer la performance de notre classification, on calcul la p-value du log-rank test qui est la probabilité statistiquement que les deux groupes ne soient pas indépendants. Plus la p-value est faible, plus les deux groupes sont alors distincts et plus la classification est réussie, on veut donc minimiser la p-value car notre but est d'interpréter la classification : si deux groupes sont très distincts et que l'un meurt très rapidement, cela veut dire que la variable testée en question influence beaucoup le diagnostic des patients. Notre but final étant d'interpréter et comprendre les variables tout en trouvant une combinaison de celles ci minimisant la p-value et ainsi aidant les médecins pour le diagnostic.

2.1 - Les variables

La partie précédente qui montre d'un bout à l'autre le processus de classification des patients était essentielle pour la compréhension globale du projet. Le gros travail de recherche du projet se concentre sur les variables choisies pour construire les différents histogrammes. Une bonne variable est une variable qui sépare les courbes de survie en deux groupes distincts avec une p-value très petite mais aussi une variable qui est interprétable et compréhensible du point de vue d'un médecin. N'ayant pas les connaissances nécessaires pour savoir quelles informations sont intéressantes à extraire sur une coupe de patient malade, nous avons donc rétabli un contact avec le médecin pour pouvoir avoir son avis sur les éléments révélateurs à un bon diagnostic et inversement. Il nous a donc révélé les éléments visibles sur les coupes synonymes de bon diagnostic : Tout d'abord les lymphocytes présents sur la coupe doivent être proche de la tumeur. De plus, les lymphocytes présents doivent être en grand nombre dans la tumeur et pour finir, les coupes avec un grand nombre de petites tumeurs signifient que la tumeur peut co-exister dans le tissu sans être protégé par la grosse tumeur, ce qui est très mauvais signe pour le diagnostic du patient. Il s'agit donc de traduire tous ces paramètres pour les transformer en variables exploitables pour la classification des patients. Voici les variables que nous avons retenues pour le projet.

A - Distance Lymphocyte/Tumeur


En effet, pour traduire l'information que nous avait donné le médecin qui était qu'un bon diagnostic signifiait que les lymphocytes soient près de la tumeur, nous avons décidé de créer la variable « Distance Lymphocyte/Tumeur » qui génère un histogramme avec les distances entre tous les lymphocytes et leur cellule cancéreuse les plus proches.



Cellule bleu : lymphocyte Cellule jaune : tumeur Cellule verte : stroma

B - Distance Lymphocyte à la bordure de la tumeur

Cette variable ressemble beaucoup à la première variable « Distance Lymphocyte/Tumeur » cependant elle génère des valeurs négatives dans l'histogramme si le lymphocyte est à l'intérieur de la tumeur et positives si le lymphocyte est à l'extérieur de la tumeur : cette variable traduit l'information du médecin tel que les lymphocytes présents doivent être en grand nombre dans la tumeur pour un bon diagnostic.




C - Densité de Lymphocyte

Cette variable est assez spéciale car elle utilise pas le même outil que les deux premières variables : elle ne manipule pas la notion de distance. Cette variable consiste à recueillir les densités des lymphocytes à différentes distances de la bordure catégorisées par des « bandes ». Chaque bande fait 5um et on considère aussi l'intérieur de la tumeur donc on prend en compte deux fois plus de bandes. De plus, une autre différence avec les autres variables est que l'histogramme ne comporte que très peu de bins (égale aux nombre de banderoles utilisées donc une dizaine) comparé aux autres variables énoncées (égale aux nombre de lymphocytes donc plusieurs milliers) mais comme on compare les histogrammes d'une même variable, cela ne pose pas de problème. Les valeurs pour chaque bande sont normalisées par le nombre global de lymphocyte.

D - L'aire de la bande à l'interface Lymphocyte/Tumeur

Cette variable manipule un nouvel outil : une aire. En effet, grâce à la triangulation de Delaunay qui est un type de graphe mathématique (qui relie entre eux les points du graphe pour faire des triangles tel que aucun point du graphe ne se trouve à l'intérieur du cercle circonscrit de l'un des triangle du graphe), nous sommes capable de modéliser l'interface entre la bordure de la tumeur et la bordure des lymphocytes par l'aire de tous les triangles qui sont entre ces deux bordures. L'histogramme de cette variable est donc la somme des aires des triangles à l'interface entre la bordure de la tumeur et la bordure des lymphocytes. Instinctivement, plus l'aire de l'interface est grande, moins les lymphocytes ont réussi à infiltrer la tumeur ce qui est synonyme de mauvais diagnostic.




Cellule bleu : lymphocyte Cellule rouge : tumeur Cellule verte : stroma
Aire rose : Interface


E - Taille du groupe de cellules d'un même type

Cette variable manipule notre dernier outil : une quantité. Nous nous sommes intéressés cette fois-ci à regarder les lymphocytes eux-mêmes et non leur place dans leur environnement. Cette variable nous apporte beaucoup d'informations car non seulement elle décrit le nombre de groupes de lymphocytes présents sur la coupe mais notamment le nombre de lymphocytes dans chaque groupe. On appelle « blob » un groupe de cellule.

Cancers blobs




Lymphocytes blobs



F - Distance entre groupe de cellules d'un même type

Cette dernière variable manipule aussi une distance mais représente cette fois ci la distance entre les groupes de cellules d'un même type. Cette information permet de voir par exemple si les groupes de lymphocytes sont isolés pour attaquer la tumeur ou si ils sont proches pour attaquer la tumeur efficacement. De plus, si on considère le type « cancer », on pourrait intégrer l'information du médecin qui disait que les coupes avec un grand nombre de petites tumeurs signifient que la tumeur peut co-exister dans le tissu sans être protégée par la grosse tumeur : ceci est très mauvais signe pour le diagnostic du patient. On peut souligner que la variable « Taille du groupe de cellules d'un même type » permet en partie de valider cette affirmation.



2.3 - Les résultats


Les données des patients de cette première base de données ont été accessibles sur le site '<https://portal.gdc.cancer.gov>'. Toutes les photos que nous avons utilisé viennent de la base de donnée TCGA qui fournit les coupes histologiques de milliers de patients atteints de tout type de cancers et pleins d'autres informations générales sur eux comme leur sexe, leur âge, la « race », l'historique alcoolique, l'historique de tabagisme, ou encore un apport d'informations biologiques avec le nom et le nombre de gènes impliqués. Pour cette première base de données, nous avons donc travaillé avec 115 patients au départ mais seulement 94 à la fin : il a fallu virer des patients avec des ROI inadaptés c'est à dire ceux qui ne représentaient pas la bordure tumeur/stroma ou encore avec une proportion de cancer trop élevé etc... Les patients de la première base de données ont un cancer du poumon de type adénocarcinome au stade IA ou IB : ce qui était intéressant sur cette première base de patients, c'était la possibilité de « prévoir » la gravité de la maladie et ainsi donner une chance au médecin de pouvoir agir le plus tôt possible. Sur ces 94 patients restants, 14 sont décédés et 70 sont vivants : on remarque que la classe n'est pas équilibré. Le nombre de patients dans la base est très faible malheureusement : cela peut être expliquer par la difficulté à recueillir des données de santé et surtout des données de cette envergure.

Les résultats sont dans l'ensemble très satisfaisants : en effet, cinq des six variables présentés dans la partie 2.2 sont statistiquement significatives, c'est à dire que les deux groupes modélisés sont statistiquement indépendants. Voici le tableau des p-values du log-rank test pour chaque variable essayées :

Features	p-values (Log-rank)
Répartition des distances (ajustées) lymphocyte - cancer	0.0022584655839803943
Répartition des distances (non ajustées) lymphocyte - cancer	0.05737550179413786
Aire de l'interface cancer-stroma	0.34611512869827965
Aire de l'interface cancer-lymphocyte	0.11365602326149649
Ratio # lymphocyte / # toutes cellules	0.019320720457706653
Répartition de la taille des amas de cancer	0.19982450948750324
Répartition de la taille des amas de lymphocytes	0.034908978593598615
ratio tumeur	0.16864032817841768
densité de lymphocyte	0.0009978137511020583
Combinaison	10 ⁻⁵

On va donc garder que 3 des 4 variables significatives, sachant que la distance Lymphocyte/Cancer est moins significative qu'une autre variable « Distance Lymphocyte à la bordure de la tumeur », très proche intuitivement de celle-ci donc n'apporte pas plus d'information.
 Essayons de comprendre la significativité des variables en regardant des exemples d'histogrammes de patients.

1) Distance Lymphocyte à la bordure de la tumeur → P-value : 0.00225




Population 0 du dessus

Population 1 du dessous

On remarque que le groupe qui survit le mieux (population 0) possède des valeurs de distance négatives bien plus élevées que le groupe qui meurt plus rapidement (population 1) : c'est compréhensible car cela veut dire que les lymphocytes sont plus infiltrés dans la tumeur et ainsi d'après le médecin, cela améliore le diagnostic de survie.

2) Taille du groupe de cellules d'un même type → P-value : 0.03490




Population 0 du dessus

Population 1 du dessous

On remarque que le groupe qui survit le mieux (population 0) possède des groupes de lymphocytes très élevés (très difficilement perceptible étant donné l'échelle choisie) ce qui signifie que le patient se défend bien et a produit des gros groupes de lymphocytes pour éliminer la tumeur.

3) Densité de Lymphocyte $\rightarrow 0.000997$



On remarque pour cette variable que les lymphocytes vont beaucoup plus loin dans la tumeur, et que les zones sont beaucoup plus denses chez la population 0 que la population 1 (on remarque ce fait en regardant les grandes valeurs négatives à gauche) ce qui, comme la première variable « Distance Lymphocyte à la bordure de la tumeur » traduit le caractère intrusif des lymphocytes ou non dans la tumeur.

Maintenant que les significativités des variables ont été expliquées biologiquement, nous avons eu l'idée de faire une combinaison de ces variables pour classer au mieux nos patients en deux groupes distincts. Pour ce faire, nous avons décidé de faire contribuer les variables à la classification à hauteur de la significativité et la performance de leur classification individuelle.

Concrètement, l'indice qui reflète la performance d'une classification est la p-value : plus il est petit, plus la significativité est importante. On a donc décidé intuitivement que le poids de chaque variable à la matrice de distance finale serait le logarithme inverse de sa p-value :

$$\text{weight}^{(i)} = \log \left(\frac{1}{p^{(i)}} \right)$$

Ainsi, grâce à cette combinaison de poids optimisée, nous avons obtenu une p-value au log-rank test de 7.36×10^{-8} ce qui est très significatif et qui surpasse de beaucoup les autres classifications individuelles.

2.3 - Les différentes distances

Après ces résultats obtenus, nous étions très satisfait de la p-value trouvée qui était très significative. Nous avons déjà fait un gros travail sur la recherche de variable, je me suis donc intéressé à optimiser une autre partie du processus de classification globale pour améliorer la p-value du log-rank test : la distance entre les histogrammes des patients. Notre classification repose exclusivement sur la matrice de distance entre tous les patients de la base de données et celle-ci est calculée en faisant la distance de Wasserstein entre chaque patient deux à deux. Cette distance est pertinente, seulement je me suis demandé si selon les variables et donc les outils qu'on manipule (distance, densité, aire, quantité), certaines autres distances n'étaient pas plus efficace dans la classification. Mon but étant alors de trouver d'autres distances qui maximisent la p-value du log-rank test mais aussi qu'on peut interpréter et comprendre.

1) Distance de Lévy-Prokhorov

La distance de Lévy-Prokhorov est certainement la plus compliquée mathématiquement parlant. Elle utilise deux distributions μ et ν et la distance entre les deux distributions est déterminée par :

$$\pi(\mu, \nu) := \inf \{ \varepsilon > 0 \mid \mu(A) \leq \nu(A^\varepsilon) + \varepsilon \text{ and } \nu(A) \leq \mu(A^\varepsilon) + \varepsilon \text{ for all } A \in \mathcal{B}(M) \}$$

Avec A^ε définit comme le ε - voisinage de A définit par :

$$A^\varepsilon := \{ p \in M \mid \exists q \in A, d(p, q) < \varepsilon \}$$

Ce qu'il faut comprendre, c'est que plus ε est faible plus on va tendre vers $\mu(A) = \nu(A)$, c'est à dire que les deux distributions sont égales. Ce qui est intéressant ici, c'est qu'on ne compare pas deux distributions dans leur globalité mais localement avec le ε - voisinage

2) Distance de Hellinger

Beaucoup de distances statistiques entre deux distributions P et Q se définissent par la « f-divergence » de P par rapport à Q par :

$$D_f(P \parallel Q) = \int_{\Omega} f\left(\frac{dP}{dQ}\right) dQ$$

Le choix de la fonction f permet donc de donner une diversité aux distances selon le type de distributions P et Q . Dans le cas de la distance de Hellinger, la fonction f choisie est :

$$f(t) = 2(1 - \sqrt{t})$$

On obtient donc la distance H entre deux distributions P et Q :

$$H^2(P, Q) = \frac{1}{2} \int (\sqrt{dP} - \sqrt{dQ})^2$$

Cette distance est intéressante car elle est symétrique, non duale et c'est la distance canonique de l'espace des distributions de la famille exponentielle.

3) Distance de Bhattacharyya

La distance statistique de Bhattacharyya fait partie de la famille dit « α -divergente » qui est plus adapté aux lois discrètes. Cette famille est elle même un cas particulier de la famille dit « f -divergente ».

La famille dit « α -divergente » est défini par :

$$D_\alpha(P||Q) = \lim_{x \rightarrow \alpha} \frac{1}{x-1} \log \left(\sum_{i=1}^n \frac{p_i^x}{q_i^{x-1}} \right)$$

La distance statistique de Bhattacharyya est donc un cas particulier ou $\alpha = 1/2$.

Cette distance est la plus utilisée pour la mise en correspondance entre deux observations basées sur l'histogramme de couleur. De plus, elle est couramment utilisé pour des problématiques de séparation de classes en classification automatique ce qui est exactement ce que nous voulons faire.

4) Distance de kullback_leibler

La distance de kullback_leibler fait partie aussi de la famille dit « α -divergente ». Elle est un cas particulier où $\alpha = 1$.


$$D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)}$$

On remarque que la distance de kullback_leibler ne respecte pas toutes les propriétés d'une distance : elle n'est pas symétrique et ne respecte pas l'inégalité triangulaire. La divergence de Kullback-Leibler s'interprète comme la différence moyenne du nombre de bits nécessaires au codage d'échantillons de P en utilisant un code optimisé pour Q plutôt que le code optimisé pour P . C'est donc un point de vue intéressant, mais difficilement interprétable à nos données de santé.

5) Distance de kolmogorov_smirnov

Cette distance est très particulière car il s'agit du même concept théorique que le log-rank test converti en distance que nous effectuons pour évaluer la performance de notre classification. En effet, cette distance entre deux distributions est directement le logarithme négatif de la p-value qui est la probabilité que les deux distributions suivent la même loi de probabilité. On constate que cette distance est plus adaptée à des distributions continues alors que nos histogrammes sont discrets, mais tester ce type de distances permet de justifier nos intuitions.

Maintenant que nous avons défini toutes les distances utilisées, le but est maintenant de comparer les classifications de chaque variable prédéfini dans 2.1 pour voir si une distance est pertinente en particulier pour certaines variables.



L'axe des abscisses représente la p-value de la classification et l'ordonnée représente la proportion de la population qui à un meilleur diagnostic de survie. Comme nous pouvons le constater la distance de wasserstein est pertinente pour les notions de distance : on obtient pour les variables « adjuce distance L/C » et « distance L/C » une p-value proche de 0. Pour les variables qui manipulent des outils comme l'aire ou la longueur de blobs, la distance de Bhattacharyya semble très efficace et obtient en moyenne les meilleures p-values. La distance de Hellinger semble pertinente pour la variable « inter blobs L » alors que la distance Lévy - prokhorov semble efficace pour la « densité de lymphocyte ». On favorise davantage les proportions plus proche de 0.5 pour une meilleure interprétation.

Pour conclure, la distance de Wasserstein reste pertinente dans la globalité des variables mais les distances de Bhattacharyya, Hellinger et Lévy - prokhorov pourraient améliorer la p-value de la classification finale avec toutes les variables et leurs poids associés.

3

SEGMENTATION ET LABELISATION
DE LA DEUXIEME BASE DE DONNES

3.1 - La base de données

Après les résultats satisfaisants trouvés avec la première base de données, je me suis intéressé à reproduire les résultats sur des patients atteints du même cancer : l'adénocarcinome, qui est un cas particulier du cancer du poumon, mais cette fois ci au stade IIA et IIB. Le but étant de voir si ces résultats sont applicables aussi à un stade plus avancé et bien évidemment de voir les différences et les points communs entre les deux bases de données.

La deuxième base de données est composée d'au départ 101 patients mais au final 79 patients car des patients ont été supprimés car la qualité de leur ROI n'étaient pas satisfaisante : soit cela ne représente pas assez bien la bordure cancer/stroma, soit il y a trop de cancer sur le ROI.

La base de données comporte 20 patients morts et 59 patients vivants qui est une meilleur proportion Mort/Vivant que la première base de données.

La base de données répertorie l'identifiant du patient, son statut (Vivant/Mort), son « Days to last follow up » qui est le dernier jour ou le patient a été suivi.

# id patient	Vivant / Mort	Days to last follow up	File
1	T	50	patient1.svs
2	F	150	patient2.svs
3	T	45	patient3.svs
...	...	...	...

Exemple de la base de données utilisée




Exemple de patients morts (rouge) et vivants (noir).

3.2 - La procédure de labelisation

La procédure de labelisation est très importante pour l'acquisition de bons résultats : c'est la première étape après le téléchargement de la coupe sous format .svs depuis la base de données.


Grace au logiciel *Imagescope*, on peut lire les images téléchargées sous format .svs de la base de données TCGA pour ensuite labéliser les ROI à la main : le but est de sélectionner plusieurs régions d'intérêt (ROI) sous forme de carré à la bordure entre la tumeur et le stroma. Evidemment, le choix peut être faux ou partiellement faux car on se base juste à la simple photo de la coupe histologique, c'est pour cela que plusieurs ROI sont sélectionnés pour être sur d'avoir au moins un ROI représentant la bordure.




Après cette étape, pour chaque patient, on obtient un fichier .svs et un fichier.xml (qui représente les coordonnées des ROIs sélectionnés). Toutes les conditions sont donc réunies pour commencer la segmentation de toutes les cellules des ROIs ainsi que la classification de chaque cellule dans un des trois phénotypes (lymphocyte, stroma et cancer).

3.3 - La segmentation des cellules et la classification




Les coupes de tous les patients étant maintenant labellisées en plusieurs ROIs, on peut maintenant utiliser la première partie de l'algorithme conçu par des chercheurs américains pour justement segmenter et classifier des cellules du cancer du poumon. La première partie s'effectue sur Matlab et extrait les cellules de chaque ROI avec la fonction `cell_extract.m`.



Immédiatement après avoir extrait toutes les cellules de l'image s'en suit la partie Deep-learning sous R. L'algorithme qui utilise Matlab a préparé pour chaque cellule un patch, c'est à dire une petite image, centrée sur la cellule. Toutes les cellules rentrent dans un CNN (conventional neural network) qui est un algorithme de classification très performant en particulier sur les images pré-entraînées par ces mêmes chercheurs, qui a une précision sur le phénotype des cellules de 92%. Dans notre cas, l'erreur sur une cellule n'est pas très importante étant donné le nombre de cellules par coupe.



On obtient donc pour chaque ROI de patient, un ROI labellisé après l'extraction des coordonnées de cellules et en sortie du CNN, un ROI phénotypé près à servir de support pour l'extraction des variables sous forme d'histogramme.



ROI labellisé après l'algorithme utilisant Matlab

ROI phénotypé possédant trois classes : Lymphocyte (bleu), Cancer (rouge), et stroma (vert).

J'ai donc utilisé ce procédé à nouveau pour extraire tous les ROI phénotypés des 79 patients de la deuxième base de données. Ce procédé prend énormément de temps car il nécessite l'attention permanente de l'utilisateur en cas de crash ou de problème : il arrive que parfois, l'image soit mal exportée ou que le ROI ne rentre pas dans la norme de l'algorithme des chercheurs américains (trop petit ou trop grand) sans compter que pour un patient, le procédé prend 4h sur un ordinateur de l'école. J'avais préalablement créé ma base de données avec les ROIs labellisés à l'avance mais j'ai dû improviser en re-labelisant les ROIs défectueux pour être sûr d'avoir une base de données de qualité avec au moins deux ROIs pertinents.

La base de données des 79 patients étant maintenant créée, je me suis intéressé à refaire le processus dans 2) pour pouvoir ainsi essayer d'avoir la meilleure p-value dans le but de classer au mieux les 79 patients en deux groupes distincts pour en tirer des conclusions pour les stades IIA et IIB de la maladie puis comparer les résultats obtenus avec les stades IA et IB pour pouvoir comprendre les points communs et les différences à un stade différent de la maladie.


4

ANALYSE ET COMPARAISON DES
RESULTATS


4.1 - Les résultats de la deuxième base de données

Comme pour la première base de données, le processus a été réalisé depuis le début : tout d'abord, pour chaque variable, j'ai créé les 79 histogrammes pour ensuite calculer les 7 matrices de distance correspondantes aux 7 variables en testant chacune des 6 distances choisies précédemment. On obtient donc 42 classifications différentes et le but est donc de regarder en détail quelle classification donne la meilleure p-value pour comprendre quelle distance est pertinente sur une variable en particulier. On rappelle que la p-value est en abscisse et que la proportion de la classe prédominante est en ordonnée. Voici ci-dessous les p-values de chaque variable en fonction de la distance utilisée :


Interblobs_L




Distance_L/C




Density_L




Adjuced_distance_L/C




Aire_interface_L/C



Longueur_blobs_L









Longueur_blobs_C



Interprétons maintenant les résultats : deux variables sont très pertinentes et se démarquent beaucoup. Il s'agit des variables « Interblobs_L » et « Aire_interface_L/C » qui sont respectivement les distances entre les différents amas de lymphocytes et les aires à l'interface entre les cellules cancéreuses et les lymphocytes. La p-value des ces deux variables est en moyenne respectivement de 10^{-4} et 10^{-3} ce qui est très significatif. On remarque que pour ces deux variables, la distance de Bhattacharyya se démarque étant donné sa meilleure p-value et sa proportion proche de 0.5 (plus facilement interprétable si les deux classes sont équilibrées).

Ensuite, on constate que les variables « Distance_L/C », « Longueur_blobs_C » et « Density_lymphocyte » qui sont respectivement les distances entre les lymphocytes et les cellules cancéreuses, la longueur des amas de cellules cancéreuses et la densité des lymphocytes autour de la tumeur obtiennent une p-value minimum de 10^{-2} en moyenne, ce qui reste significatif. Pour ces variables, la distance de Kullback-Leibler semble se démarquer.

Pour finir, la variable « Longueur_blobs_L » qui est la longueur des amas de lymphocytes est significative pour une p-value minimum de 10^{-2} pour une seule distance : celle de Kolmogorov. La variable « Adjuced_distance_L/C » n'a donné aucune p-value significative pour aucune des 6 distances.




Maintenant qu'on a choisi les variables associées à leur meilleure distance, on peut commencer à créer la matrice de distance finale composée d'une combinaison des matrices de distances de toutes les variables significatives (dans notre cas elles sont toutes significatives à part « Adjusted_distance_L/C »). L'idée, comme l'a été exposée dans le début du rapport dans la partie résultat de la première base de données, est de faire contribuer chaque variable à hauteur de la qualité de sa p-value. Plus précisément, le poids de chaque variable est l'opposé du logarithme de la p-value : plus la p-value est faible, plus le poids est élevé.

Voici les poids attribués à chaque variable :

Interblobs_L :	8.03
Aire_interface_L/C :	7.24
Distance_L/C :	3.29
Longueur_C :	6.03
Density_lymphocyte :	5.31
Longueur_L :	4.45

Après la construction de la matrice finale, on obtient la classification suivante :



Grace à cette classification regroupant toutes les variables significatives avec leur poids respectif, on obtient une p-value minimum de 3.24×10^{-5} avec une proportion de 0.67 dans le groupe prédominant, ce qui est dix fois mieux que notre ancienne meilleur classification. Il serait donc maintenant intéressant de comparer ces résultats avec ceux de la première base de données.

4.2 - Comparaison avec la première base de données

Il est intéressant de voir les différences du point de vue des résultats entre les deux bases de données pour mieux comprendre les phénomènes qui interviennent et surtout pour confirmer la validité de la procédure. De plus, les patients n'étant pas au même stade (IIA et IIB pour la deuxième), il est important de comprendre les répercussions du changement de stade des patients sur la qualité de la classification finale.

Les seules différences initiales entre les deux bases de données sont le nombre de patients dans les bases respectives (79 patients dans la deuxième contre 115 patients dans la première) et le stade de la maladie (IIA et IIB dans la deuxième contre IA et IB dans la première). Les résultats trouvés sont différents non seulement du point de vue de la p-value de toutes les variables mais aussi des distances utilisées pour chaque variable.

En effet, les variables n'ont pas du tout le même comportement selon la base de données utilisée : pour la première, les variables pertinentes étaient la distance ajustée entre les lymphocytes et les cellules tumorales (« Adjuced_distance_L/C »), la densité des lymphocytes (« Density_lympho ») et la longueur des amas de lymphocytes (« Longueur_blobs_L »). Ces variables utilisaient la distance de Wasserstein qui donnait globalement les meilleurs résultats de p-value pour cette première base de données même si la distance de Bhattacharyya était plus efficace pour la longueur des amas de lymphocytes ainsi que la distance de Lévy - prokhorov pour la densité de lymphocyte.

Pour la deuxième base de données, les variables pertinentes étaient la distance entre les différents groupes de lymphocytes (« Interblobs_L ») et l'aire à l'interface entre les cellules cancéreuses et les lymphocytes (« Aire_interface_L/C »). La distance donnant la meilleure p-value pour ces deux variables est la distance de Bhattacharyya. D'autres variables sont aussi significatives : il s'agit de la distance entre les lymphocytes et les cellules cancéreuses (« Distance_L/C »), la densité des lymphocytes (« Density_Lympho ») et la longueur des amas de cellules cancéreuses (« Longueur_blobs_C »). On obtient de bonnes p-value pour ces variables avec la distance de Kullback-leibler. La dernière variable significative est la longueur des amas de lymphocytes (« Longueur_blobs_L ») et obtient une bonne p-value avec la distance de Kolmogorov.

On constate donc que les variables les plus pertinentes sont différentes pour les deux bases de données : la première exploite la distance ajustée entre les lymphocytes et les cellules tumorales (« Adjusted_distance_L/C »), la densité des lymphocytes (« Density_lympho ») et la longueur des amas de lymphocytes (« Longueur_blobs_L ») alors que la deuxième base de données exploite la distance entre les différents groupes de lymphocytes (« Interblobs_L ») et l'aire à l'interface entre les cellules cancéreuses et les lymphocytes (« Aire_interface_L/C »). De plus, on constate que les distances utilisées ne sont pas les mêmes : on va privilégier la distance de Wasserstein dans la première base des données et la distance de Bhattacharyya pour la deuxième base des données. On peut donc penser que la différence de stade des patients impliquerait une modification cellulaire qui favoriserait les variables donnant une bonne p-value de la deuxième base de données. On ne peut pas exclure le fait qu'il y est un facteur propre aux patients de la base de données car on travaille avec des bases de données de moins de 100 patients.

4.3 - Conclusion

Les résultats trouvés après le travail sur les deux bases de données est très satisfaisant : la classification finale sépare les patients en deux groupes statistiquement indépendants que ce soit avec des patients au stade IIA et IIB ou avec des patients au stade IA et IB. Cela pourrait donc aider les médecins à travailler en amont avec le patient dès qu'il est admis à l'hôpital en le soumettant à notre algorithme de classification : le médecin pourra alors agir en conséquence en prenant des mesures en fonction des résultats de l'algorithme. De plus, grâce à l'étude que nous avons effectué sur deux bases de données avec des patients de stades différents, les médecins pourront essayer de comprendre biologiquement pourquoi une certaine variable est significative à un stade donné et ainsi mieux comprendre la maladie et peut-être améliorer les traitements à venir. Une étude intéressante pour la suite serait de créer une troisième base de données venant d'une autre source que TCGA : cela nous permettrait de confirmer nos résultats et ainsi s'affranchir du biais pour avoir utilisé la même base de données pour tous les patients.