

Utilisation de méthodes d'apprentissage automatique pour prédire l'implantation d'un pacemaker dans les suites d'une procédure de TAVI

*Mémoire de Master 2 Biologie-Santé,
spécialité "Signaux et images en biologie et médecine"*

par Amine EL OUAHIDI

Sous la direction de :

- Dr. Bastien PASDELOUP (MCU, Lab-STICC, UMR CNRS 6285, IMT Atlantique) ;
- Dr. Romain DIDIER (EA 3878 GETBO, Service de Cardiologie, CHU de Brest).

Préparé à : IMT Atlantique / Lab-STICC, Technopôle de Brest.

Soutenance le : 02/09/2022.

Remerciements

Je tiens à adresser toute ma reconnaissance au Dr. Bastien PASDELOUP, pour ses enseignements, sa disponibilité et surtout ses judicieux conseils qui m'ont permis de mener à bien ce projet.

Je tiens à remercier le Dr Romain DIDIER, pour son soutien constant, et sa confiance.

Je remercie le Pr MANSOURATI, de m'avoir donné les moyens de réaliser cette année recherche.

Je tiens à remercier Yassine, pour sa patience, sa disponibilité, sans qui ce travail n'aurait pas eu la même valeur.

Je remercie le Dr HAMONIC et le Dr NICOL pour leur aide précieuse dans ce projet de recherche.

Je remercie tous les membres de l'équipe BRAIn, pour ces 6 mois très enrichissants humainement et intellectuellement.

Finalement je remercie mes parents et Coline pour leur soutien indéfectible tout au long de mon parcours.

Résumé

Introduction : L'implantation d'un pacemaker (IPM) demeure la principale complication dans les suites du TAVI. Nous avons étudié l'apport de méthodes d'intelligence artificielle dans la prédiction de l'IPM à partir de données acquises en pré-TAVI, en nous intéressant particulièrement aux données scanographiques. **Méthodes :** Inclusion rétrospective de 521 patients, 18.8% de pacemaker post-TAVI. Prédiction en utilisant des méthodes d'apprentissage automatique sur des données catégorielles et numériques ($\mathcal{D}_{num}$), ainsi qu'une méthode d'apprentissage profond sur des données d'imagerie 3D scanographiques ($\mathcal{D}_{img}$). **Résultats :** Sur $\mathcal{D}_{num}$, nos meilleurs modèles atteignent $81.3\% \pm 0.7$ (AUC-ROC) et 63% (score F1). Les données extraites de l'imagerie y tiennent une place centrale dans les prédictions. Sur $\mathcal{D}_{img}$, les meilleurs performances sont atteintes à partir de la séquence non injectée : $70.2\% \pm 0.3$ (AUC-ROC) et 50.1% (score F1). **Conclusion :** Les méthodes d'apprentissage automatique peuvent générer des modèles de prédiction robustes et performants.

Mots-clés : TAVI; pacemaker; apprentissage automatique; apprentissage profond; scanner TDM.

Abstract

Introduction: Pacemaker implantation (PMI) remains the main complication after TAVI. We studied the contribution of artificial intelligence methods in the prediction of PMI from data acquired in pre-TAVI and with particular interest in CT data. **Methods:** Retrospective inclusion of 521 patients, 18.8% post-TAVI pacemaker. Prediction using machine learning methods on categorical and numerical data ($\mathcal{D}_{num}$) and using a deep learning method on 3D CT imaging data ($\mathcal{D}_{img}$). **Results:** On $\mathcal{D}_{num}$, our best model reaches $81.3\% \pm 0.7$ (AUC-ROC) and 63% (F1 score). Data obtained from measurements on 3D scans have a central place in prediction. On $\mathcal{D}_{img}$, best performance is achieved with the non-injected sequence: $70.2\% \pm 0.3$ (AUC-ROC) and 50.1% (F1 score). **Conclusion:** Machine learning methods can generate robust prediction models with high performance.

Keywords: TAVI; pacemaker; machine learning; deep learning; CT scanner.

Liste des symboles

k NN	k Nearest Neighbors
AUC-ROC	Area Under the ROC Curve
BAV1	B loc A trio- V entriculaire de type 1
BAVc	B loc A trio- V entriculaire c omplet
BBD	B loc de B ranche D roit
BBG	B loc de B ranche G auche
CNN	C onvolutional N eural N etwork
DICOM	D igital I maging and C OMmunications in M edicine
DL	D eep L earning
ECG	É lectro C ardio G ramme
ETT	É chocardiographie T rans- T horacique
IPM	I mplantation d'un P ace M aker
LASSO	L east A bsolute S hrinkage and S election O perator
LR	L ogistic R egression
LWL	L ocally W eighted L earning
ML	M achine L earning
MLP	M ulti L ayer P erceptron
RA	R étrécissement A ortique
RF	R andom F orest
RFE	R ecursive F eature E limination
ROC	R receiver O perating C haracteristic
ROS	R andom O ver- S ampling
SHAP	S Hapley A dditive e x P lanations
SM	S eptum M embraneux
SMOTE	S ynthetic M inority O versampling T Echnique
SVM	S upport V ector M achine
TAVI	T ranscatheter A ortic V alve I plantation
TDM	T omo D ensito M étrie à rayon X
THG	T rouble de H aut G rade
XGBoost	e Xtreme G radient B oosting

Table des matières

1	Introduction	1
1.1	Rétrécissement aortique et TAVI	1
1.2	Apprentissage automatique et modèles d'apprentissage profond	3
1.3	Apprentissage automatique et TAVI dans la littérature	4
1.4	Objectifs de notre travail	5
2	Matériels et méthodes	6
2.1	Population de l'étude	6
2.2	Cible de la prédiction	6
2.3	Composition des jeux de données	7
2.4	Protocole scanner	8
2.5	Analyse statistique	9
2.6	Apprentissage automatique	9
2.6.1	Prise en compte des valeurs extrêmes	10
2.6.2	Prise en compte des données manquantes	10
2.6.3	Normalisation et encodage	11
2.6.4	Prise en compte du caractère déséquilibré de la cible	11
2.6.5	Sélection de variables	12
2.6.6	Modèles de ML et analyse des performances	12
2.6.7	Validation croisée imbriquée	13
2.7	Apprentissage profond à partir des images scanner	14
2.7.1	Format de nos images	14
2.7.2	les convolutions, base de l'architecture de DL "Resnet"	15
2.7.3	Pré-traitements sur les images DICOM	16
2.7.4	Segmentation	16
2.7.5	Entraînement du modèle	17
3	Résultats	18
3.1	Principaux résultats sur $\mathcal{D}_{num}$	18
3.1.1	Construction d'un modèle de ML utilisant une régression logistique	18
3.1.2	Comparaison des performance des modèles	19
3.2	Variables complémentaires	20
3.3	Place des données scanner	20
3.4	Comparaisons aux autres études	21
3.5	Analyses des performances avec la cible "trouble de haut grade"	21
3.6	Performances obtenues sur $\mathcal{D}_{img}$	22
4	Discussion	22


4.1	Forces de notre travail	22
4.2	Limites	23
4.3	Perspectives	24
5	Conclusion	26
	Références	26
Annexe A	Détails sur les métriques utilisées	I
A.1	Précision, Rappel, Score F1	I
A.2	Accuracy	I
A.3	Matrice de confusion	I
A.4	Courbe ROC, AUC-ROC, AUC-PR	I
Annexe B	Paramètres influençant la qualité de l'imagerie	III
Annexe C	Caractéristiques de la population	IV
Annexe D	Préparation des données pour l'apprentissage	VI
Annexe E	Utilisation des variables per-pré-post TAVI	VIII
Annexe F	Variabilité histologique du septum membraneux	IX

1 Introduction


1.1 Rétrécissement aortique et TAVI

Le rétrécissement aortique (RA) est la plus fréquente des cardiopathies valvulaires dans les pays industrialisés. Sa prévalence est estimée à 5% des sujets de plus de 75 ans en Europe. En France, l'INSEE recensait 200 000 cas en l'an 2000 et projette 600 000 cas en 2050. L'évolution naturelle du RA symptomatique est très péjorative avec une médiane de survie inférieure à 2 ans à partir de la survenue des premiers symptômes.

L'implantation d'une valve aortique par voie percutanée (TAVI – *transcatheter aortic valve implantation*) est une technique développée en France depuis 2001 consistant en l'implantation d'une valve aortique biologique par voie percutanée et endovasculaire (à travers les vaisseaux). Elle permet le remplacement de la valve aortique pathologique par une prothèse biologique acheminée par voie endovasculaire, le plus souvent à partir de l'artère fémorale au niveau du pli de l'aîne. Contrairement à la chirurgie cardiaque, cette intervention ne nécessite ni anesthésie générale, ni ouverture du thorax, ni circulation sanguine extracorporelle (Figure 1).



(a) Schéma d'implantation d'un TAVI¹.



(b) Radiographie d'un patient implémenté d'un pacemaker.

FIGURE 1 : Implantation d'un TAVI et sa principale complication : l'implantation d'un pacemaker.

L'intervention permettant l'implantation d'un TAVI a tout d'abord été validée dans la prise en charge des patients inopérables (et donc récusés de la chirurgie cardiaque)^[1], puis des patients à risque opératoire haut^[2] et intermédiaire^[3] et enfin aux patients à bas risque^[4,5]. Cette validation progressive a été rendue possible par l'amélioration des techniques et des systèmes d'implantation, avec pour conséquence une réduction de l'incidence des complications per- et post-opératoires liées au TAVI.

Parmi ces complications, la survenue d'un trouble de la conduction électrique demeure la plus fréquente, et son incidence ne semble pas diminuer significativement avec le temps^[6]. Il est alors nécessaire d'implanter un pacemaker, ce qui n'est pas sans risque pour les patients. En effet, on observe chez les patients implantés un risque accru d'insuffisance cardiaque, d'infection, et de mortalité.

¹Source : <https://www.action-groupe.org/fr/post/tavi>.

Des facteurs de risques de survenue de troubles de la conduction en post-TAVI ont été mis en évidence, incluant des données cliniques et électrophysiologiques^[7] comme le sexe masculin, la présence d'un bloc atrio-ventriculaire de type 1 (BAV 1) et la présence d'un bloc de branche droit (BBD). De plus, du fait de la proximité entre les voies de conduction électrique du cœur et la région d'implantation du TAVI, des facteurs de risques anatomiques ont également été identifiés. Parmi ces derniers, on distingue tout particulièrement la longueur du septum membraneux (SM) et le degré de calcification de la valve aortique native. Hamdan *et al.*^[8] ont montré que la longueur du SM constituerait un critère prédictif de survenue de troubles de la conduction avec comme hypothèse que plus la distance entre la valve et les voies de conduction est grande, plus faible est le risque. Concernant le degré de calcification, représenté par la mesure scanner du score calcique, Latsios *et al.*^[9] ont montré que plus le score calcique est élevé, plus le risque de troubles de la conduction est important (Figure 2).




FIGURE 2 : Mesures du septum membraneux et du score calcique respectivement chez un patient ayant présenté des troubles de la conduction en post-TAVI (A et B), et chez un patient n'ayant pas présenté ces troubles (C et D).

En se basant entre autres sur ces données anatomiques, les constructeurs de valves ont émis de nouvelles recommandations concernant les techniques d'implantation, incluant notamment une implantation plus haute de la valve : la *radiolucent method*^[10] et la *cuspl overlap technique*^[11]. Toutefois, l'implantation plus haute de la valve peut s'accompagner de la survenue d'autres types de complications, comme la migration de la prothèse, un risque d'accident vasculaire cérébral, de fuites peri-prothétiques ou d'une obstruction artérielle coronaire.

La prédiction du risque de survenue d'un trouble conductif menant à l'implantation d'un pacemaker dans les suites d'une procédure de TAVI demeure donc toujours un challenge d'actualité en cardiologie. En effet, la détection en pré-opératoire des patients à haut risque permettrait de mettre en place des mesures de prévention et d'adapter la prise en charge.

Nous nous attachons donc dans notre travail à prédire le risque d'implantation d'un pacemaker dans les suites d'un TAVI. Pour cela, une des piste de plus en plus utilisées dans le domaine médical est l'utilisation des outils d'intelligence artificielle.

1.2 Apprentissage automatique et modèles d'apprentissage profond

L'apprentissage automatique (ML – *machine learning*) est un sous-domaine de l'intelligence artificielle à l'intersection entre les statistiques, les mathématiques et l'informatique. Les algorithmes de ML construisent des modèles de prédiction à partir d'un jeu de données (*dataset*) d'apprentissage. Pour cela, on divise généralement ce *dataset* en trois sous-ensembles disjoints :

- L'ensemble d'entraînement (*training set*), utilisé pour effectuer le processus d'apprentissage du modèle. Il contient des données annotées, que les algorithmes de ML utilisent pour apprendre à prédire l'annotation à partir des données ;
- L'ensemble de validation (*validation set*), qui permet d'évaluer la capacité de généralisation du modèle. Il contient également des données annotées, qui servent à vérifier la performance du modèle quand les annotations sont supposées inconnues ;
- L'ensemble de test (*test set*), qui sert une fois le processus d'entraînement terminé à évaluer les performances du modèle, et donc sa capacité prédictive en conditions réelles.

Le processus d'apprentissage consiste donc à exploiter l'information contenue dans le *training set*, et à retenir le modèle minimisant l'erreur de prédiction sur le *validation set*. Ce modèle est ensuite évalué sur le *test set* pour comparaison avec d'autres modèles. Quand les annotations sont numériques, on parle de tâche de régression. Si celles-ci sont catégorielles, on parle alors de tâche de classification, et on évalue la performance des modèles par le pourcentage de données correctement classifiées (*accuracy*). Dans ce rapport, on considère une tâche de classification binaire, c'est à dire que l'annotation à prédire est un booléen.

L'apprentissage profond (DL – *deep learning*) est un sous-ensemble du ML dont la popularité a explosé ces dernières années, par sa capacité à dépasser en performance les algorithmes à l'état de l'art dans de très nombreux domaines. Ces modèles consistent en l'enchaînement de couches de neurones artificiels paramétrables, permettant d'extraire progressivement de la donnée des attributs abstraits, qui sont ensuite recombinaés pour prédire l'annotation associée. L'organisation interne des couches au sein d'un modèle de DL définit une architecture de réseau de neurones. Une force de ces modèles est leur capacité à exploiter directement des données complexes (*e.g.*, son, image) là où de nombreux algorithmes de ML plus classiques (*e.g.*, forêt aléatoire (RF – *random forest*), régression logistique (LR – *logistic regression*), boosting de gradient (XGBoost – *extreme gradient boosting*)) reposent principalement sur des données numériques ou catégorielles.

1.3 Apprentissage automatique et TAVI dans la littérature

Dans le domaine médical, les techniques de ML occupent une place de plus en plus grandissante, notamment dans deux sous-domaines que sont la classification diagnostique et la prédiction pronostique. Dans le domaine du TAVI, plusieurs études ont montré la supériorité des modèles de ML, tout particulièrement dans la prédiction du pronostic en post-TAVI, par rapport aux scores statistiques habituels^[12]. Concernant la prédiction du risque d'implantation d'un pacemaker (IPM) en post-TAVI, à ce jour, trois études récentes ont mis en évidence l'intérêt des modèles de ML :

- Truong *et al.*^[13] ont obtenu une AUC-ROC de 81% et une *accuracy* de 71% par un modèle de RF (plus de détails sur ces métriques sont donnés en [Annexe A](#));
- Tsushima *et al.*^[14], en utilisant un modèle de LR combiné à un mécanisme d'apprentissage localement pondéré (LWL – *locally weighted learning*), ont obtenu une AUC-ROC de 82% et une *accuracy* de 71% ;
- Pandlet *et al.*^[15], en utilisant un modèle XGBoost, ont obtenu une AUC-ROC de 70.6%.

Il nous paraît toutefois important de souligner deux éléments :

- Dans ces trois études, sont utilisées des données cliniques, électriques (ECG), échographiques (ETT), et procédurales (type de valve, voie d'abord). À notre connaissance, aucune étude n'utilise de données tomodensitométriques à rayon X (TDM) pour prédire le risque d'IPM, alors qu'il existe des facteurs de risques d'IPM décelables sur les TDM (voir [Section 1.1](#));
- Dans ces trois études, des données pré- et per-TAVI sont utilisées. Les données pré-TAVI sont toutes les données relatives aux comorbidités, caractères démographiques, et examens cliniques et para-cliniques réalisés avant l'implantation du TAVI. Les données per-TAVI sont des données recueillies pendant la procédure du TAVI (type de valve, taille de la valve, pré- ou post-dilatation, voie d'abord). En plus de ces données, Truong *et al.*^[13] utilisent également des données post-TAVI, à savoir la survenue d'un bloc de branche gauche (BBG) de novo, et les valeurs ΔPR et ΔQRS , caractérisant la différence entre les mesures de temps de conduction électrique intracardiaque des segments "PR" (de l'oreillette au ventricule) et "QRS" (intra-ventriculaire), respectivement, visualisées sur l'ECG, entre le pré-tavi et le premier ECG post-TAVI.

Enfin, conformément aux recommandations^[16], la réalisation d'un examen TDM fait aujourd'hui partie du bilan pré-opératoire avant un TAVI. En effet, cet examen est actuellement le *gold-standard* pour la détermination de la taille de l'anneau aortique et des rapports entre la valve aortique et les ostias coronaires. Ces paramètres étant déterminants dans la planification de procédure comportant notamment le type de bioprothèse percutanée à implanter.

1.4 Objectifs de notre travail

L'objectif de notre travail est donc de prédire le risque d'IPM dans les suites d'une procédure de TAVI, en utilisant les outils de l'intelligence artificielle. Il se décompose en deux objectifs :

- Nous entraînons des modèles d'apprentissage automatique à prédire le risque d'implantation d'un pacemaker dans les suites d'un TAVI. Nous nous attachons ici à prédire cette cible grâce aux données cliniques, paracliniques et d'imagerie acquises en pré-TAVI exclusivement, dans un but de cohérence médicale. Ces modèles sont entraînés sur des données numériques et catégorielles, qui intègrent notamment des mesures obtenues à partir de données scanographiques, contrairement aux autres travaux de la littérature. En complément, des résultats exploitant les données per- et post-TAVI sont également fournis afin de comparer les résultats de notre approche à ces derniers dans des conditions similaires ;
- Nous exploitons également un modèle de DL pour prédire le risque d'IPM directement à partir des imageries scanner.

La suite de ce rapport est organisée comme suit. En [Section 2](#), nous présentons la méthodologie de ce travail. Dans un premier temps, nous définissons successivement de la [Section 2.1](#) à la [Section 2.5](#) la population de l'étude, la cible de prédiction, le type de données utilisées, le protocole scanner et l'analyse statistique. Par la suite, en [Section 2.6](#), nous présentons les étapes (de traitement des données puis les modèles de prédiction) utilisées pour développer les modèles d'apprentissage automatique, et en [Section 2.7](#) celles utilisées pour développer le modèle d'apprentissage profond sur les données scanner. En [Section 3](#), nous structurons les résultats de notre travail en 6 parties : la [Section 3.1](#) porte sur les principaux résultats du ML. Un grand nombre de techniques de préparation des données ont été considérées. Nous avons évalué l'apport de celles-ci pour une régression logistique, et avons comparé les performances avec différents modèles de ML. Nous présentons ensuite successivement : les résultats des modèles selon les données considérées en [Section 3.2](#), l'apport des données scanner dans les prédictions de ML en [Section 3.3](#), une comparaison de notre meilleur modèle aux autres études en [Section 3.4](#), l'analyse les performances de notre meilleur modèle à prédire une autre cible (les troubles de la conduction de haut grade) en [Section 3.5](#), et les performances de prédiction de l'IPM grâce à de l'apprentissage profond directement à partir des données 3D scanographiques en [Section 3.6](#). La [Section 4](#) tire des conclusions à partir de ces résultats.

Dans ce document, les termes techniques du ML sont principalement donnés en anglais, et sont formatés en italique. Une traduction française est donnée dès que possible pour indication, bien que peu usitée dans la littérature du domaine.

2 Matériels et méthodes

2.1 Population de l'étude

Ce travail est une étude monocentrique rétrospective, incluant les patients implantés d'un TAVI entre janvier 2019 et décembre 2021 au Centre Hospitalier Universitaire (CHU) de Brest, France.

Le protocole de l'étude (n°29BRC22.0127) a été approuvé par le Comité d'Éthique du CHU de Brest et conduit en respectant les principes de la Déclaration d'Helsinki, ainsi que de la réglementation relative aux recherches rétrospectives sur données en vigueur. Tous les patients ont reçu un formulaire de non opposition et d'information concernant la collecte de leurs données médicales et leur analyses.

Les critères d'exclusion de l'étude étaient : les patients porteurs d'un stimulateur cardiaque (pacemaker ou défibrillateur) avant l'implantation du TAVI ($n = 75$), et la présence de données scanographiques TDM manquantes ou de mauvaise qualité ($n = 18$). Après application des critères d'exclusion, $n = 521$ patients ont été inclus dans l'analyse (Figure 3).




FIGURE 3 : Schéma de sélection des patients inclus dans l'étude

2.2 Cible de la prédiction

Nous avons choisi d'entraîner nos modèles afin de prédire le risque d'IPM dans les suites du TAVI (< 28 jours). En pratique, cette décision est prise après concertation de l'équipe de soins intensifs de cardiologie composée au minimum d'un cardiologue électrophysiologiste (implanteur de pacemaker) et d'un cardiologue hémodynamicien (implanteur de TAVI). La Table 1 détaille les indications de pacemaker de notre étude, ainsi que le nombre d'implantations au sein de notre jeu de données associées à ces causes. Nous ne détaillons pas ici les indications de pacemaker qui peuvent être retrouvées dans les dernières recommandations de la société européenne de cardiologie^[17].

Indication d'implantation du pacemaker	Nombre PM ($n = 98$)
BBG de novo + nécessité d'un traitement ralentisseur	1
BBG de novo $> 180\text{ms}$	6
BAV2 mobitz 2	8
BAV2 mobitz 1 de novo + nécessité d'un traitement ralentisseur	6
BAV1 + BBG + nécessité d'un traitement ralentisseur	7
Dysfonction sinusale symptomatique	3
BAV complet	58
Bloc de branche alternant	10

TABLE 1 : Indication d'implantation du pacemaker dans les suites du TAVI (< 28 jours).

Étant donné qu'il n'existe pas actuellement de recommandations claires concernant les indications d'IPM en post-TAVI, il existe une différence entre le taux de pacemakers effectivement implantés et le taux de pacemakers effectivement utilisés par les patients. En effet, on estime que seulement $\frac{1}{3}$ des patients utilisent leur pacemaker dans l'année suivant son implantation. Dans notre étude, et de manière similaire aux autres études de la littérature, nous avons développé notre modèle afin de prédire l'IPM. L'annotation à prédire à partir des données par les modèles est donc une variable binaire indiquant si oui ou non un pacemaker a été implanté.

Afin de tenter de s'affranchir du biais lié à l'incertitude sur l'indication d'implantation, nous avons également entraîné nos modèles à prédire une autre cible, à savoir les troubles de la conduction de haut grade (THG), *i.e.*, bloc atrio-ventriculaire complet (BAVc) persistant, survenue d'un bloc de branche alternant de novo, et dysfonction sinusale symptomatique. En effet, ce type de troubles étant à risque vital en l'absence de pacemaker, son implantation est indiscutable (Class I ESC clinical guidelines 2021^[17]).

Notre *dataset* contient 98 patients (18.8%) implantés d'un pacemaker, dont 71 patients (13.6%) ayant été implantés sur l'indication trouble de haut grade.

2.3 Composition des jeux de données

Comme mentionné en [Section 1.4](#), nous cherchons à répondre à notre question de recherche en effectuant les prédictions à partir d'algorithmes issus du ML. Parmi ces algorithmes, les modèles de DL ont la capacité d'exploiter les données d'imagerie directement, sans nécessiter de calcul de mesures. Nous considérons donc dans ces travaux les deux bases de données suivantes, constituées des mêmes 521 patients :

- $\mathcal{D}_{num}$, constituée uniquement des données numériques et catégoriques associées aux patients, qui peuvent être divisées en cinq catégories principales : antécédents médicaux, données cliniques, données ECG, données ETT, données TDM. Outre la mesure du score calcique et la longueur du SM, l'ensemble des variables ont été extraites rétrospectivement dans les dossiers médicaux des patients. Le score calcique et la longueur du SM ont été mesurés en aveugle de la cible de prédiction (IPM post-TAVI). Par ailleurs, 10% des mesures du SM ont été mesurées une seconde fois par un cardiologue senior en ima-

gerie. La cohérence interne entre les deux opérateurs a été confirmée par l'utilisation du test alpha de Cronbach : 0.87 avec un intervalle de confiance à 95% [0.77;0.93]. Enfin, nous avons également recueilli des données per- et post-implantation du TAVI. En effet, même si l'objectif de notre travail est de prédire l'IPM à partir de données pré-TAVI, ces données serviront à des fins de comparaison avec les autres études (voir [Section 1.3](#));

- $\mathcal{D}_{img}$, constituée des images 3D issues des examens d'imagerie TDM. Pour chaque patient, nous avons recueilli les images au format DICOM (voir [Section 2.4](#)).

Le nettoyage des données et l'examen de leur qualité ont été effectués par un second opérateur afin de minimiser les erreurs et les données aberrantes qui pourraient pénaliser l'étude.

2.4 Protocole scanner

Conformément aux recommandations^[16], l'évaluation TDM cardiaque (dans le cadre du bilan pré-TAVI) s'effectue en deux parties. Une première phase sans injection de produit de contraste iodé, synchronisée à l'ECG permettant notamment le calcul du score calcique valvulaire. Une deuxième phase avec injection synchronisée à l'ECG selon un mode rétrospectif permettant notamment d'effectuer une reconstruction en diastole et en systole (voir [Figure 4](#)).




FIGURE 4 : Protocole scanner cardiaque : (A) Séquence injectée en systole ; (B) Séquence injectée en diastole ; (C) séquence non injectée.

Dans notre études, deux appareils scanners TDM ont été utilisés : AQUILION ONE GENESIS TOSHIBA ($n = 290$) et EDGE SIEMENS ($n = 231$). Les images ont été reconstruites sur un logiciel de post-processing (Syngo.via ; Siemens Healthcare).

La résolution des coupes scanners (axes x et y), quelque soit la marque du scanner, est de 512×512 pixels. Le nombre de coupes (*slices*) réalisées (axe z) varie selon le caractère injecté ou non de la séquence scanner. En effet, la séquence sans injection, ayant surtout pour objectif l'analyse du score calcique, contient moins de coupes que les séquences injectées utilisées pour effectuer des mesure plus fines comme le diamètre de l'anneau ou l'analyse des coronaires. Concernant la distance entre centres de deux pixels adjacents en mm (*pixel spacing*), la distribution des valeurs s'étend de 0.3 à 0.6mm avec une médiane à 0.43mm. Enfin l'épaisseur des coupes en mm (*slice thickness*) varie également selon le caractère injecté ou non de la séquence

scanner et selon la marque du scanner (pour le scanner Toshiba, elle est de 0.5mm quelque soit la séquence, et pour le scanner Siemens de 3mm en non injectée et 0.6mm en injectée). Des diagrammes représentant la distribution des scanners, réalisés en fonction de ces paramètres (nombre de *slices*, *pixel spacing* et *slice thickness*) sont donnés en [Figure 12](#) en [Annexe B](#).

Afin d'intégrer de l'information issue des données TDM dans $\mathcal{D}_{num}$, nous avons inclus :

- Les mesures de l'anneau aortiques (structure virtuelle correspondant à l'alignement du point d'attache le plus bas des cusps valvulaires aortiques) : grand diamètre (mm), petit diamètre (mm), surface en diastole (mm^2), surface en systole (mm^2);
- La longueur du SM ([Figure 2](#), A et C), définie comme la distance entre la partie inférieure de la valve aortique et la partie supérieure du septum musculaire cardiaque. Sa mesure a été effectuée en mode double oblique, sous la cusp-non coronaire ou sous la commissure séparant la cusp-coronaire droite et la non coronaire (selon l'anatomie cardiaque du patient). Afin d'effectuer ces mesures, nous avons utilisé la technique de Hamdan *et al.* ^[8];
- La mesure du score calcique ([Figure 2](#), B et D), réalisée après contournage manuel de l'ensemble des calcifications valvulaires aortique. Par la suite, un calcul du score d'Agaston a été effectué par le logiciel de post-traitement Syngo.via software.

2.5 Analyse statistique

Les variables continues ont été exprimées en moyennes avec écart-types et nous les avons comparées en estimant leurs significativités par rapport à la valeur prédite (implantation d'un pacemaker dans les 28 jours après le TAVI). Dans le cas où une variable suit une loi normale, sa significativité a été estimée avec un test de Student, et avec un test de Mann Whitney Wilcoxon dans le cas contraire. La normalité de la distribution des variables a été évaluée au préalable par un test de Kolmogorov-Smirnov. Les variables catégorielles ont été exprimées en nombre absolu et pourcentage, et comparées par un test du Chi 2. Pour tous les tests, un seuil de p-value ≤ 0.05 a été considéré pour établir la significativité.

L'analyse a été conduite en utilisant le langage de programmation Python 3.8.10 et sa bibliothèque Scipy.stats.

2.6 Apprentissage automatique

De la [Section 2.6.1](#) à la [Section 2.6.6](#), nous présentons les traitements sur les données utilisées par les algorithmes de ML. Pour chaque partie, une ou plusieurs techniques ont été considérées, ainsi que la non-application du traitement correspondant. Une analyse exhaustive de toutes les combinaisons de ces traitements (*e.g.*, pas de traitement des valeurs extrême + imputation des données manquantes par la moyenne + ... ; suppression des données extrêmes + imputation par

$kNN + \dots; \dots$) a été réalisée afin de déterminer les traitements bénéfiques à la classification des données. Pour toutes les configurations, une validation croisée imbriquée, présentée en [Section 2.6.7](#), a été effectuée. Les résultats de cette étude sont donnés en [Annexe D](#) et synthétisés en [Section 3.1.1](#).

2.6.1 Prise en compte des valeurs extrêmes

On appelle valeur extrême toute observation d'une variable différant grandement des autres observation de la même variable. Certains algorithmes de ML sont sensibles à ce type de données. En effet, de telles valeurs peuvent biaiser la construction des modèles. Il existe plusieurs manières de traiter les valeurs extrêmes. Dans notre travail, nous avons considéré deux traitements possibles de ces données :

- Pas de traitement des données extrêmes ;
- Troncature au dessus d'un certains seuil ([Figure 5](#)), défini à partir du Z-score (standardisation). On supprime alors de notre jeu de données les valeurs dont la valeur absolue est supérieur ou égale à la valeur absolue de 3 déviations standards. Le Z-score est calculé en soustrayant la moyenne et en divisant par l'écart-type.




FIGURE 5 : Procédure de suppression des valeurs extrêmes (*outliers*) à partir du Z-score².

2.6.2 Prise en compte des données manquantes

Certains algorithmes étant également sensibles aux données manquantes, pour faire face à cette problématique, nous avons utilisé et comparé quatre approches :

- Remplacement par la valeur de la moyenne ;
- Remplacement par la valeur de la médiane ;
- Remplacement par la valeur du mode (valeur la plus fréquente) ;
- Imputation par k plus proches voisins ($kNN - k$ nearest neighbors), *i.e.*, remplacement des valeurs manquantes par la moyenne des valeurs des k plus proches voisins.

²Source : <https://www.analyticsvidhya.com/blog/2022/08/dealing-with-outliers-using-the-z-score-method/>.

2.6.3 Normalisation et encodage

La normalisation est une étape de pré-traitement qui permet de changer l'échelle des variables numériques. Cette étape permet de redimensionner les variables numériques pour qu'elles soient comparables sur une échelle commune. Elle permet ainsi d'éviter la contribution plus importante de variables simplement en raison d'une distribution plus large dans l'entraînement des modèles. Nous avons considéré les approches suivantes :

- Pas de normalisation des données ;
- Standardisation des données : cette technique consiste à ramener pour chaque variable la moyenne à 0 et l'écart-type à 1 et rendre ainsi normale la distribution de nos variables. Pour ce faire, on soustrait pour chaque valeur de la variable la moyenne du *training set*, puis on divise le résultat par l'écart-type du *training set* ;
- Normalisation par MinMax : cette technique consiste à soustraire le minimum, puis diviser par la soustraction du maximum et du minimum, afin de placer les valeurs entre 0 et 1. Ainsi la valeur minimale sera de 0, la maximale de 1, et les écarts entre les valeurs normalisées resteront proportionnels à leurs valeurs d'origine.

Comme certains algorithmes de ML ne peuvent pas traiter les variables catégorielles, nous avons utilisé la méthode du *one-hot encoding*, qui transforme chaque valeur de caractéristique catégorielle en une valeur binaire, c'est-à-dire que nous créons un nombre de nouvelles variables binaires égal au nombre de catégories possibles de la variable catégorielle initiale.

2.6.4 Prise en compte du caractère déséquilibré de la cible

Dans notre *dataset*, la cible principale de prédiction (IPM) est survenue chez 18.8% des patients. Notre ensemble de données est donc déséquilibré par rapport à la cible de prédiction. Le déséquilibre des classes est un problème courant en apprentissage automatique, en particulier en classification binaire. Les modèles de ML visent généralement à minimiser l'erreur de prédiction et donc à maximiser l'*accuracy* (voir [Annexe A](#) pour plus de détails sur les métriques utilisées). Dans le cas de données déséquilibrées, la prédiction systématique de la classe majoritaire maximisera l'*accuracy*, ce qui nous donnera une fausse impression de la qualité de prédiction de notre modèle.

Pour faire face à cela, nous avons d'abord analysé plusieurs métriques d'évaluation autres que l'*accuracy*, puis nous avons utilisé et comparé des techniques de ré-échantillonnage :

- Pas de prise en compte du caractère déséquilibré des classes ;
- Sur-échantillonnage aléatoire (ROS – *random oversampling*), qui duplique aléatoirement des éléments de la classe minoritaire pour équilibrer le jeu de données ;

- Sur-échantillonnage synthétique (SMOTE^[18] – *Synthetic minority oversampling technique*), qui fonctionne en sélectionnant des exemples (de la même classe) qui sont similaires, et génère un nouvel exemple entre eux par interpolation.

Quelle que soit la technique utilisée (ROS ou SMOTE) le rééquilibrage est effectué seulement sur le *training set*. Les autres *datasets* quand à eux sont laissés déséquilibrés car leur répartition est inconnue dans un contexte d’application réelle.

2.6.5 Sélection de variables

La sélection de variables est le processus qui permet d’évaluer la pertinence des variables dans la prédiction des résultats. Cette étape est cruciale pour améliorer l’apprentissage automatique en sélectionnant les variables les plus importantes et en éliminant les variables redondantes et non pertinentes pour prédire avec précision la variable cible.

Nous avons choisi d’implémenter l’élimination récursive des variables (RFE – *recursive feature elimination*). Cette technique sélectionne récursivement des ensembles de plus en plus petits de variables. À chaque itération, nous entraînons notre modèle sur un ensemble de données de plus en plus petit, en commençant par l’ensemble du *training set*, puis nous estimons l’importance de nos variables pour éliminer la ou les moins importantes. Nous itérons jusqu’à ce qu’à atteindre une seule variable et évaluons la performance de notre modèle à chaque étape. Ainsi nous pouvons choisir les variables les plus pertinentes et leur nombre en fonction des performances de prédictions du modèle.

Nous avons comparé plusieurs techniques d’évaluation de l’importance de nos variables afin d’identifier lors des itérations de la RFE les variables les moins pertinentes :

- Sélection de caractéristiques statistiquement significatives (en débutant avec $p < 0.05$);
- Sélection par LASSO^[19];
- Sélection par Boruta^[20];
- Sélection par SHAP^[21].

Les variables sélectionnées par chaque technique ont été analysées par un médecin cardiologue expert pour discuter de leur pertinence clinique.

2.6.6 Modèles de ML et analyse des performances

Dans cette étude, nous avons évalué plusieurs modèles classiquement utilisés en classification^[22] pour prédire l’IPM post-TAVI :

- *random forest* (RF);
- XGBoost;

- *multilayer perceptron* (MLP) ;
- *support vector machine* (SVM) ;
- Régression Logistique (LR).

Il est à noter que le MLP se base sur des réseaux de neurones et peut être vu comme faisant partie de la sous-famille des modèles d'apprentissage profond.

Pour développer nos modèles, le langage de programmation Python 3.8.10 ainsi que sa bibliothèque Scikit-learn ont été utilisés.

La performance des modèles ML pour prédire l'IPM post-TAVI a été analysée en utilisant l'*accuracy*, le score F1, l'AUC-ROC et enfin l'AUC-PR (voir [Annexe A](#) pour plus de détails).

2.6.7 Validation croisée imbriquée

Pour rappel, il est classique de diviser le jeu de données en 3 parties : *training set*, *validation set* et *test set* (voir [Section 1.2](#)). L'inconvénient d'un tel découpage statique est que les résultats dépendent d'une organisation des données qui, même si effectuée aléatoirement, peut contenir des biais, et ne permet pas de produire des intervalles de confiance sur les résultats. Une alternative est la validation croisée imbriquée, que nous avons réalisée dans ces travaux ([Figure 6](#)). Cette validation consiste en deux parties :

- Un *cross-testing* (partie gauche de la [Figure 6](#)) : Le jeu de données est séparé en 10 parties stratifiées de tailles égales, 9 dédiées au train (*training set A*) et 1 au test (*test set*). Pour chaque choix possible du *test set*, on effectue un entraînement d'un modèle, indépendamment des 9 autres entraînements. Cette technique permet d'obtenir une estimation plus réelle des véritables performances d'un modèle sur l'ensemble du jeu de données. Le score reporté pour un modèle est donc la moyenne des 10 scores obtenus ;
- Pour trouver les paramètres optimaux de nos modèles, nous réalisons, pour chacun des 10 entraînements du *cross-testing*, une *cross-validation*. Pour une configuration d'entraînement donnée, nous divisons le *training set A* en 5 sous-parties, 1 dédiée au *validation set* et 4 au *training set* (*training set B*). On ajuste ainsi les paramètres du modèle en entraînant sur le *training set B* et en optimisant la capacité de prédiction sur le *validation set*. On itère cette procédure pour tout choix du *validation set*. À l'issue de cette étape, on récupère les paramètres optimaux (amenant à la meilleure performance sur le *validation set*), et on effectue un entraînement du modèle sur l'ensemble du *training set A* afin de fournir une prédiction pour le *test set* en cours.

Cette technique est répétée 8 fois, afin de réduire la variance de nos résultats. Le résultat final est donc une moyenne de ces $8 * 10$ entraînements. La validation croisée imbriquée nous permet donc de :

- Limiter l'*overfitting*, qui est un phénomène qui se produit lorsque les modèles sur-apprennent les données d'entraînement, ce qui conduit à d'excellentes performances sur le *training set* mais à de mauvais résultats sur de nouvelles données ;
- Maximise l'apprentissage, en faisant en sorte d'utiliser l'intégralité de notre jeu de données pour l'entraînement, la validation et le test (très utile si effectif de petite taille) ;
- Estimer la variance de nos modèles. En effet, la variance peut provenir de plusieurs endroits, que ce soit dans la nature même de nos modèles ou alors dans le découpage du *dataset*. Ainsi, plus le *dataset* est petit, plus la variance est problématique. Cette technique nous permet de calculer un écart-type et fournir des intervalles de confiance à 95%.




FIGURE 6 : Schéma de la validation croisée imbriquée

2.7 Apprentissage profond à partir des images scanner

2.7.1 Format de nos images

Les examens d'imagerie sont stockés au format standard international *Digital Imaging and Communications in Medicine* (DICOM). Un fichier DICOM comprend l'image, et également des métadonnées (attributs) telles que des données cliniques sur le patient (*e.g.*, identité, nom du centre, nom du médecin prescripteur de l'examen), sur les modalités d'acquisition (*e.g.*, type d'imagerie, matériel d'imagerie, données sur l'injection de contraste, données sur la résolution).

La sérialisation est le processus de conversion d'un objet en flux d'octets pour stocker l'objet ou le transmettre à la mémoire, une base de données ou un fichier. Son principal objectif est d'enregistrer l'état d'un objet afin de pouvoir le recréer si nécessaire. L'attribut "Transfer Syntax UID" renseigne sur la méthode utilisée pour la sérialisation ainsi que sur l'existence d'une méthode de compression des images. Concernant nos données, quelle que soit la marque du scanner, la méthode utilisée pour la sérialisation était "Explicit VR Little Endian", et nos images n'étaient pas compressées.

Afin de visualiser les différents éléments des fichiers DICOM, nous avons utilisé le langage de programmation Python 3.8.10 avec sa bibliothèque Pydicom.

2.7.2 les convolutions, base de l'architecture de DL "Resnet"

Les réseaux neuronaux convolutifs (CNN – *convolutional neural networks*) sont des modèles de DL utilisant des couches dites de convolution, où chaque neurone est responsable d'un fragment de l'image. Ils sont inspirés du cortex visuel et adaptés aux problèmes de vision par ordinateur (*e.g.*, la classification ou la segmentation d'images). Ils sont associés en plusieurs couches entièrement connectées, qui décomposent les caractéristiques de l'image en une multitude de motifs différents (*feature maps*). Cette décomposition peut être répétée plusieurs fois de façon séquentielle au sein de l'architecture (Figure 7).

Les couches de convolution constituent un élément central du traitement d'image par l'apprentissage profond. Classiquement, en vision, on réalise des convolutions 2D, mais celles-ci (bien que moins courantes) existent également en 3D. Nous avons donc utilisé une architecture de réseau de neurones adaptée aux données 3D que nous manipulons, appelée "Resnet 3D", inspirée des modèles Resnet de référence pour la classification d'images 2D^[23].

L'implémentation des modèles a été réalisée en utilisant le langage Python 3.8.10 avec sa bibliothèque Pytorch. Les calculs ont été réalisés sur un GPU Nvidia-rtx-3090.




FIGURE 7 : Représentation d'une convolution avec un noyau de taille 3 * 3 et un pas de 2³.

³Source : <https://www.imaios.com/fr>.

2.7.3 Pré-traitements sur les images DICOM

Dans un premier temps, nous concaténons toutes nos images 2D en une image 3D en les ordonnant sur l'axe z , grâce à l'attribut "ImagePositionPatient" / "SliceLocation" contenu dans les métadonnées DICOM. Ensuite, nous ré-échelonnons les valeurs de nos images grâce à la transformation "Modality LUT". Cette transformation transforme les valeurs de pixels dépendantes du fabricant en valeurs de pixels significatives pour la modalité, et indépendantes du fabricant. Cela permet d'unifier les acquisitions provenant de différentes marques. Il s'agit d'une transformation linéaire, qui utilise les informations issues des des métadonnées : "Rescale Slope" (0028,1053) et "Rescale Intercept" (0028,1052).

Similairement aux modèles de ML nous avons effectué une étape de normalisations des images. Pour cela nous utilisons la méthode de la "Z-Normalisation". Ainsi, pour chaque image, nous avons soustrait à la valeur de l'intensité de chacun de ses pixels l'intensité moyenne de l'image et nous les divisons par la valeur de l'écart-type de l'intensité de l'image.

Nous utilisons pour ces traitements le langage de programmation Python 3.8.10 avec sa bibliothèque Torchio.

2.7.4 Segmentation

Dans le cadre de ce projet nous utilisons des images TDM 3D de forte résolution (voir [Section 2.4](#)). De par cette caractéristique, l'utilisation de ce type d'image dans des réseaux de neurones augmente drastiquement les besoins en puissance de calcul et le volume de mémoire vive nécessaire. Ainsi, afin de réduire la résolution de nos images, nous avons décidé de réduire la taille de ces dernières en recadrant autour du cœur. Pour cela, nous avons au préalable réalisé une segmentation du cœur afin d'exclure les structures adjacentes : tissus pulmonaire, digestif et pariétal. Pour cela, nous avons adapté le code issu d'une compétition Kaggle "Chest-ct-segmentation"^[24], pour le faire fonctionner sur nos données. En bref, ce code entraîne un modèle "U-net" (famille de modèles de DL classique en segmentation d'image) sur un jeu de données d'images scanographiques 2D (scanner thoracique)^[25], capable de segmenter le cœur, les poumons et la trachée.

Nos images scanographiques étant centrées sur le cœur, elles ne correspondent donc pas totalement aux images utilisées pour le développement du modèle de segmentation. Ainsi, nous avons ré-entraîné leur architecture sur leur jeu de données, en le rendant invariant aux zooms grâce à des traitement de "random-resize-crop" dans l'entraînement du modèle. Cette technique consiste à ne pas entraîner le modèle sur l'image complète mais sur un patch aléatoire et zoomé au sein de celle-ci. Chaque image est considérée plusieurs fois pour entraîner le modèle à partir de portions différentes.

Une fois le modèle ré-entraîné, nous avons fait passer nos images 3D comme une suite

d'images 2D successives afin d'en extraire des masques du cœurs. Suite à cela, nous en avons extrait des boîtes de délimitation cubiques (en 3D), en corrigeant manuellement les erreurs de segmentation. Celles-ci permettent de réduire la taille de nos images en les recardant ([Figure 8](#)).




FIGURE 8 : Segmentation d'une coupe 2D. En vert le masque obtenu grâce au U-net et en rouge le cadre déduit du masque.

2.7.5 Entraînement du modèle

Dans l'état actuel, le modèle est entraîné sur l'une des trois modalités (calcique, systole, diastole) à la fois afin de prédire l'IPM. Utiliser plusieurs séquences en même temps aurait nécessité une procédure et une architecture plus complexes (plusieurs canaux sur l'entrée du réseau ou alors plusieurs entrées) ainsi qu'un coup en calcul plus fort, mais amènerait probablement à un modèle fournissant de meilleures performances.

Similairement aux méthodes de ML, nous réalisons plusieurs fois nos entraînements en utilisant une *cross-validation* avec 5 sous-ensembles (et non plus une validation croisée imbriquée pour des raisons de ressources en calculs nécessaires), afin d'éviter le sur-apprentissage et estimer au mieux les performances de nos modèles. Le jeu de données est séparé aléatoirement en 85% pour le *training set* et 15%, pour le *test set*. Nous réalisons toute la procédure 10 fois afin d'estimer la variance de notre modèle. Le modèle sélectionné à la fin de l'entraînement par *cross-validation* est le modèle ayant les meilleures performances sur le *validation set*, que nous évaluons ensuite sur le *test set*.

Plus en détails, nous avons utilisé l'"entropie croisée binaire", comme fonction de perte pour l'entraînement du modèle. Il s'agit de la fonction de perte la plus standard pour la classification binaire. Afin de savoir quand arrêter l'entraînement nous utilisons une fonction d'*early stopping* qui permet d'arrêter l'entraînement une fois que la fonction de perte évaluée sur le *training set* ne décroît plus. Nous utilisons "Adam" comme *optimizer* et un *batch size* de 8 (choix lié à la quantité de mémoire vive disponible sur la carte graphique).

3 Résultats

3.1 Principaux résultats sur $\mathcal{D}_{num}$

3.1.1 Construction d'un modèle de ML utilisant une régression logistique

Dans cette section, nous détaillons la recherche exhaustive des traitements sur les données (voir [Section 2.6](#)) pour la régression logistique. Nous avons entraîné des modèles pour toutes les configurations possibles des traitements présentés, et présentons certaines d'entre elles (par souci de concision) en [Table 2](#) (les performances de l'ensemble des combinaisons sont disponibles en [Annexe D](#)). Dans cette table, un "-" dénote l'absence du traitement correspondant.

Rééchantillonnage	ROS	SMOTE	-	-	-	-	-	-
Valeurs aberrantes	-	-	Cut	-	-	-	-	-
Normalisation	Std	Std	Std	MinMax	Std	Std	Std	Std
Données manquantes	Moyenne	Moyenne	Moyenne	Moyenne	Moyenne	Mode	Médiane	kNN
AUC-ROC	77.9 ± 0.8	77.2 ± 0.7	71.6 ± 0.8	72.0 ± 0.9	72.1 ± 0.8	73.8 ± 0.8	73.0 ± 0.8	71.5 ± 0.6
Score F1	60.1	58.5	54.9	51.0	55.9	57.4	56.1	55.3
Accuracy	82.3	81.1	85.6	82.0	85.0	85.6	85.4	85.1

TABLE 2 : Performances de la régression logistique (LR) en fonction du preprocessing, on part de la meilleure combinaison à gauche, et à chaque nouvelle étape on change un élément pour analyser son implication.

On constate que le seul élément qui a véritablement de l'impact est la technique de *resampling* (ré-échantillonnage). ROS et SMOTE performant similairement, ROS étant plus simple que SMOTE, on décide de sélectionner ROS pour la suite. Pour le reste des paramètres, étant donné leur faible impact sur les performances, on décide de conserver la technique qui semble la plus simple, à savoir : pas de traitement des valeurs aberrantes, imputation des valeurs manquantes par la moyenne, et normalisation des nos données numériques par standardisation.

La [Table 3](#) présente la performance de la LR en fonction de la méthode de sélection de variables utilisée. Les méthodes SHAP et de sélection par significativité statistique ont obtenu les meilleures performances pour les métriques AUC-ROC, score F1 et *accuracy*, tout en conservant un nombre de variables très similaire et bien plus faible que Boruta ou LASSO. Cette dernière a obtenu un résultat très en dessous des 3 autres méthodes sur tous les critères.

	SHAP	Significativité statistique	Boruta	LASSO
AUC-ROC	81.3 ± 0.7	80.5 ± 0.7	79.5 ± 0.6	60.8 ± 0.7
Score F1	63.0	62.3	61.3	36.8
Accuracy	82.3	82.3	81.6	67.1
Nombre de variables	8	11	19	19

TABLE 3 : Performances de la régression logistique en fonction du critère d'importance des features pour la sélection de feature réursive

En utilisant les éléments ayant amené aux meilleurs performances (ROS, imputation des valeurs manquantes par la moyenne, standardisation, et sélection des variables par SHAP), puis entraînement du modèle de LR, nous avons obtenus une AUC-ROC de $81.3\% \pm 0.7$ et une PR-ROC de 66.9% en utilisant uniquement les données pré-TAVI. ([Figure 9](#), A et B). Par ailleurs grâce à la sélection de variables par SHAP, nous pouvons étudier les 8 variables qui ont servi

à entraîner le modèle, à savoir 3 variables scanographiques, 2 variables ECG, et 3 variables cliniques (Figure 9, C). A noter que les 2 premières variables (hauteur du septum membraneux et surface de l’anneau aortique en systole) sont tellement importantes pour effectuer les prédictions, qu’en ne sélectionnant que ces deux là on atteint une AUC-ROC de $77.9\% \pm 0.6$ et un score F1 de 59.9% .




FIGURE 9 : Performances de la régression logistique.

3.1.2 Comparaison des performance des modèles

Afin de réaliser les comparaisons entre les différents modèles de ML, nous avons émis l’hypothèse que les éléments importants pour la performance de la LR (pour rappel, ROS, imputation des valeurs manquantes par la moyenne, standardisation, et sélection des variables par SHAP) seront également importants pour les autres modèles. S’affranchir de cette hypothèse nécessiterait de relancer une étude exhaustive pour chaque modèle, ce qui serait extrêmement coûteux en temps et en ressources. Nous avons toutefois testé un grand nombre de configurations pour les autres modèles, et avons empiriquement observé la pertinence de cette hypothèse. Nous avons donc entraîné nos 5 modèles de ML, et avons reporté les performances obtenues en Figure 10. On observe des performances très similaires entre le modèle SVM et le modèle de la régression logistique, qui sont au dessus des autres modèles.




FIGURE 10 : Performances des différents modèles.

3.2 Variables complémentaires

Jusqu'à présent les résultats que nous avons présenté étaient issus de l'entraînement des modèles sur les données pré-TAVI uniquement. Afin de pouvoir se comparer aux autres études, nous avons également inclus dans cette deuxième partie les données per- et post-TAVI.

Dans la [Table 4](#), nous constatons que quelles que soient les données utilisées pour effectuer la prédiction, LR obtient les meilleures performances. On constate également que l'ajout des données per- et post- permet un gain de performance par rapport à l'utilisation isolée des données pré-TAVI, et cela quel que soit le modèle utilisé.

Variables	SVM			LR			RF			MLP			XGBoost		
	AUC	F1	Acc.	AUC	F1	Acc.	AUC	F1	Acc.	AUC	F1	Acc.	AUC	F1	Acc.
pré	81.1	63.4	82.3	81.3	63.4	82.7	77.3	60.7	83.3	75.9	56.6	79.1	73.3	56.5	83.6
pré + per	81.7	65.7	83.6	83.1	67.0	84.2	80.4	64.0	84.2	78.1	59.3	81.0	74.6	54.8	84.6
pré + per + post	82.3	65.8	84.0	82.9	65.4	83.5	80.3	63.5	85.4	78.9	60.9	81.9	76.1	61.7	86.1

TABLE 4 : Influence des variables pré-, per- et post-opératoires sur les différents modèles.

Chacun des 5 modèles a donc été entraîné 3 fois (uniquement avec les variables pré puis avec les variables pré + per et enfin en utilisant les variables pré + per + post). La [Table 12](#) en [Annexe E](#) liste les variables sélectionnées pour chacun des 15 entraînements.

3.3 Place des données scanner

Grâce à la sélection de variables, nous avons constaté dans les sections précédentes l'importance des variables scanographiques dans l'entraînement des modèles. Afin de confirmer cela, nous avons entraîné notre meilleur modèle (LR) avec et sans les données scanner TDM, puis nous avons également entraîné notre modèle en utilisant seulement les données scanographiques (8 variables). Dans la [Table 5](#), les résultats de ces analyses confirment la place centrale des don-

nées scanner. On observe une perte de performance notable sans ce type de données avec une performance chutant sous les 66% d'AUC-ROC. Alors que le fait d'utiliser seulement des données scanner nous fait obtenir d'excellentes performances, qui se rapprochent des prédictions utilisant toutes les variables importantes.

	Tout	Seulement Scanner	Sans Scanner
AUC	81.3 ± 0.7	80.0 ± 0.6	64.9 ± 0.7
Score F1	63.0	61.9	41.2
Accuracy	82.3	82.2	69.0

TABLE 5 : Influence des données scanner sur régression logistique.

3.4 Comparaisons aux autres études

Afin d'analyser nos performances avec celles des autres études, nous avons inclus dans la comparaison les 3 études récentes réalisant les prédictions à partir de modèles de ML (voir [Section 1.3](#)). Nous avons également inclus dans la comparaison une étude n'utilisant pas d'entraînement de modèles de ML mais où un score de risque a été dérivé d'une régression logistique multivariée (*EMORY risk score*)^[26]. Nous présentons dans la [Table 6](#) les résultats. Notre approche obtient les meilleures performances quelle que soit la métrique utilisée ou le type de données utilisées (pré, pré + per, pré + per + post).

	Notre approche	Truong 2021 ^[13]	Tsushima 2021 ^[14]	Pandey 2021 ^[15]	Kiani 2019 ^[26]
AUC-ROC	83.1	81	81	70.2	77.8
AUC-PR	74.8	N/A	72.6	N/A	N/A
Accuracy	84.2	76	74	N/A	N/A
Population	521	557	1160	288	1145
Cible prédite	IPM	IPM	IPM	IPM	IPM
Modèle	RL	RF	RL	XGBoost	score statistique
Données utilisées	Pré+per+post	Pré+per+post	Pré+per	Pré+per	Pré+per

TABLE 6 : Comparaison des performances de notre modèle avec celles des autres études.

3.5 Analyses des performances avec la cible "trouble de haut grade"

En passant de la cible implantation d'un pacemaker (IPM) à trouble de haut grade (THG), on observe (et cela quelle que soit la métrique utilisée) une diminution dans la performance notre modèle (LR). Les résultats de cette analyse sont donnés en [Table 7](#).

	Cible IPM	Cible THG
AUC-ROC	81.3 ± 0.7	73.5 ± 0.7
Score F1	63.0	50.0
Accuracy	82.3	77.9

TABLE 7 : Comparaison des performances selon la cible prédite.

3.6 Performances obtenues sur $\mathcal{D}_{img}$

Les performances des modèles de DL ont été retranscrites dans [Table 8](#). L'architecture est un Resnet 10 adapté aux images 3D. Le nombre d'*epochs* moyen par entraînement est de 89, ce qui équivaut à environ 1h20 d'entraînement (une *epoch* est dite terminée quand l'ensemble des individus du *training set* est passé à travers le modèle). Pour rappel, l'arrêt de l'entraînement se fait sur un critère d'*early stopping* déterminé au préalable.

	Calcique	Systole	Diastole
AUC-ROC	70.2 $\pm$ 0.3	62.3 $\pm$ 0.5	60.1 $\pm$ 0.4
Score F1	50.1	39.8	31.1
Accuracy	78.0	71.7	70.4

TABLE 8 : Performances du Resnet 3D selon les séquences scanographiques utilisées pour l'entraînement.

4 Discussion

4.1 Forces de notre travail

Les principaux résultats de notre travail sont donc :

- La réalisation d'une étude exhaustive des éléments de traitement des données amenant à l'entraînement de modèles performants pour la prédiction d'IPM et de THG ;
- La définition de modèles permettant une prédiction en pré-TAVI exclusivement, contrairement aux autres études de la littérature ;
- La mise en place d'un modèle de prédiction (LR) performant dépassant les performances des autres études dans la prédictions de l'IPM dans les suites d'un TAVI ;
- La prise en compte de données scanographiques (non utilisées dans les autres études) et l'identification de celles-ci comme facteurs d'augmentation des performances ;
- L'initiation d'un travail d'exploitation des images scanographiques 3D en utilisant des réseaux de neurones à base de convolutions 3D (DL).

De plus, nous nous sommes attachés à mettre en place une analyse des pré-traitements ainsi qu'un protocole d'entraînement nous permettant de maximiser nos performances et de diminuer la variance de nos résultats, afin d'apporter de la fiabilité dans les performances de nos modèles. Nous nous sommes donc particulièrement attachés à présenter ces éléments pour l'optimisation d'un modèle "simple", dont les lecteurs de revues médicales sont familiers (la régression logistique). A notre connaissance ce genre d'approche dans les études médicales utilisant du ML reste très peu réalisée, et les résultats des études sont souvent très difficile à reproduire en l'absence d'une description rigoureuse et exhaustive de la méthodologie, et difficile à interpréter en l'absence d'intervalles de confiance.

Il est courant dans la littérature médicale utilisant du ML de comparer les modèles utilisées à l'utilisation d'une régression logistique "classique". Nous avons fait le choix dans notre étude de ne pas réaliser cela et d'optimiser au même titre que les autres cette dernière. En effet, et notre travail nous le confirme, l'utilisation de la régression logistique sur des effectif de "petite taille" (quelques dizaines à quelque centaines d'individus) se relève tout à fait pertinente. Les modèles plus sophistiqués (*e.g.*, XGBoost, MLP, SVM) ayant été développés pour de la prédiction sur des jeux de données de plus grande taille, typiquement quelques milliers de données.

Nous avons également comparé en [Section 3.4](#) les performances de notre meilleur modèle avec celui des autres études. Bien que cette approche est standard en recherche médicale, nous tenons à signaler qu'elle ne peut être à prendre en totale considération ici. En effet, pour pouvoir comparer fiablement plusieurs modèles effectuant la même prédiction (issus de plusieurs études) il aurait été nécessaire de les tester sur le même jeu de données, chose que n'avons pas réalisée (pour des raisons multiples à la tête desquelles l'impossibilité de partage de données médicales). De plus, ces études ne reportent pas d'intervalle de confiance sur leurs prédictions. Il serait donc nécessaire de reproduire leurs approches en détails pour une comparaison plus fine des résultats.

Enfin, à travers les techniques de sélection de variables, nous avons mis évidence la place prépondérance des données scanner quantitatives dans la genèse des prédiction. En effet, après élimination récursive des variables une à une (technique de la RFE), notre modèle obtient ses meilleures performances en gardant seulement 8 variables dont 3 variables d'imageries scanner. Par ailleurs, en ne gardant que deux variables que sont la hauteur du septum membraneux et le diamètre de l'anneau, notre modèle obtient tout de même des performance importantes (AUC-ROC 77.9%).

Dans la deuxième partie de notre travail nous avons initié le développement de modèles de *deep learning* ayant pour vocation de prédire le risque d'IPM directement à partir d'imagerie 3D. Nous obtenons des résultats positifs, mais pour le moment en dessous de ceux des modèles entraînés sur les données de $\mathcal{D}_{num}$. Cependant, il reste de nombreuses pistes d'améliorations à explorer.

4.2 Limites

Premièrement, et cela est par définition inhérent aux études rétrospectives monocentriques, nous ne pouvons extrapoler les performances de notre modèle à d'autres centres. Par ailleurs, d'autres types de variables, et notamment scanographiques ou cliniques, auraient pu être incluses dans les prédictions (*e.g.*, antécédents de syncopes, mesure de septum inter-ventriculaire, présence de calcification aortique spécifiquement en regard du septum membraneux, profondeur d'implantation de la nouvelle valve et notamment son rapport par rapport aux voies de conductions, calcifications mitrales), mais également un plus grand nombre de patients auraient pu être in-

clus. Nous sommes bien conscients de ces lacunes, constituant clairement des limites à notre études. Pour y remédier, des études prospectives, sur un plus grand nombre de patients et surtout multicentriques seraient à mettre en place.

Deuxièmement comme nous l'avons signalé en [Section 2.2](#), le choix de l'IPM en post-TAVI est très critiquable. Pour y remédier, nous avons également entraîné nos modèles sur une cible moins discutables (troubles de la conduction de haut grade), mais nos modèles n'ont pas obtenu des performances similaires à l'IPM. Une autre piste aurait été de choisir comme cible l'utilisation du pacemaker (variable binaire) à 6 mois ou 1 an après son implantation, mais plusieurs éléments constituent actuellement des freins à ce choix. Le premier élément est le choix du seuil de stimulation qui définirait l'utilisation du pacemaker (1% ?, 50% ?, 80% ?), le deuxième étant que les seuils de fréquence cardiaque déclenchant la stimulation ("activation du pacemaker") varient selon les fabricants de pacemaker (chaque fabricant utilise des algorithmes propre ayant pour but notamment de favoriser la conduction native en "tolérant" certaines anomalies) mais également selon le type de programmation effectuée par le cardiologue pour répondre au besoin du patient (*e.g.*, programmation d'un pacemaker différente selon le mode de vie du patient, l'indication initiale du pacemaker).

Enfin, de notre point de vue, le principal biais de notre étude est un biais de mesure et notamment de la mesure de la longueur du septum membraneux. D'une part nous savons aujourd'hui sur des études histologique (voir [Figure 13](#) en [Annexe F](#)) que certains septums membraneux ne sont pas organisés de manière rectiligne mais plutôt de manière arquée voire même repliés sur eux même ; or cette subtilité est difficile à distinguer avec la résolution d'un scanner TDM où le SM est considéré comme un élément rectiligne. D'autre part, la réalisation de la mesure du SM n'est pas effectuée en pratique quotidienne chez tous les patients. De plus, selon la qualité de l'imagerie (influencée notamment par la qualité de la synchronisation cardiaque et/ou de l'injection) la mesure du SM (élément de petite taille, en moyenne 6.33mm dans chez les patients implantés d'un pacemaker et 9.02mm chez les autres) peut être mise à défaut. Ces éléments constituent clairement une limite à la diffusion de notre modèle en conditions réelles.

4.3 Perspectives

Nous obtenons des résultats intéressants, notamment sur les données de $\mathcal{D}_{num}$ via les modèles de ML. Ainsi, nous envisageons de publier nos résultats sous la forme d'un article de recherche. L'idée serait d'illustrer l'intérêt des modèles de ML utilisant des données scanner pour la prédiction de risque d'IPM.

Plus concrètement d'un point de vue clinique, au vu des limites énoncées, il est intéressant d'avoir un modèle capable de prédire le risque de pacemaker sans avoir besoin d'intervention humaine supplémentaire (qui peut être biaisée) comme des mesures ou des extractions de variables spécifiques. De ce fait, la démarche par analyse d'images scanner est intéressante pour

palier à cela. De plus, elle permet d’explorer le cœur dans sa totalité, et pourrait, si des bonnes performances sont atteintes, permettre de découvrir de nouveaux liens entre la morphologie et le risque d’IPM, en utilisant par exemple des outils de visualisation des portions d’images amenant à la prédiction (*e.g.*, GradCAM^[27]).

De nombreuses pistes restent à explorer pour améliorer l’approche à base d’images 3D :

- Une première piste serait d’utiliser des techniques de *data augmentation* afin d’augmenter artificiellement le *training set*. Nous envisageons plusieurs techniques d’augmentation (voir Figure 11) :
- Une seconde piste serait d’utiliser les différentes séquences scanner en même temps dans l’entraînement des réseaux. Une manière consisterait à combiner les prédictions issues de 3 modèles en les moyennant ou en entraînant un modèle simple dessus. Des méthodes plus complexes peuvent également être envisagées, comme entraîner un plus gros réseau avec plusieurs entrées, ou plusieurs canaux d’entrées, afin de permettre au modèle d’extraire de l’information jointe des différentes séquences ;
- Enfin une des pistes les plus prometteuses, de notre point de vue, serait de fusionner les données de $\mathcal{D}_{num}$ et les images scanner de $\mathcal{D}_{img}$ pour entraîner un modèle avec toute l’information à disposition. Les MLP étant assez performants dans les résultats en Section 3.1.2, une première approche sera d’étudier la littérature en fusion de données hétérogènes pour le *deep learning*, ce qui permettra de coupler dans un même modèle des données numériques, catégorielles et d’imagerie scanner.




FIGURE 11 : Techniques de *data augmentation* 3D envisagées : a) Coupe 2D de l’image d’origine ; b) Changement de contraste ; c) Bruitage ; d) Déformation élastique ; e) Rotation + Zoom ; f) Échange aléatoire de cubes 3D.

5 Conclusion

Notre travail confirme aujourd’hui la place des outils de l’intelligence artificielle dans la prédiction du risque d’implantation d’un pacemaker dans les suites d’un TAVI. Nous avons tout d’abord prédit à l’aide de modèles de *machine learning*, en nous appuyant à décrire scrupuleusement la méthodologie de la préparation des données et des entraînement, l’IPM en post-TAVI. Le modèle le plus performant obtenu est une régression logistique. Les données scanographiques quantitatives ont été les paramètres les plus utilisés dans les prédictions. Nous avons ensuite initié l’entraînement de réseaux de neurones avec pour objectifs de prédire l’IPM directement à partir des images 3D scanographiques, et les résultats prometteurs ouvrent la voie à de prochains travaux.

Références

- [1] Blase A Carabello. Transcatheter aortic-valve implantation for aortic stenosis in patients who cannot undergo surgery. *Current Cardiology Reports*, 13(3) :173–174, 2011.
- [2] Craig R Smith, Martin B Leon, Michael J Mack, D Craig Miller, Jeffrey W Moses, Lars G Svensson, E Murat Tuzcu, John G Webb, Gregory P Fontana, Raj R Makkar, et al. Transcatheter versus surgical aortic-valve replacement in high-risk patients. *New England Journal of Medicine*, 364(23) :2187–2198, 2011.
- [3] Michael J Reardon, Nicolas M Van Mieghem, Jeffrey J Popma, Neal S Kleiman, Lars Søndergaard, Mubashir Mumtaz, David H Adams, G Michael Deeb, Brijeshwar Maini, Hemal Gada, et al. Surgical or transcatheter aortic-valve replacement in intermediate-risk patients. *New England journal of medicine*, 376(14) :1321–1331, 2017.
- [4] Jeffrey J Popma, G Michael Deeb, Steven J Yakubov, Mubashir Mumtaz, Hemal Gada, Daniel O’Hair, Tanvir Bajwa, John C Heiser, William Merhi, Neal S Kleiman, et al. Transcatheter aortic-valve replacement with a self-expanding valve in low-risk patients. *New England Journal of Medicine*, 380(18) :1706–1715, 2019.
- [5] Michael J Mack, Martin B Leon, Vinod H Thourani, Raj Makkar, Susheel K Kodali, Mark Russo, Samir R Kapadia, S Chris Malaisrie, David J Cohen, Philippe Pibarot, et al. Transcatheter aortic-valve replacement with a balloon-expandable valve in low-risk patients. *New England Journal of Medicine*, 380(18) :1695–1705, 2019.
- [6] Vincent Auffret, Rishi Puri, Marina Urena, Chekrallah Chamandi, Tania Rodriguez-Gabella, François Philippon, and Josep Rodés-Cabau. Conduction disturbances after transcatheter aortic valve replacement : current status and future perspectives. *Circulation*, 136(11) :1049–1069, 2017.

- [7] George CM Siontis, Peter Jüni, Thomas Pilgrim, Stefan Stortecky, Lutz Büllesfeld, Bernhard Meier, Peter Wenaweser, and Stephan Windecker. Predictors of permanent pacemaker implantation in patients with severe aortic stenosis undergoing tavr : a meta-analysis. *Journal of the American College of Cardiology*, 64(2) :129–140, 2014.
- [8] Ashraf Hamdan, Victor Guetta, Robert Klempfner, Eli Konen, Ehud Raanani, Michael Glikson, Orly Goitein, Amit Segev, Israel Barbash, Paul Fefer, et al. Inverse relationship between membranous septal length and the risk of atrioventricular block in patients undergoing transcatheter aortic valve implantation. *JACC : Cardiovascular Interventions*, 8(9) :1218–1228, 2015.
- [9] George Latsios, Ulrich Gerckens, Lutz Buellesfeld, Ralf Mueller, Daniel John, Seyrani Yuecel, Joerg Syring, Barthel Sauren, and Eberhard Grube. “device landing zone” calcification, assessed by msct, as a predictive factor for pacemaker implantation after tavi. *Catheterization and cardiovascular interventions*, 76(3) :431–439, 2010.
- [10] Yasser Sammour, Kinjal Banerjee, Arnav Kumar, Hassan Lak, Sanchit Chawla, Cameron Incognito, Jay Patel, Manpreet Kaur, Omar Abdelfattah, Lars G Svensson, et al. Systematic approach to high implantation of sapien-3 valve achieves a lower rate of conduction abnormalities including pacemaker implantation. *Circulation : Cardiovascular Interventions*, 14(1) :e009407, 2021.
- [11] Gilbert HL Tang, Syed Zaid, Iassen Michev, Hasan Ahmad, Ryan Kaple, Cenap Undemir, Martin Cohen, and Steven L Lansman. “cusp-overlap” view simplifies fluoroscopy-guided implantation of self-expanding valve in transcatheter aortic valve replacement. *JACC : Cardiovascular Interventions*, 11(16) :1663–1665, 2018.
- [12] Dagmar F Hernandez-Suarez, Yeunjung Kim, Pedro Villablanca, Tanush Gupta, Jose Wiley, Brenda G Nieves-Rodriguez, Jovaniel Rodriguez-Maldonado, Roberto Feliu Maldonado, Istoni da Luz Sant’Ana, Cristina Sanina, et al. Machine learning prediction models for in-hospital mortality after transcatheter aortic valve replacement. *Cardiovascular Interventions*, 12(14) :1328–1338, 2019.
- [13] Vien T Truong, Daniel Beyerbach, Wojciech Mazur, Matthew Wigle, Emma Bateman, Akhil Pallerla, Tam NM Ngo, Satya Shreenivas, Justin T Tretter, Cassady Palmer, et al. Machine learning method for predicting pacemaker implantation following transcatheter aortic valve replacement. *Pacing and Clinical Electrophysiology*, 44(2) :334–340, 2021.
- [14] Takahiro Tsushima, Sadeer Al-Kindi, Fahd Nadeem, Guilherme F Attizzani, Yakov Elgudin, Alan Markowitz, Marco A Costa, Daniel I Simon, Mauricio S Arruda, Judith A Mackall, et al. Machine learning algorithms for prediction of permanent pacemaker implantation after transcatheter aortic valve replacement. *Circulation : Arrhythmia and Electrophysiology*, 14(3) :e008941, 2021.

- [15] Amitabh C Pandey, Arjun Nichani, Megan Pelter, Daniel Ng, Ashley Jaravata, Zabrina Duncan, Siddharth Suresh, Sandeep Mehta, Curtiss Stinis, Sanjeev Bhavnani, et al. Machine learning for prediction of pacemaker after tavr in patients with low stroke volume index. *Journal of the American College of Cardiology*, 77(18_Supplement_1) :1182–1182, 2021.
- [16] Philipp Blanke, Jonathan R Weir-McCall, Stephan Achenbach, Victoria Delgado, Jörg Hausleiter, Hasan Jilaihawi, Mohamed Marwan, Bjarne L Nørgaard, Niccolo Piazza, Paul Schoenhagen, et al. Computed tomography imaging in the context of transcatheter aortic valve implantation (tavi)/transcatheter aortic valve replacement (tavr) an expert consensus document of the society of cardiovascular computed tomography. *JACC : Cardiovascular Imaging*, 12(1) :1–24, 2019.
- [17] Michael Glikson, Jens Cosedis Nielsen, Mads Brix Kronborg, Yoav Michowitz, Angelo Auricchio, Israel Moshe Barbash, José A Barrabés, Giuseppe Boriani, Frieder Braunschweig, Michele Brignole, et al. 2021 esc guidelines on cardiac pacing and cardiac resynchronization therapy : Developed by the task force on cardiac pacing and cardiac resynchronization therapy of the european society of cardiology (esc) with the special contribution of the european heart rhythm association (ehra). *EP Europace*, 24(1) :71–164, 2022.
- [18] Nitesh V Chawla, Kevin W Bowyer, Lawrence O Hall, and W Philip Kegelmeyer. Smote : synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16 :321–357, 2002.
- [19] Trevor Park and George Casella. The bayesian lasso. *Journal of the American Statistical Association*, 103(482) :681–686, 2008.
- [20] Miron B Kursu and Witold R Rudnicki. Feature selection with the boruta package. *Journal of statistical software*, 36 :1–13, 2010.
- [21] Shay Cohen, Eytan Ruppín, and Gideon Dror. Feature selection based on the shapley value. In *Proceedings of the 19th international joint conference on Artificial intelligence*, pages 665–670, 2005.
- [22] Zhi-Hua Zhou. *Machine learning*. Springer Nature, 2021.
- [23] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [24] <https://www.kaggle.com/datasets/polomarco/chest-ct-segmentation>.
- [25] 2020 Kónya et al. Lung segmentation dataset, <https://www.kaggle.com/sandorkonya/ct-lung-heart-trachea-segmentation>.

- [26] Soroosh Kiani, Norihiko Kamioka, George B Black, Marvin Louis Roy Lu, John C Lisko, Birju Rao, Andenet Mengistu, Patrick T Gleason, James P Stewart, Hope Caughron, et al. Development of a risk score to predict new pacemaker implantation after transcatheter aortic valve replacement. *JACC : Cardiovascular Interventions*, 12(21) :2133–2142, 2019.
- [27] Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam : Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE international conference on computer vision*, pages 618–626, 2017.
- [28] Tomokazu Kawashima and Fumi Sato. Visualizing anatomical evidences on atrioventricular conduction system for tavi. *International journal of cardiology*, 174(1) :1–6, 2014.

Annexe A Détails sur les métriques utilisées

A.1 Précision, Rappel, Score F1

La précision et le rappel se concentrent sur la performance du modèle concernant les individus positifs. La précision correspond au taux de prédictions correctes parmi les prédictions positives. Elle mesure donc la capacité du modèle à ne pas faire d'erreur lors d'une prédiction positive. Le *rappel* (ou sensibilité) correspond au taux d'individus positifs détectés par le modèle. Il mesure la capacité du modèle à détecter l'ensemble des individus positifs.

Le score F1 est une métrique de classification qui mesure la capacité d'un modèle à bien prédire les individus positifs, tant en termes de précision (taux de prédictions positives correctes) qu'en termes de rappel (taux de positifs correctement prédits). Il correspond en effet à la moyenne harmonique de ces indicateurs.

A.2 Accuracy

Cette métrique de performance évalue la capacité d'un modèle de classification à bien prédire à la fois les individus positifs et les individus négatifs. Elle mesure le taux de prédictions correctes sur l'ensemble des prédictions.

L'*accuracy* a en commun avec le score F1 de résumer la performance d'un modèle en un seul indicateur pour chaque seuil de classification. Le score F1 est plus complexe mais a l'avantage d'être plus robuste en présence de données déséquilibrées.

A.3 Matrice de confusion

La matrice de confusion ([Table 9](#)) est le socle des différentes métriques de classification utilisées en ML. Elle consiste en un tableau à 4 valeurs représentant les différentes combinaisons de valeurs réelles et valeurs prédites (Vrai Positif, Faux Positif, Vrai Négatif, Faux Négatif).

		Classe prédite	
		Positive	Négative
Classe réelle	Positive	Vrai Positif (VP)	Faux Négatif (FN)
	Négative	Faux Positif (FP)	Vrai Négatif (VN)

Mesure	Formule
Accuracy	$(VP+VN)/(VP+FP+FP+VN)$
Précision	$TP/(TP+FP)$
Rappel	$TP/(TP+FN)$
Score F1	$2*Précision*Rappel/(Précision+Rappel)$


TABLE 9 : Matrice de confusion

A.4 Courbe ROC, AUC-ROC, AUC-PR


La courbe *Receiver operating characteristic* (ROC) est une représentation graphique de la relation existante entre la sensibilité et la spécificité (1-spécificité) d'un test pour tous les seuils possibles. Cette courbe permet de calculer la métrique de l'aire sous la courbe ROC (AUC-ROC), consistant à sommer les surfaces des trapèzes verticaux reliant deux points successifs.

Similairement, la métrique AUC-PR consiste à calculer l'aire sous la courbe *Précision-Rappel*. C'est une métrique de performance adaptée à la classification quand les données sont déséquilibrées.


Annexe B Paramètres influençant la qualité de l'imagerie



(a) Nombre de coupes (*slices*) par acquisition (axe *z*).



(b) Distance entre le centre de deux pixels adjacents (*pixel spacing*, axes *x* et *y*).



(c) Épaisseur des coupes (*slice thickness*, axe *z*).

FIGURE 12 : Nombres de scanners réalisés en fonctions des paramètres influençant sur la qualité de l'imagerie. Pour chaque patient sont réalisées : une séquence non injectée (=calcique), et deux séquences injectées en systole et en diastole.

Annexe C Caractéristiques de la population

Variables	Tous (n = 521)	Pacemaker (n = 98)	Pas de Pacemaker (n = 423)	p-value	Corrélation r Pearson
Démographique					
Age	83.12 ± 5.4	83.5 ± 5.80	83.3 ± 5.4	0.272	0.035
sexe (féminin)	48 % (252)	35.71 % (35)	51.3 % (217)	0.045	-0.122
imc (kg/m²)	26.4 ± 4.7	26.7 ± 5.34	26.4 ± 4.5	0.951	0.023
taille (cm)	164.14 ± 8.6	166.0 ± 9.6	163.7 ± 8.38	0.013	0.103
Antécédent					
Bioprothèse aortique chirurgicale	4.41% (23)	0 % (0)	5.44 % (23)	0.02	-0.104
pontage coronarien	6.53% (34)	7.14% (7)	6.38% (27)	0.79	0.012
angioplastie coronaire	19% (100)	19.39 % (19)	19.15% (81)	0.961	0.002
sca<100 jours	1.34% (7)	1.02 % (1)	1.42% (6)	0.759	-0.014
bpco gold ≥ 2	5.18% (27)	6.12% (6)	4.96% (21)	0.65	0.02
aomi	8.64% (45)	8.16% (8)	8.75% (37)	0.859	-0.008
accident vasculaire cérébral	7.29 % (38)	11.22% (11)	6.38% (27)	0.109	0.073
diabète sans insuline	13.83% (72)	12.24% (12)	14.18% (60)	0.641	-0.022
diabète avec insuline	3.84% (20)	4.08% (4)	3.78% (16)	0.891	0.006
créatinine pré-TAVI (umol/l)	90.21 ± 41.91	103.31 ± 71.72	87.18 ± 30.32	0.023	0.151
clairance rénale (CK)	60.65 ± 24.34	58.36 ± 24.85	61.19 ± 24.16	0.306	-0.045
insuffisance rénale chronique 3	51.82 % (270)	50.0 % (49)	52.25 % (221)	0.780	-0.018
insuffisance rénale chronique 4	4.8 % (25)	5.1 % (5)	4.73 % (20)	0.878	0.007
insuffisance rénale chronique 5	0.58 % (3)	3.06 % (3)	0.0 % (0)	3x10-4	0.158
anticoagulation pré-TAVI	27.45 % (143)	32.65% (32)	26.24% (111)	0.27	0.056
euroscore logistique	9.54 ± 7.78	9.27 ± 7.5	9.61 ± 7.8	0.809	-0.017
Clinique					
dyspnée	94% (493)	94.9% (93)	94.56% (400)	0.975	0.006
NYHA II	37.6% (197)	42.86% (42)	36.6% (155)	0.26	0.062
NYHAIII	60.2% (314)	56.12% (55)	61.23% (259)	0.557	-0.041
NYHAIV	1.92% (10)	1.02% (1)	2.13% (9)	0.475	-0.032
≥ 2OAP < 2ans	3.45% (18)	2.04% (2)	3.78% (16)	0.403	-0.037
angor classe 4 (CCS)	0.38% (2)	0% (0)	0.47% (2)	0.496	-0.03
Electrocardiographique (ECG)					
trouble du rythme pré-TAVI	21.5% (112)	20.41% (20)	21.75% (92)	0.796	-0.013
BBD pre tavi	10.36% (54)	24.49% (24)	7.09% (30)	1x10-6	0.223
BBG pre tavi	9.6% (50)	9.18% (9)	9.69% (41)	0.883	-0.007
PR pré TAVI (ms)	186.43 ± 38.82	205.95 ± 48.35	181.73 ± 34.48	3x10-5	0.247
QRS pré TAVI (ms)	104.81 ± 22.41	114.12 ± 24.8	102.66 ± 21.22	9x10-6	0.2
Echographique (ETT)					
gradient moyen pre TAVI (mmhg)	51.28 ± 20.78	51.34 ± 9.75	51.27 ± 22.54	0.274	0.001
surface valvulaire préTAVI (cm²)	0.714 ± 0.23	0.73 ± 0.187	0.71 ± 0.242	0.127	0.033
FEVG (%)	56 ± 9.471	55.58 ± 8.83	56.10 ± 9.59	0.287	-0.021
valeur paps (mmhg)	40.84 ± 13.67	39.51 ± 14.55	41.15 ± 13.42	0.112	-0.047
fuite aortique grade 1	34.74% (181)	39.8 % (39)	33.57% (142)	0.346	0.051
fuite aortique grade 2	7.49% (39)	7.14 % (7)	7.57 % (32)	0.89	-0.006
fuite aortique grade 3	1.34% (7)	2.04 % (2)	1.18 % (5)	0.508	0.029
fuite aortique grade 4	1.54% (8)	0.0 % (0)	1.89 % (8)	0.173	-0.06
fuite mitrale grade 1	28.02 % (146)	22.45% (22)	29.31% (124)	0.247	-0.06
fuite mitrale grade 2	8.64% (45)	6.12% (6)	9.22% (39)	0.347	-0.043
fuite mitrale grade 3	0.96% (5)	1.02% (1)	0.95% (4)	0.945	0.003
fuite mitrale grade 4	0.58% (3)	0.0% (0)	0.71% (3)	0.404	-0.037
Scannographique (TDM)					
diametre de l'anneau aortique (mm)	23.08 ± 2.36	23.77 ± 2.11	22.92 ± 2.38	1x10-3	0.142
petit diametre de l'anneau (mm)	21.16 ± 2.25	21.53 ± 2.24	21.06 ± 2.23	0.04	0.083
grand diametre de l'anneau (mm)	26.05 ± 2.67	26.80 ± 2.59	25.86 ± 2.66	2x10-6	0.139
surface diastole (mm²)	479.99 ± 88.65	504.79 ± 89.25	474.11 ± 87.35	4x10-4	0.136
surface systole (mm²)	482.45 ± 84.41	507.47 ± 88.72	476.31 ± 82.05	2x10-4	0.147
score calcique	3790.65 ± 2019	4530.65 ± 2531	3608.43 ± 1823	5x10-4	0.182
longueur du septum membraneux	8.51 ± 2.44	6.33 ± 2.14	9.02 ± 2.06	7x10-16	-0.422
calcification tiers supérieur aorte thoracique	6.33% (33)	6.12% (6)	6.38% (27)	0.926	-0.004
Données per-procédure					
localisation procédure, bloc opératoire	6.72% (35)	8.16% (8)	6.38% (27)	0.54	0.028
localisation procédure, cardiologie interventionnelle	88.68% (462)	85.71% (84)	89.36% (378)	0.729	-0.045
localisation procédure, salle hybride	4.61% (24)	6.12% (6)	4.26% (18)	0.437	0.035
abord ilio-fémoral	93.09% (485)	91.84% (90)	93.38% (395)	0.886	-0.024
abord carotidien	5.37% (28)	7.14% (7)	4.96% (21)	0.401	0.038
abord trans-aortique	0.96% (5)	1.02% (1)	0.95% (4)	0.945	0.003
abord trans-apical	0.58 % (3)	0.0 % (0)	0.71% (3)	0.404	-0.037
prédilatation	33.59% (175)	30.61% (30)	34.28% (145)	0.572	-0.03
postdilatation	6.14% (32)	5.1% (5)	6.38% (27)	0.644	-0.021
Type valve implantée					
Acurate	8.64% (45)	2.04% (2)	10.17% (43)	0.013	-0.113
Corevalve	35.89% (187)	40.82% (40)	34.75% (147)	0.366	0.049
Portico	1.15% (6)	1.02% (1)	1.18% (5)	0.893	-0.006
Sapiens 3	53.74% (280)	54.08% (53)	53.66% (227)	0.959	0.003

diametre valve	26.7 ± 2.73	27.58 ± 2.94	26.50 ± 2.64	5x10-4	0.153
Données post-procédure					
Δ PR (ms)	-3 ± 25	-21 ± 43	-1 ± 19	2x10-3	-0.272
Δ QRS (ms)	2 ± 17	-3 ± 23	3 ± 16	2x10-2	-0.145

TABLE 10 : Caractéristique de la population. Les variables continues sont données sous forme d'une moyenne ± écart type. Les variables catégorielles sous forme de % et (valeur absolue).

Annexe D Préparation des données pour l'apprentissage

Rééchantonnage	Valeurs aberrantes	Normalisation	Données manquantes	AUC-ROC	Score F1	Accuracy
ROS	Oui	Standard	Moyenne	76.6±0.8	57.2	80.2
ROS	Oui	Standard	Médiane	77.5±0.7	58.5	80.7
ROS	Oui	Standard	Mode	76.3±0.8	57.3	80.4
ROS	Oui	Standard	kNN	75.5±0.8	56.1	79.5
ROS	Oui	MinMax	Moyenne	77.2±0.8	58.4	80.9
ROS	Oui	MinMax	Médiane	75.2±0.7	55.9	80.0
ROS	Oui	MinMax	Mode	75.9±0.7	56.8	80.5
ROS	Oui	MinMax	kNN	74.9±0.8	55.0	79.5
ROS	Oui	-	Moyenne	72.2±0.7	50.9	75.9
ROS	Oui	-	Médiane	72.4±0.7	51.0	75.5
ROS	Oui	-	Mode	74.5±0.9	53.7	77.7
ROS	Oui	-	kNN	74.6±0.7	53.7	76.9
ROS	-	Standard	Moyenne	77.9±0.8	60.1	82.3
ROS	-	Standard	Médiane	76.2±0.8	56.8	80.2
ROS	-	Standard	Mode	76.3±0.6	57.1	80.1
ROS	-	Standard	kNN	76.2±0.9	57.3	80.0
ROS	-	MinMax	Moyenne	74.7±0.7	54.9	79.2
ROS	-	MinMax	Médiane	75.7±0.6	56.5	80.0
ROS	-	MinMax	Mode	75.4±0.7	56.1	79.9
ROS	-	MinMax	kNN	74.70.71	55.2	79.7
ROS	-	-	Moyenne	73.0±0.8	51.5	75.6
ROS	-	-	Médiane	71.9±0.8	50.5	75.0
ROS	-	-	Mode	72.4±0.9	50.6	75.2
ROS	-	-	kNN	72.9±0.7	51.6	76.0
SMOTE	Oui	Standard	Moyenne	77.4±0.7	58.9	81.0
SMOTE	Oui	Standard	Médiane	77.7±0.6	59.9	81.8
SMOTE	Oui	Standard	Mode	76.9±0.6	58.3	80.9
SMOTE	Oui	Standard	kNN	76.3±0.8	56.8	80.4
SMOTE	Oui	MinMax	Moyenne	76.3±0.7	57.2	80.6
SMOTE	Oui	MinMax	Médiane	74.9±0.3	55.7	80.2
SMOTE	Oui	MinMax	Mode	75.1±0.7	55.8	80.1
SMOTE	Oui	MinMax	kNN	75.8±0.7	57.0	80.4
SMOTE	Oui	-	Moyenne	72.5±0.9	51.1	75.3
SMOTE	Oui	-	Médiane	73.1±0.7	52.0	76.0
SMOTE	Oui	-	Mode	72.6±0.8	51.5	76.0
SMOTE	Oui	-	kNN	73.9±0.9	53.2	77.2
SMOTE	-	Standard	Moyenne	77.2±0.7	58.5	81.1
SMOTE	-	Standard	Médiane	76.7±0.6	58.3	81.3
SMOTE	-	Standard	Mode	76.4±0.9	57.3	80.9
SMOTE	-	Standard	kNN	74.8±0.7	55.5	79.6
SMOTE	-	MinMax	Moyenne	75.0±0.7	55.7	80.2
SMOTE	-	MinMax	Médiane	75.5±0.7	56.3	80.5
SMOTE	-	MinMax	Mode	75.2±0.8	56.8	80.6
SMOTE	-	MinMax	kNN	74.7±0.7	55.3	80.1
SMOTE	-	-	Moyenne	70.9±0.9	49.6	74.9
SMOTE	-	-	Médiane	73.7±0.7	52.4	75.7
SMOTE	-	-	Mode	72.60.92	51.5	76.2
SMOTE	-	-	kNN	73.9±0.7	52.9	76.7
-	Oui	Standard	Moyenne	71.6±0.8	54.9	85.6
-	Oui	Standard	Médiane	72.7±0.8	55.8	85.1
-	Oui	Standard	Mode	71.4±0.8	53.5	84.1
-	Oui	Standard	kNN	72.2±0.7	56.3	85.8
-	Oui	MinMax	Moyenne	72.7±0.7	53.5	81.9
-	Oui	MinMax	Médiane	71.9±1.1	51.2	82.4

-	Oui	MinMax	Mode	73.7±0.8	54.0	81.7
-	Oui	MinMax	kNN	72.9±1.0	53.1	82.0
-	Oui	-	Moyenne	68.0±0.8	47.0	81.3
-	Oui	-	Médiane	67.5±0.7	47.4	83.0
-	Oui	-	Mode	67.8±0.8	47.5	83.0
-	Oui	-	kNN	68.5±0.9	47.5	81.0
-	-	Standard	Moyenne	72.1±0.8	55.9	85.0
-	-	Standard	Médiane	73.0±0.8	56.1	85.4
-	-	Standard	Mode	73.8±0.8	57.4	85.6
-	-	Standard	kNN	71.5±0.6	55.3	85.1
-	-	MinMax	Moyenne	72.0±0.9	51.0	82.0
-	-	MinMax	Médiane	72.0±0.9	52.1	81.6
-	-	MinMax	Mode	71.7±1.1	49.6	80.7
-	-	MinMax	kNN	70.8±0.9	49.8	81.4
-	-	-	Moyenne	67.6±0.8	47.8	83.0
-	-	-	Médiane	67.9±0.9	47.3	82.5
-	-	-	Mode	67.2±0.7	46.8	82.6
-	-	-	kNN	67.8±0.7	48.3	82.1

TABLE 11 : Ensemble des configurations possibles de traitements sur les données. Dans cette table, un "-" dénote l'absence du traitement correspondant. Table réalisée à partir d'un modèle de régression logistique, des données pré-TAVI et sans sélection de variable.

Annexe E Utilisation des variables per-pré-post TAVI

	SVM					RL					RF					MLP					XGBoost					Somme							
	●	●+	●	●+	●	●	●+	●	●+	●	●	●+	●	●+	●	●	●+	●	●	●+	●	●	●+	●	●	●+	●	●	●+	Total			
age	×	×						×	×				×																	4	11/15		
anticoagulant_pretavi_Oui																														4	2/15		
Bloc_branche_pre_tavi_bbd		×			×																								1	2	3	6/15	
Bloc_branche_pre_tavi_bbg																													1	0	0	1/15	
bioprothese_aortique_Oui																													1	0	0	1/15	
creatinine_lors_inclusion																													1	0	0	1/15	
diametre_anneau																													1	0	0	1/15	
euroscore_logistique	×	×	×	×	×			×	×			×																	3	4	5	12/15	
fuite_mitrale_pretavi_Grade I																													1	1	0	2/15	
gradient_moyen_pre_tavi																													×	1	0	1	2/15
grand_diametre_anneau																													1	0	1	2/15	
hauteur_septum_membraneux	×	×	×	×	×			×	×			×																	5	5	15/15		
imc																													1	0	1	2/15	
petit_diametre_anneau	×	×	×	×	×			×	×			×																	3	5	4	12/15	
predilatation_Non																													1	1	1	3/15	
pr_pre_tavi	×	×	×	×	×			×	×			×																	3	5	4	12/15	
qrs_pre_tavi	×				×																								3	0	2	5/15	
score_calcique												×																	3	1	2	6/15	
sexe_Femme																													1	1	0	2/15	
surface_diastole																													1	1	2	4/15	
surface_systole	×	×	×	×	×			×	×			×	×	×	×	×	×	×	×	×	×	×	×	×	×	×	×	5	5	15/15			
taille	×	×	×	×	×			×	×			×	×	×	×	×	×	×	×	×	×	×	×	×	×	×	×	3	3	4	10/15		
valeur_paps'																													1	1	2	4/15	
diametre_valve_un		×																											2	1	3/10		
ratio_hauteur_valve																														3	2	5/10	
type_valve_un_Acurate		×	×		×				×			×	×	×	×	×	×	×	×	×	×	×	×	×	×	×	×			4	3	7/10	
type_valve_un_Corevalve																													1	0	1/10		
delta_pr_j1																																5	5/5
delta_qrs_j1		×	×																													5	5/5

TABLE 12 : Utilisation des variables par les modèles selon la quantité de variables disponibles. En noir les variables pré-TAVI, en bleu les variables per-TAVI et en vert les variables post-TAVI. Chacun des 5 modèles a donc été entraîné 3 fois. Si une variables est sélectionnée par le modèle, une croix (×) est présente dans la cellule correspondante, sinon la cellule reste vide.

Annexe F Variabilité histologique du septum membraneux




FIGURE 13 : Variation positionnelle du septum membraneux (SM) en anatomopathologie⁴. (A) SM rectiligne; (B) SM incurvé (acronymes dans l'image — RV : ventricule droit; TV : valve tricuspide; AVB : noeud atrio-ventriculaire; RA : oreillette droite; MS : septum membraneux; LV : ventricule gauche; RC : cusp coronaire droite; VS : septum inter ventriculaire).

⁴Source : Kawashima *et al.* [28]