

Remerciements

*Au président du jury,
À Monsieur le Professeur Jacques Mansourati,*

Vous me faites l'honneur de présider ce jury et je vous en remercie. Apprendre la cardiologie à vos côtés est une réelle chance pour moi. Je suis reconnaissant de vos enseignements, de votre bienveillance et de votre disponibilité malgré vos nombreuses obligations.

*A mon Directeur de thèse,
À Monsieur le Professeur Romain Didier,*

Romain je te remercie de la confiance que tu m'as accordé dans la réalisation de ce travail. Merci de m'avoir enseigné ta vision de l'hémodynamique mais plus globalement du sens clinique. Ton don de simplification est tel que tu peux rendre même les situations les plus complexes compréhensibles et accessibles.

Au Dr Sinda Hannachi,

Sinda, ta sagesse, ton humilité et ton accessibilité t'honorent. Merci pour tes fidèles encouragements et tes riches enseignements durant ces années d'internat. Merci pour tes précieux conseils dans le cadre de ce travail. Merci pour la confiance que tu m'accordes au quotidien.

Au Dr Bastien Pasdeloup,

Bastien, merci de m'avoir permis de découvrir ce magnifique domaine qu'est l'intelligence artificielle en m'ouvrant les portes de ton unité. Merci pour ton encadrement tout au long de ce projet, ainsi que pour tes corrections, tes conseils, ta rigueur et tes remarques pertinentes.

Au Dr Clément Benic,

Clément, tu m'as transmis ta vision de la cardiologie avec bienveillance et réflexion. Ton bon sens et ta rigueur scientifique ont été des atouts précieux pour moi. Tu m'as appris à penser de manière critique, à toujours remettre en question les évidences. Merci pour la confiance que tu m'accordes au quotidien.

A toute l'équipe de BRAIn, je tiens à vous exprimer mes plus sincères remerciements pour l'accueil et l'accompagnement que j'ai reçu durant mon année recherche.

À tous mes chefs et anciens chefs, chacun à votre façon, vous avez contribué à mon épanouissement depuis mon premier jour d'internat : Marie-Claire, Pierre-Philippe, Florent, Valérie, Hugo, Marji, Christopher, Andrei, Pierre, Jean-Baptiste H, Mehdi, Atef, Vincent C., Francois-Côme, Souheib, Christophe, et bien sûr Angèle !

A tous les solides Dr Junior, vous qui n'avez de junior que le nom: Sirine (mon duo !), Vincent M (le khoya !), Ombeline (la classe !), Anaïs (la sista' !), Laura (la maghribia !), Yahia (le doué !) et aux deux « Ex DJ » pour qui l'exploitation n'aura duré qu'un an : Matthias (l'atout charme de la provence !) et Marine (toujours pleine d'énergie!).

A tous mes co-internes, en commençant par ma promo d'adoption : Pierre-Yves, Jean-Baptiste G, Christopher et Fawzi ! A tous les vieux internes : Tony, Erwan, Jean et Julien. Aux immatures de la promo de 2020 : Davy, Flo, Thomas, et Simon! Et enfin à toute la jeunesse : Clément, Maxence et Lisa !

À toute l'équipe paramédicale de l'hémodynamique, dont la bonne humeur et l'attention à mon égard ont contribué à mon choix de la cardiologie interventionnelle dans la suite de mon parcours.

A toutes les IDE, AS, et secrétaires de cardiologie, vous faites preuve de beaucoup de professionnalisme et d'humanité auprès des patients alors que les conditions ne sont pas toujours faciles. . .

A ma famille :

A mon cousin Habib, tu étais un modèle de simplicité et de générosité pour tous. Je te dédie ce travail, en souvenir de ta bonté et de ton amour du prochain.

À ma mère, le ciment de la famille, merci pour ton soutien et ton amour. Tu m'as toujours encouragé à croire en moi, et à ne jamais abandonner. Tu es ma plus grande source d'inspiration.

A mon père, tu es mon plus grand professeur. Je sais que je ne serais pas la personne que je suis aujourd'hui sans ton amour et ton soutien. Je te suis éternellement reconnaissant.

A mon cher frère Yassine, tu es un frère formidable et un ami précieux. Je tiens à te remercier de tout cœur pour ton soutien et ta présence tout au long de ce projet, qui n'aurait jamais eu la même portée sans ta contribution. Je te suis éternellement reconnaissant.

A mon cher frère Zak, merci pour ta joie de vivre et ton humour au quotidien. Ta passion, ta rigueur et ton travail te permettront d'obtenir de belles choses en cette année charnière pour toi, sois assuré de mon soutien indéfectible.

A mes grands-mères, des femmes fortes sans qui aujourd'hui je ne serai pas là.

A mes tantes et oncles, avec une pensée plus émue encore pour : mon oncle Abdelhadi pour tes précieux conseils, ma tante Malika pour avoir cru en moi depuis le début, ma tata Za', mon tonton Momo et au Dr des poissons tonton H!

A tous mes cousins et cousines, Samy, Nora, Adil, Kamel, Rita, Lina, Nouhaila, Nayela, Sofia et tous les autres. . .

À ma belle-famille Baron : Claire, Dominique, Morgane, Pauline, Titouan, Hugo, Michel, Marie-Claude, Sterenn et Raphaël merci de m'avoir accueilli dans votre famille avec tant de gentillesse, de bienveillance et d'amour.

A mes amis d'enfance, Sami toi qui m'a transmis la passion des nouvelles technologies, Ali modèle de vertus, Guillaume avec qui on a vécu tellement de bons moments depuis ce premier jour d'été 2001 à la piscine Kerhallet. Sam ce jour est aussi très particulier pour toi car tu soutiens ta thèse au même moment que moi, force et honneur !

A mes potos Carabins, Benoit «le meilleur d'entre nous !» Gaëtan le patron ! Romain le philosophe! Adé la plus stylée ! Milena ma complice ! et Louise toujours pleine de surprises ! A tous les Cotos, cette belle bande de fous !

A mes amis du lycée, Lisa, Ismail et Betty, bien que difficiles à réunir, notre amitié est restée constante à travers les années !

A Coline, merci pour ton amour au quotidien, pour ton soutien à toute épreuve, pour ta tendresse et pour tout le reste. Merci pour le bonheur que je vis à tes côtés.

Liste des symboles

k NN	k Nearest Neighbors
AUC-ROC	Area Under the ROC Curve
AVC	Accident Vasculaire Valve Cérébral
BAV1	Bloc Atrio-Ventriculaire de type 1
BAVc	Bloc Atrio-Ventriculaire complet
BBD	Bloc de Branche Droit
BBG	Bloc de Branche Gauche
CNN	Convolutional N eural N etwork
DICOM	D igital I maging and C ommunications in M edicine
DL	D eep L earning
ECG	Électro C ardio G ramme
ETT	Échocardiographie T rans- T horacique
IPM	Implantation d'un P ace M aker
LASSO	L east A bsolute S hrinkage and S election O perator
LR	L ogistic R egression
LWL	L ocally W eighted L earning
ML	M achine L earning
MLP	M ulti L ayer P erceptron
MS	S eptum M embraneux
RAC	R étrécissement A ortique C alcifié
RF	R andom F orest
RFE	R ecursive F eature E limination
ROC	R eciever O perating C haracteristic
ROS	R andom O ver- S ampling
SHAP	S Hapley A dditive e x P lanations
SMOTE	S ynthetic M inority O versampling T Echnique
SVM	S upport V ector M achine
TAVI	T ranscatheter A ortic V alve I plantation
TDM	T omo D ensito M étrie à rayon X
THG	T rouble de H aut G rade
XGBoost	e Xtreme G radient B oosting

Table des matières

1	Introduction	1
1.1	Le rétrécissement valvulaire aortique calcifié	1
1.1.1	Physiopathologie	1
1.1.2	Épidémiologie	1
1.2	Le TAVI	2
1.2.1	La place du TAVI	2
1.2.2	Les troubles conductifs de haut grade	2
1.3	Apprentissage automatique	3
1.4	Apprentissage automatique et TAVI dans la littérature	5
1.5	Objectifs de notre travail	6
1.6	Organisation de la suite du rapport	6
2	Matériels et méthodes	7
2.1	Population de l'étude	7
2.2	Cible de la prédiction	7
2.3	Composition des jeux de données	9
2.4	Protocole scanner	9
2.5	Analyse statistique	10
2.6	Apprentissage automatique sur les données numériques et catégorielles.	11
2.6.1	Feature engineering	11
2.6.2	Réduction du nombre de variables	13
2.6.3	Modèles utilisés	14
2.6.4	Validation croisée imbriquée	14
2.6.5	Mise en place de la meilleure chaîne de traitement des données	16
2.6.6	Construction du modèle final	17
2.7	Apprentissage profond à partir des images scanner	17
2.7.1	Format des images	17
2.7.2	Les convolutions, base de l'architecture de DL "ResNet"	18
2.7.3	Pré-traitements sur les images DICOM	19
2.7.4	Segmentation	20
2.7.5	Entraînement du modèle	20
3	Résultats	21
3.1	Principaux résultats sur $\mathcal{D}_{num}$	21
3.1.1	Performance des modèles dans la prédiction de l'IPM à 28 jours.	21
3.1.2	Variables utilisées pour générer les prédictions de notre modèle final	21
3.2	Variables complémentaires	22
3.3	Place des données d'imagerie pour prédire l'IPM	23
3.4	Comparaisons aux autres études	23
3.5	Analyses des performances avec la cible "trouble de haut grade"	24

3.6 Performances obtenues sur $\mathcal{D}_{img}$	25
4 Discussion	25
4.1 Forces de notre travail	25
4.1.1 Apprentissage automatique sur $\mathcal{D}_{num}$	25
4.1.2 Apprentissage profond sur $\mathcal{D}_{img}$	27
4.1.3 Résultats complémentaires	28
4.2 Limites	28
4.3 Perspectives	30
5 Conclusion	30
Références	32
Annexe A Détails sur les métriques utilisées	I
A.1 Précision, Rappel, Score F1	I
A.2 Accuracy	I
A.3 Matrice de confusion	I
A.4 Courbe ROC, AUC-ROC, AUC-PR	I
Annexe B Paramètres influençant la qualité de l'imagerie	II
B.1 Références des scanners :	II
B.2 Paramètres d'acquisition des séquences non injectées	III
B.3 Paramètres d'acquisition des séquences injectées	III
Annexe C Caractéristiques de la population	IV
Annexe D Ensemble des méthodes de préparation des données pour l'apprentissage	VIII
D.1 Prise en compte des valeurs extrêmes	VIII
D.2 Prise en compte des données manquantes	VIII
D.3 Normalisation et encodage	VIII
D.4 Prise en compte du caractère déséquilibré de la cible	IX
D.5 Sélection de variables	X
Annexe E Préparation des données pour l'apprentissage	XI
Annexe F Analyse des variables sélectionnées suite aux entraînements sur chaque modalité de variables.	XIII
Annexe G Variabilité histologique du septum membraneux	XIV
Annexe H Découvertes fortuites sur les TDM	XV
Annexe I Analyse à 18 mois des Holter implantables	XVI
Annexe J Prédiction des AVC en post TAVI	XVII

1 Introduction

1.1 Le rétrécissement valvulaire aortique calcifié

1.1.1 Physiopathologie

Le Rétrécissement Valvulaire aortique Calcifié (RAC) a été longtemps considéré comme étant juste un processus "dégénératif", causé par l'usure des feuillets valvulaires ainsi qu'un dépôt passif de calcium avec le temps. Grâce aux données anatomopathologiques et d'imagerie, les mécanismes évoqués sont plutôt multifactoriels impliquant des dépôts de lipoprotéines, une inflammation chronique, et des transformation ostéoblastique des cellules interstitielles au sein des feuillets valvulaires entraînant une calcification active des feuillets^[1] (Figure 1). Cet ensemble de modifications va entraîner une réduction de la surface de l'orifice aortique représentant un obstacle à l'éjection systolique du ventricule gauche. La surface normale de l'orifice aortique chez l'adulte est de 3 à 4 cm². Un rétrécissement aortique est considéré serré lorsque la surface valvulaire aortique est inférieure à 1 cm² ou 0,6 cm/m²^[2].




FIGURE 1 : Aspect macroscopique et histologique d'une valve aortique normale ((a) et (c)) et anormale ((b) et (d))¹.

1.1.2 Épidémiologie

Le RAC est la valvulopathie la plus fréquente en Europe et en Amérique du Nord. Les formes rhumatismales étant devenue très rare dans ces pays, la forme dégénérative prédomine et sa prévalence augmente avec l'âge : rare (0.2%) avant 60 ans, autour de 2% entre 60 et 69 ans, puis 4% entre 70 et 79 ans, et 10% entre 80 et 89 ans^[3]. Selon l'INSEE, le pourcentage de la population concernée ayant plus de 75 ans est passé de 4% en 1950 à 10% en 2010. D'après leurs prévisions, plus de 15% de la population aura plus de 75 ans en 2050, la prévalence du RAC devrait d'augmenter dans les prochaines années.

¹Source : Lindman *et al.*^[1].

Par ailleurs, il s'agit d'une pathologie grave, en particulier après l'apparition des symptômes. Au premier rang on retrouve l'angor, la syncope, et la dyspnée liée à l'insuffisance cardiaque. En l'absence d'intervention, l'espérance de vie des patients ayant un RAC serré est estimée à 2 ans en présence d'angor, 3 ans en cas de syncope et 5 ans si dyspnée^[4]. De par sa fréquence et sa gravité, elle représente donc un véritable enjeu de santé publique.

1.2 Le TAVI

1.2.1 La place du TAVI

L'implantation d'une valve aortique par voie percutanée (TAVI – *transcatheter aortic valve implantation*) est une technique développée par le Pr. Alain Cribier en 2001. Cette technique consiste à implanter une valve aortique biologique par voie percutanée endovasculaire. Elle permet le remplacement de la valve aortique pathologique par une prothèse biologique acheminée par voie endovasculaire, le plus souvent par voie transfémorale. Contrairement à la chirurgie cardiaque, cette intervention ne nécessite pas d'anesthésie générale, ni thoracotomie ou circulation sanguine extra-corporelle (Figure 2).

L'intervention permettant l'implantation d'un TAVI a tout d'abord été validée dans la prise en charge des patients inopérables (et donc récusés de la chirurgie cardiaque)^[5], puis des patients à risque opératoire haut^[6] et intermédiaire^[7] et enfin aux patients à bas risque^{[8][9]}. Cette validation progressive a été rendue possible par l'amélioration des techniques et des systèmes d'implantation, avec pour conséquence une réduction de l'incidence des complications per- et post-opératoires liées au TAVI.




FIGURE 2 : Les deux principaux types de TAVI. Prothèse auto-expansible (a) et expansible par ballonnet (b)².

1.2.2 Les troubles conductifs de haut grade

Parmi les complications du TAVI, la survenue d'un trouble de la conduction électrique de haut grade demeure la plus fréquente, et son incidence ne semble pas diminuer significativement avec le temps^[10]. Il est alors nécessaire d'implanter un pacemaker, ce qui n'est pas sans risque pour les patients. En effet la pose d'un pacemaker expose aux complications propres à la procédure (infection, hémorragie de la loge

²Source : Lindman *et al.* ^[1].

de pacemaker), elle peut également générer, du fait de l'asynchronisme en lien avec la stimulation ventriculaire droite, à une dégradation de la FEVG qui a pour conséquence de nouvelles hospitalisations pour insuffisance cardiaque^[11]. Enfin l'implantation d'un pacemaker peut être responsable d'un allongement de la durée d'hospitalisation.

Des facteurs de risque de survenue de troubles de la conduction en post-TAVI ont été mis en évidence, incluant des données cliniques et électrophysiologiques^[12] comme le sexe masculin, la présence d'un bloc atrio-ventriculaire de type 1 (BAV 1) et la présence d'un bloc de branche droit (BBD).

Grâce aux données d'imagerie tomodensitométrique à rayon X (TDM) et du fait de la proximité entre les voies de conduction électrique du cœur et la région d'implantation du TAVI, des facteurs de risques anatomiques ont également été identifiés. Parmi ces derniers, on distingue tout particulièrement la longueur du septum membraneux (MS), la profondeur d'implantation valvulaire, et le degré de calcification de la valve aortique native.

Hamdan *et al.*^[13] ont montré que la longueur du MS constituerait un critère prédictif de survenue de troubles de la conduction en postulant que plus la distance entre la valve et les voies de conduction est grande, plus faible est le risque. De plus cette longueur du MS est à mettre en relation avec la profondeur d'implantation (ID – *implantation depth*) de la valve (*i.e.*, portion de la valve sous le plan de l'anneau aortique). En effet, il a été montré que plus le chevauchement entre la profondeur d'implantation et la longueur du MS est important, plus il existe un risque de lésion des voies de conduction. (Figure 3). Concernant le degré de calcification, représenté notamment par la mesure scanner du score calcique, Latsios *et al.*^[14] ont montré que plus le score calcique est élevé, plus le risque de troubles de la conduction est important (Figure 4).

En se basant -entre autres- sur ces données anatomiques, les constructeurs de valves ont émis de "nouvelles recommandations de bonnes pratiques" concernant les techniques d'implantation, incluant notamment une implantation plus haute de la valve : la *radiolucent method*^[15] et la *cusplap technique*^[16]. Toutefois, l'implantation trop haute de la valve peut s'accompagner de la survenue d'autres types de complications, comme la migration de la prothèse, un risque d'accident vasculaire cérébral, de fuites peri-prothétiques ou d'une obstruction artérielle coronaire.

La prédiction du risque de survenue d'un trouble conducteur menant à l'implantation d'un pacemaker après une procédure de TAVI demeure donc toujours un challenge d'actualité en cardiologie. En effet, la détection en pré-opératoire des patients à haut risque permettrait de mettre en place des mesures préventives et d'adapter la prise en charge. Notre travail a donc consisté à prédire le risque d'implantation d'un pacemaker dans les suites d'un TAVI. Pour cela, une des pistes de plus en plus utilisées dans le domaine médical est l'utilisation des outils de l'intelligence artificielle.

1.3 Apprentissage automatique

L'apprentissage automatique (ML – *machine learning*) est un sous-domaine de l'intelligence artificielle à l'intersection entre les statistiques, les mathématiques et l'informatique. Les algorithmes de ML construisent des modèles de prédiction à partir d'un jeu de données (*dataset*) d'apprentissage. Pour cela, on divise généralement ce *dataset* en trois sous-ensembles disjoints :




FIGURE 3 : Mesures du septum membraneux et de la profondeur d'implantation valvulaire, respectivement chez un patient n'ayant pas présenté des troubles de la conduction en post-TAVI ((a) et (b)), et chez un patient ayant présenté ces troubles ((c) et (d)). Δ MSID est défini par la différence entre la longueur du MS et la profondeur d'ID.




FIGURE 4 : Mesures du septum membraneux et du score calcique, respectivement chez un patient ayant présenté des troubles de la conduction en post-TAVI (A et B), et chez un patient n'ayant pas présenté ces troubles ((c) et (d)).

- L'ensemble d'entraînement (*training set*), utilisé pour effectuer le processus d'apprentissage du modèle. Il contient des données annotées, que les algorithmes de ML utilisent pour apprendre à prédire l'annotation à partir des données ;
- L'ensemble de validation (*validation set*), qui permet d'évaluer la capacité de généralisation du modèle. Il contient également des données annotées, qui servent à vérifier la performance du modèle quand les annotations sont supposées inconnues ;
- L'ensemble de test (*test set*), qui sert une fois le processus d'entraînement terminé à évaluer les performances du modèle, et donc sa capacité prédictive en conditions réelles.

Le processus d'apprentissage consiste donc à exploiter l'information contenue dans le *training set*, et à retenir le modèle minimisant l'erreur de prédiction sur le *validation set*. Ce modèle est ensuite évalué sur le *test set* pour comparaison avec d'autres modèles. Quand les annotations sont numériques, on parle de tâche de régression. Si celles-ci sont catégorielles, on parle alors de tâche de classification, et on évalue la performance des modèles par le pourcentage de données correctement classifiées (*accuracy*). Dans ce rapport, on considère une tâche de classification binaire, c'est à dire que l'annotation à prédire est un booléen.

L'apprentissage profond (DL – *deep learning*) est un sous-ensemble du ML dont la popularité a explosé ces dernières années, par sa capacité à dépasser en performance les algorithmes à l'état de l'art dans de très nombreux domaines. Ces modèles consistent en l'enchaînement de couches de neurones artificiels paramétrables, permettant d'extraire progressivement de la donnée des attributs abstraits, qui sont ensuite recombinaés pour prédire l'annotation associée. L'organisation interne des couches (et leur type) au sein d'un modèle de DL définit une architecture de réseau de neurones. Une force de ces modèles est leur capacité à exploiter directement des données complexes (*e.g.*, son, image) là où de nombreux algorithmes de ML plus classiques (*e.g.*, forêt aléatoire (RF – *random forest*), régression logistique (LR – *logistic regression*), boosting de gradient (XGBoost – *extreme gradient boosting*), vecteur de support (SVM – *support-vector machine*)) reposent principalement sur des données numériques ou catégorielles.

1.4 Apprentissage automatique et TAVI dans la littérature

Dans le domaine médical, les techniques de ML occupent une place de plus en plus grandissante, notamment dans la classification diagnostique et la prédiction pronostique. Dans le domaine du TAVI, plusieurs études ont montré la supériorité des modèles de ML, tout particulièrement dans la prédiction du pronostic en post-TAVI, par rapport aux scores statistiques habituels^[17].

Concernant la prédiction du risque d'implantation d'un pacemaker (IPM) en post-TAVI, quatre études ont mis en évidence l'intérêt des modèles de ML :

- Gomez *et al.*^[18] : dans cette étude, ayant pour principal objectif de prédire la mortalité intrahospitalière en post-TAVI, les auteurs ont également entraîné leur modèle à prédire l'IPM en post-TAVI. Les auteurs ont ainsi prédit cette cible avec une AUC-ROC ([Annexe A](#)) de 61% et une *accuracy* ([Annexe A](#)) de 70% en utilisant un modèle de SVM ;
- Truong *et al.*^[19] : dans une étude visant à prédire l'IPM post-TAVI, les auteurs ont obtenu une

AUC-ROC de 81%, une *accuracy* de 76%, et un *score F1* ([Annexe A](#)) de 0.49 par un modèle de RF;

- Tsushima *et al.* ^[20] : dans une étude visant à prédire l'IPM post-TAVI, les auteurs ont obtenu une AUC-ROC de 82%, une *accuracy* de 68% et un *score F1* de 61% en utilisant un modèle de LR combiné à un mécanisme d'apprentissage localement pondéré (LWL – *locally weighted learning*);
- Agasthi *et al.* ^[21] : en utilisant un modèle à base de boosting de gradient, les auteurs ont obtenu une AUC-ROC de 65% pour prédire l'IPM post-TAVI.

Les trois premières études ont utilisé des données cliniques, électriques (ECG), échographiques (ETT), et procédurales (type de valve, voie d'abord). La dernière complémente ces données avec six variables TDM afin de prédire l'IPM. Toutefois, il est important de souligner qu'aucun des facteurs de risque anatomique (notamment ni le septum membraneux ni la profondeur d'implantation) n'a été inclus dans l'analyse.

En complément des études citées précédemment, il est à noter que deux nouveaux travaux ^[22,23] ont été réalisés dans un contexte connexe mais pas directement comparable au notre. Les auteurs entraînent des modèles sur des données issues de simulation du stress biomécanique induit par la prothèse et non sur des données réelles. Ces travaux sont prometteurs, mais souffrent des limitations suivantes : d'une part leur applicabilité en pratique clinique quotidienne est difficile à mettre en oeuvre en l'absence d'outils simples et accessible pour le moment, et d'autre part les modèles de ML entraînés avec ces données n'intègrent que peu de données cliniques et ECG. Pour ces raisons, les expériences proposées dans cette thèse sont uniquement comparées aux quatre travaux cités plus haut.

1.5 Objectifs de notre travail

Le **critère primaire** de notre travail est de prédire le **risque d'Implantation d'un PaceMaker** (*i.e.*, **IPM**) dans les suites d'une procédure de TAVI. Nous prédisons l'IPM en utilisant deux méthodes d'intelligence artificielles :

- Nous entraînons des modèles d'apprentissage automatique (ML) à prédire le risque d'implantation d'un pacemaker dans les suites d'un TAVI. Ces modèles sont entraînés sur des données numériques et catégorielles, qui intègrent notamment des mesures anatomiques obtenues à partir de données scanographiques, et ce contrairement aux autres travaux de la littérature ;
- Nous exploitons également un modèle d'apprentissage profond (DL) pour prédire le risque d'IPM directement à partir des imageries scanner.

Le **critère secondaire** de notre étude est de prédire **les troubles de la conduction de haut grade** (*i.e.*, **THG**) dans les suites d'une procédure de TAVI . Pour effectuer cela, le meilleur modèle d'apprentissage automatique développé pour prédire l'IPM est utilisé.

1.6 Organisation de la suite du rapport

La suite de ce rapport est organisée comme suit. En [Section 2](#), nous présentons la méthodologie de ce travail. Dans un premier temps, nous définissons successivement de la [Section 2.1](#) à la [Section 2.5](#) la

population de l'étude, la cible de prédiction, le type de données utilisées, le protocole scanner et l'analyse statistique. Par la suite, en [Section 2.6](#), nous présentons les étapes utilisées pour développer les modèles d'apprentissage automatique, et en [Section 2.7](#) celles utilisées pour développer le modèle d'apprentissage profond sur les données scanner. En [Section 3](#), nous structurons les résultats de notre travail en 6 parties : la [Section 3.1](#) porte sur les principaux résultats du ML. Nous présentons ensuite successivement : les résultats des modèles selon les données considérées en [Section 3.2](#), l'apport des données d'imagerie dans les prédictions de ML en [Section 3.3](#), une comparaison de notre meilleur modèle aux autres études en [Section 3.4](#), l'analyse des performances de notre meilleur modèle à prédire une autre cible (les troubles de la conduction de haut grade) en [Section 3.5](#), et les performances de prédiction de l'IPM grâce à l'apprentissage profond directement à partir des données 3D scanographiques en [Section 3.6](#). La [Section 4](#) décrit les forces, les limites et les perspectives de notre étude.

Dans ce document, les termes techniques du ML sont principalement donnés en anglais, et sont formatés en italique. Une traduction française est donnée dès que possible pour indication, bien que peu utilisée dans la littérature du domaine.

2 Matériels et méthodes

2.1 Population de l'étude

Ce travail est une étude monocentrique rétrospective, incluant les patients implantés d'un TAVI entre janvier 2019 et décembre 2021 au Centre Hospitalier Universitaire (CHU) de Brest, France.

Le protocole de l'étude (n°29BRC22.0127) a été approuvé par le Comité d'Éthique du CHU de Brest et est conduit en respectant les principes de la Déclaration d'Helsinki, ainsi que de la réglementation relative aux recherches rétrospectives sur données en vigueur. Tous les patients ont reçu un formulaire d'information et de non-opposition concernant la collecte et les analyses de leurs données médicales.

Les critères d'exclusion de l'étude étaient : les patients porteurs d'un stimulateur cardiaque (pacemaker ou défibrillateur) avant l'implantation du TAVI (69 patients), l'absence ou la mauvaise qualité des données scanographiques TDM (20 patients) et les patients décédés moins de 24h en post-TAVI (6 patients). Après application des critères d'exclusion, 520 patients ont été inclus dans l'analyse ([Figure 5](#)).

2.2 Cible de la prédiction

Nous avons choisi d'entraîner nos modèles afin de prédire le risque d'IPM dans les 28 jours suivant la procédure de TAVI. En pratique, cette décision est prise après concertation de l'équipe de soins intensifs de cardiologie composée au minimum d'un cardiologue électrophysiologiste (implanteur de pacemaker) et d'un cardiologue hémodynamicien (implanteur de TAVI). La [Table 1](#) détaille les indications de pacemaker de notre étude, ainsi que le nombre d'implantations au sein de notre jeu de données associées à ces causes. Les indications de pacemaker utilisées sont celles de la Société Européenne de Cardiologie^[24].

Toutefois, il n'existe pas actuellement de recommandations claires concernant les indications d'IPM en post-TAVI. En effet, il existe une différence entre le taux de pacemakers effectivement implantés et le




FIGURE 5 : Schéma de sélection des patients inclus dans l'étude.

Indication d'implantation du pacemaker	Nombre PM (98 patients)
BBG de novo + nécessité d'un traitement ralentisseur	1
BBG de novo > 180ms	6
BAV2 mobitz 2	8
BAV2 mobitz 1 de novo + nécessité d'un traitement ralentisseur	6
BAV1 + BBG + nécessité d'un traitement ralentisseur	7
Dysfonction sinusale symptomatique	3
BAV complet	58
Bloc de branche alternant	9

TABLE 1 : Indication d'implantation du pacemaker dans les suites du TAVI (< 28 jours) dans notre population.

taux de pacemakers effectivement utilisés par les patients. On estime que seulement $\frac{1}{3}$ des patients utilisent leur pacemaker dans l'année suivant son implantation^[25]. Dans notre étude, et de manière analogue aux autres études de la littérature, nous avons développé notre modèle afin de prédire l'IPM. L'annotation à prédire à partir des données par les modèles est une variable binaire indiquant si oui ou non un pacemaker a été implanté.

Afin de tenter de s'affranchir du biais lié à l'incertitude sur l'indication d'implantation, nous avons également entraîné nos modèles à prédire une autre cible, à savoir les troubles de la conduction de haut grade (THG), *i.e.*, un bloc atrio-ventriculaire complet (BAVc) persistant, survenue d'un bloc de branche alternant de novo, et la dysfonction sinusale symptomatique. En effet, ce type de troubles étant à risque vital en l'absence de pacemaker, son implantation est indiscutable (Class I ESC clinical guidelines 2021^[24]).

Notre *dataset* contient 98 patients (18.8%) implantés d'un pacemaker, dont 71 patients (13.6%) ont été implantés sur l'indication trouble de haut grade.

2.3 Composition des jeux de données

Comme mentionné en [Section 1.5](#), nous cherchons à répondre à notre question de recherche en effectuant les prédictions via des algorithmes de ML. Parmi ces algorithmes, et contrairement aux autres modèles étudiés, les modèles de DL ont la capacité d’exploiter les données d’imagerie directement, sans nécessiter de calculs de mesures. Nous considérons donc dans ces travaux les deux bases de données suivantes, constituées des mêmes 520 patients :

- Une **base de donnée n°1**, appelée $\mathcal{D}_{num}$, constituée uniquement des données numériques et catégorielles associées aux patients. Nous avons ainsi collecté 44 variables **pré-TAVI** (*i.e.*, acquises avant la procédure) : 20 variables relatives aux antécédents médicaux et données cliniques, 6 variables ECG, 6 variables ETT (réalisée $< 72h$ de l’implantation du TAVI) et 12 variables issues du scanner TDM (voir [Section 2.4](#)). Nous avons également collecté 12 variables **per-TAVI** (*i.e.*, acquises pendant la procédure) et 11 variables **post-TAVI** (5 issues du premier ECG réalisé après la procédure, et 6 à partir de la première ETT réalisée après la procédure). Toutes les mesures scanner ont été faites de manière prospective en aveugle de la cible de prédiction (IPM post-TAVI). Les autres variables ont été extraites rétrospectivement dans les dossiers médicaux des patients. L’ensemble des variables de cette base de données sont consultables en [Annexe C](#) ;
- Une **base de données n°2**, appelée $\mathcal{D}_{img}$, constituée des images 3D issues des examens d’imagerie TDM. Pour chaque patient, nous avons recueilli les images au format DICOM (voir [Section 2.4](#)).

Le nettoyage des données et l’examen de leur qualité ont été effectués par un second opérateur afin de minimiser les erreurs et les données aberrantes qui pourraient pénaliser l’étude.

2.4 Protocole scanner

Conformément aux recommandations^[26], l’évaluation TDM cardiaque (dans le cadre du bilan pré-TAVI) s’effectue en deux parties : une première phase sans injection de produit de contraste iodé, synchronisée à l’ECG selon un mode prospectif permettant notamment le calcul du score calcique valvulaire ; une deuxième phase avec injection synchronisée à l’ECG selon un mode rétrospectif permettant notamment d’effectuer une reconstruction en diastole et en systole ([Figure 6](#)).




FIGURE 6 : Protocole scanner cardiaque : (a) Séquence injectée en systole ; (b) Séquence injectée en diastole ; (c) séquence non injectée.

Les paramètres des acquisitions scanner sont disponibles en [Annexe B](#).

Afin d'intégrer de l'information issue des données TDM dans $\mathcal{D}_{num}$, nous avons inclus :

- Les mesures de l'anneau aortique (structure virtuelle correspondant à l'alignement du point d'attache le plus bas des cusps valvulaires aortiques) : grand diamètre (mm), petit diamètre (mm), surface en diastole (mm^2), surface en systole (mm^2);
- La mesure du score calcique ([Figure 4](#), (b) et (d)), réalisée après détourage manuel de l'ensemble des calcifications valvulaires aortiques. Par la suite, un calcul du score d'Agagston^[27] a été effectué par le logiciel de post-traitement Syngo.via software (Siemens Healthineers, Forchheim, Germany);
- Le degré de calcification de chaque cuspide valvulaire aortique (CNC – Cusp Non-Coronaire, CCG – Cusp Coronaire Gauche, CCD – Cusp Coronaire Droite) évalué visuellement et classé comme nul (0), léger (1), modéré (2), ou sévère (3);
- La présence (0) ou l'absence (1) de calcifications dans la partie supérieure du septum musculaire cardiaque;
- La présence (0) ou l'absence (1) de calcifications au niveau de la chambre de chasse ventriculaire gauche (*i.e.*, coulées calcaires);
- La longueur du MS ([Figure 4](#), (a) et (c)), définie comme la distance entre la partie inférieure de la valve aortique et la partie supérieure du septum musculaire cardiaque. Sa mesure a été effectuée en mode double oblique, sous la cusp-non coronaire ou sous la commissure séparant la cusp-coronaire droite et la non coronaire (selon l'anatomie cardiaque du patient). Afin d'effectuer ces mesures, nous avons utilisé la technique de Hamdan *et al.*^[13]. Nous avons ainsi effectué sa mesure en systole (*sMS*) puis en diastole (*dMS*).

2.5 Analyse statistique

Dans les analyses de cette thèse, les variables continues ont été exprimées en moyenne avec écart-type, et nous les avons comparées en estimant leurs significativités par rapport à la valeur prédite (implantation d'un pacemaker dans les 28 jours après le TAVI). Dans le cas où une variable suit une loi normale, sa significativité a été estimée avec un test de Student, et avec un test de Mann Whitney Wilcoxon dans le cas contraire. La normalité de la distribution des variables a été évaluée au préalable par un test de Kolmogorov-Smirnov. Les variables catégorielles ont été exprimées en nombre absolu et pourcentage, et comparées par un test du Chi^2 . Pour tous les tests, un seuil de p -value ≤ 0.05 a été considéré pour établir la significativité.

L'analyse a été conduite en utilisant le langage de programmation Python 3.8.10 et sa bibliothèque Scipy.stats.

2.6 Apprentissage automatique sur les données numériques et catégorielles.

Dans cette section, nous présentons dans un premier temps en [Section 2.6.1](#) le processus de *feature engineering* utilisé dans notre travail puis la méthodologie introduite pour identifier la meilleure chaîne de traitements pour prédire l'IPM à partir de la **base de données n°1** : $\mathcal{D}_{num}$.

A visée didactique, nous présentons en [Annexe D](#) les principes généraux des méthodes de traitement nécessaires sur les données avant d'entraîner les algorithmes de ML. Une fois ces pré-requis abordés, les modèles utilisés dans notre étude sont décrits en [Section 2.6.3](#), puis le principe de validation croisée imbriquée utilisé pour effectuer l'entraînement des modèles est décrit en [Section 2.6.4](#). Enfin sont exposées successivement de la [Section 2.6.5](#) à la [Section 2.6.6](#) les étapes utilisées pour définir la meilleure chaîne de traitement des données et générer le modèle final de prédiction.

L'ensemble de ces étapes sont résumées dans la [Figure 7](#).

2.6.1 Feature engineering

Le *feature engineering* est un processus de création de nouvelles variables à partir de données initiales pour améliorer la performance des modèles d'apprentissage automatique. En pratique, sur la base des données initiales (66 variables), nous avons créé de nouvelles variables par combinaisons de deux mesures ou plus, afin de générer de nouvelles variables nous paraissant pertinentes pour la prédiction de l'IPM en post-TAVI.

En pratique, nous avons défini un grand nombre d'associations pour arriver à 204 variables. Parmi celles-ci, de nombreuses variables seront éliminées par la procédure d'entraînement de modèles définie plus tard. Toutefois, certaines variables auront un pouvoir prédictif fort. On distingue notamment :

- $\Delta dsMS$: différence entre la mesure de la longueur diastolique du MS et sa mesure systolique ($dMS - sMS$);
- $\Delta sMSID$: différence entre la mesure de la longueur systolique du MS et la profondeur d'implantation de la prothèse (ID) ($sSM - ID$);
- ΔQRS : différence entre la mesure pré-TAVI du QRS et sa mesure post-TAVI (mesurée sur le premier ECG après la procédure);
- ΔPR : différence entre la mesure pré-TAVI du PR et sa mesure post-TAVI (mesurée sur le premier ECG après la procédure);
- *AVA ratio* : ratio entre la mesure ETT pré-TAVI de la surface valvulaire aortique et sa surface en post-TAVI ($AVA - aortic\ valve\ area$);
- *AVA-PNA-pre-ratio* : ratio entre la mesure ETT pré-TAVI de la surface valvulaire aortique et la surface nominale de la prothèse donnée par le constructeur;
- *AVA-PNA-post-ratio* : ratio entre la mesure ETT post-TAVI de la surface valvulaire aortique et la surface nominale de la prothèse donnée par le constructeur.




FIGURE 7 : Schéma de l'ensemble des étapes permettant de déterminer le meilleur modèle et sa meilleure chaîne de traitement pour prédire l'IPM. Notre base de données se compose de 520 patients, avec pour chacun 67 variables de diverses modalités, identifiées par des couleurs distinctes. À l'étape 1 (pre-processing), nous commençons par traiter les données et introduisons de nouvelles variables (Section 2.6.1). Nous obtenons ainsi 204 variables pour chaque patient, parmi lesquelles nous éliminons les moins significatives à l'étape 2 (sélection des caractéristiques "grossière") (Section 2.6.2). Après cette sélection, 46 variables pour chaque patient demeurent. À partir de celles-ci, nous entrons dans l'étape 3 (recherche de la meilleur pipeline : meilleur modèle et sa chaîne de traitement). Dans cette étape, nous définissons de manière exhaustive toutes les chaînes de traitements et modèles possibles (Section 2.6.5), entraînés avec la procédure de validation croisée imbriquée (procédure d'entraînement et d'évaluation des modèles), détaillée dans la Section 2.6.4. Enfin, à l'étape 4 (construction du modèle final), nous prenons la meilleur pipeline de traitement trouvé et procédons à une méthode récursive d'élimination des caractéristiques à l'aide de SHAP pour réduire le nombre de variables (Section 2.6.6). Nous obtenons ainsi une liste finale de 22 variables par patients qui sont les plus corrélées avec l'IPM. Le modèle est ensuite entraîné à nouveau avec ces variables en utilisant la validation croisée imbriquée. La première figure (Résultats, à gauche) détaille les variables restantes, les couleurs correspondant à celles des données d'entrée. Elles sont classées par ordre décroissant d'importance selon la méthode SHAP, et les couleurs des barres indiquent une corrélation positive ou négative avec l'implantation de la PM. La deuxième figure (Résultats, à droite) montre les courbes AUC-ROC obtenues en utilisant la meilleure pipeline, pour toutes les modalités, ainsi que pour chaque modalité prise individuellement.

- *Calcification de la zone d'implantation à risque* : afin de rendre compte du degré de calcification global de la région autour des voies de conduction ([Figure 8](#)), nous avons créé cette variable comme étant la somme du degré de calcification de la CNC (valeur allant de 0 à 3), du degré de calcification de la CCD (valeur allant de 0 à 3) et du degré de calcification de la partie supérieure du septum musculaire (valeur de 0 ou 1). Cette variable est donc une valeur numérique entre 0 et 7 ;




FIGURE 8 : Schéma anatomique des rapports entre les voies de conduction électrique et les structures adjacentes. La zone d'implantation à risque est représentée par un rectangle rouge. La branche gauche du faisceau de his (LBB) émerge entre le septum membraneux (MS) et la zone de jonction des cusps coronaire droite (R) et non coronaire (N)³.

2.6.2 Réduction du nombre de variables

Après avoir généré des variables supplémentaires ([Section 2.6.1](#)), nous avons encodé les variables catégorielles ([Section D.3 en Annexe D](#)). Ces ajouts ont amené à un excès de variables (204) par rapport à notre nombre de patients.

Or, en ML, il est important de réduire le nombre de variables du *dataset* avant d'initier l'entraînement d'un modèle pour principalement deux raisons :

- Amélioration de la précision du modèle : plus il y a de variables dans un *dataset*, plus il est difficile pour un modèle de ML de trouver des relations significatives entre les variables et la variable cible. En réduisant le nombre de variables, on simplifie le problème et on permet au modèle de se concentrer sur les variables les plus importantes ;
- Amélioration de la généralisation du modèle : un modèle qui est trop complexe est susceptible de sur-apprendre (*overfitting*) les données d'entraînement. Cela signifie qu'il sera très précis sur les données d'entraînement, mais qu'il sera moins précis sur des données nouvelles. En réduisant le

³Source : Khawaja *et al.* ^[28]

nombre de variables, on peut aider le modèle à généraliser mieux les données d'entraînement aux données nouvelles.

Pour remédier à cette problématique (excès de variable), nous effectuons une première phase de sélection dite "grossière". Pour ce faire nous avons introduit une variable aléatoire (suivant une distribution normale) et évalué l'importance (pour prédire l'IPM) de chacune des variables du *dataset* par rapport à cette variable aléatoire introduite. Pour évaluer l'importance des variables, deux méthodes ont été combinées : La méthode *Minimum Redundancy Maximum Relevance* (MRMR) utilisant la bibliothèque *mrmr-selection* (0.2.8)^[29] et la méthode *SHaply Additive exPlanations* (SHAP) utilisant la bibliothèque *shap* (0.42.1)^[30].

Cette approche a permis de réduire d'environ 80% le nombre de variables de notre *dataset*. Les variables identifiées par cette méthode (46) ont ensuite été analysées afin de déterminer leur pertinence clinique. Nous avons ensuite considéré cet ensemble de données réduit pour la suite des expériences.

2.6.3 Modèles utilisés

Nous avons évalué plusieurs modèles habituellement utilisés en classification^[31] pour prédire l'IPM post-TAVI :

- *Decision Tree* (DT);
- *Random Forest* (RF);
- *eXtreme Gradient Boosting* (XGBoost);
- *Gradient boosting* (GB);
- *Multilayer Perceptron* (MLP);
- *Support Vector Machine* (SVM);
- *Gaussian Naive Bayes* (NB);
- Régression Logistique (LR – *Logistic Regression*).

Il est à noter que le MLP se base sur des réseaux de neurones et peut être vu comme faisant partie de la sous-famille des modèles d'apprentissage profond.

Pour développer nos modèles, le langage de programmation Python 3.8.10 ainsi que sa bibliothèque *scikit-learn* ont été utilisés.

La performance des modèles ML pour prédire l'IPM post-TAVI a été analysée en se basant l'*accuracy*, le score F1, l'AUC-ROC et enfin l'AUC-PR (voir [Annexe A](#) pour plus de détails).

2.6.4 Validation croisée imbriquée

Dans toutes les expériences suivantes, nous entraînons et évaluons chaque modèle en effectuant 10 fois une validation croisée imbriquée.

Pour rappel, il est classique de diviser le jeu de données en 3 parties : *training set*, *validation set* et *test set* (Section 1.3). L'inconvénient d'un tel découpage statique est que les résultats dépendent d'une organisation des données qui, même si effectuée aléatoirement, peut contenir des biais, et ne permet pas de produire des intervalles de confiance sur les résultats. Une alternative est la validation croisée imbriquée, que nous avons réalisée dans ces travaux (Figure 9). Cette validation consiste en deux parties :

- Un *cross-testing* (Figure 9, gauche) : Le jeu de données est séparé en 10 blocs de taille égale, 9 dédiées à l'entraînement (*training set A*) et 1 au test (*test set*). Pour chaque choix possible du *test set*, on effectue un entraînement d'un modèle, indépendamment des 9 autres entraînements. Cette technique permet d'obtenir une estimation plus réelle des véritables performances d'un modèle sur l'ensemble du jeu de données. Le score reporté pour un modèle est la moyenne des 10 scores obtenus ;
- Pour trouver les paramètres optimaux de nos modèles, nous réalisons, pour chacun des 10 entraînements du *cross-testing*, une *cross-validation*. Pour une configuration d'entraînement donnée, nous divisons le *training set A* en 10 sous-parties, 1 dédiée au *validation set* et 9 au *training set* (*training set B*). On ajuste ainsi les paramètres du modèle en entraînant sur le *training set B* et en optimisant la capacité de prédiction sur le *validation set*. On itère cette procédure pour tout choix du *validation set*. À l'issue de cette étape, on récupère les paramètres optimaux (amenant à la meilleure performance sur le *validation set*), et on effectue un entraînement du modèle sur l'ensemble du *training set A* afin de fournir une prédiction pour le *test set* en cours.

Dans notre étude, nous avons choisi de répéter 10 fois cette technique de validation croisée imbriquée, afin de réduire la variance de nos résultats. Le résultat final est donc une moyenne de ces 10 * 10 entraînements. La validation croisée imbriquée nous permet donc de :

- Limiter l'*overfitting*, qui est un phénomène qui se produit lorsque les modèles sur-apprennent les données d'entraînement, ce qui conduit à d'excellentes performances sur le *training set* mais à de mauvais résultats sur de nouvelles données ;
- Maximiser l'apprentissage, en faisant en sorte d'utiliser l'intégralité de notre jeu de données pour l'entraînement, la validation et le test (très utile si effectif de petite taille) ;
- Estimer la variance de nos modèles. En effet, la variance peut provenir de plusieurs endroits, que ce soit dans la nature même de nos modèles ou alors dans le découpage du *dataset*. Ainsi, plus le *dataset* est petit, plus la variance est problématique. Cette technique nous permet de calculer un écart-type et fournir des intervalles de confiance à 95%.

Enfin, nous aimerions insister sur le fait que cette technique permet, via le *validation set*, de simuler l'existence d'une cohorte externe. Les modèles entraînés ont pour vocation à généraliser autant que possible à de nouvelles données. Toutefois, cette étude étant basée sur une population retrospective, il serait intéressant de vérifier la capacité de généralisation à des patients pris en charge de manière multicentrique et prospective. En effet, la capacité des modèles à produire une bonne généralisation dépend de la proximité statistique entre le *validation set* (qui sert à simuler la cohorte externe), et le *test set*, qui est constitué des patients pour lesquels on cherche à prédire l'IPM. Ainsi, si les conditions d'acquisition

des données sont similaires entre le CHU de Brest et un autre centre, nous sommes confiants que notre méthode produira des résultats positifs pour la prédiction d'IPM de ce centre.




FIGURE 9 : Schéma de la validation croisée imbriquée. Dix modèles sont entraînés indépendamment par *cross-validation*, et une mesure de performance est obtenue par moyennage de ces 10 résultats.

2.6.5 Mise en place de la meilleure chaîne de traitement des données

Après obtention des 46 variables les plus pertinentes grâce aux étapes précédentes, une étape d'identification du modèle le plus performant (Section 2.6.3) ainsi que sa séquence de traitement des données correspondante est réalisée.

Pour rappel, une description de l'ensemble des méthodes de traitement des données est disponible en [Annexe D](#). Sont ainsi appliquées successivement sur les données une méthode de prise en compte des **valeurs extrêmes**, une méthode de prise en compte des **données manquantes**, une méthode de **normalisation** des données numériques et une méthode de **ré-échantillonnage**. Pour chaque méthode, une ou plusieurs techniques ont été considérées, ainsi que la non-application du traitement correspondant. Une analyse exhaustive de toutes les combinaisons de ces traitements (*e.g.*, pas de traitement des valeurs extrême + imputation des données manquantes par la moyenne + suppression des données extrêmes + imputation par kNN + ...) a été réalisée afin de déterminer les traitements bénéfiques à la classification des données. Les différentes configurations possibles pour chaque modèle sont consultables en [Annexe E](#).

Pour toutes les configurations, une validation croisée imbriquée (Section 2.6.4) a été effectuée. À l'issue de cette étape, nous avons identifié le modèle le plus performant ainsi que sa séquence de traitement des données correspondante.

Nous tenons à signaler deux éléments :

- après analyse de l'ensemble des combinaisons, aucune différence en terme de performance n'est observée dans notre étude en utilisant la méthode de prise en compte des valeurs extrêmes. Cette méthode de traitement des données n'a donc pas été utilisée dans la chaîne de traitements finale ;

- Les valeurs d'imputation et les paramètres de normalisation ont été appris à partir du *training set* et appliqués ensuite aux *training set* et *test set*. Le ré-échantillonnage n'a été appliqué qu'au *training set*.

Afin d'effectuer ces analyses nous avons utilisé la bibliothèque scikit-learn (1.2.2), avec Python (3.10.12).

2.6.6 Construction du modèle final

L'objectif à ce stade est d'optimiser le modèle qui a été identifié comme le plus performant à l'étape précédente, et de l'optimiser en ne gardant que le nombre minimal de variables nécessaires pour obtenir ses meilleurs performances. L'objectif est d'améliorer la lisibilité pour le médecin, ainsi que d'augmenter la performance du modèle.

Afin d'identifier les variables les plus influentes et leur nombre optimal sur la base des performances prédictives du modèle, nous effectuons une deuxième phase de sélection dite "fine" en complément de la sélection "grossière" (Section 2.6.2).

Nous avons choisi d'implémenter l'élimination récursive des variables (RFE – *Recursive Feature Elimination*). Cette technique sélectionne récursivement des ensembles de plus en plus petits de variables. À chaque itération, nous effectuons un nouvel entraînement de notre modèle par validation croisée imbriquée (Section 2.6.4) sur un ensemble de variables de plus en plus petit, en commençant par l'intégralité des variables du *training set*, puis nous estimons l'importance de nos variables pour éliminer la moins importante. Nous itérons jusqu'à atteindre une seule variable et évaluons la performance de notre modèle à chaque étape. Ainsi nous pouvons choisir les variables les plus pertinentes et leur nombre en fonction des performances de prédiction des modèles. La méthode de sélection SHAP^[32] a été implémentée afin d'évaluer l'importance de nos variables à chaque itérations de la RFE.

2.7 Apprentissage profond à partir des images scanner

Dans cette section, nous nous attachons à prédire l'implantation d'un pacemaker en utilisant uniquement les données brutes des scanners regroupées au sein de la **base de données n°2** : $\mathcal{D}_{img}$.

Une représentation schématique de l'ensemble des étapes suivies dans cette section pour générer les prédictions est disponible en Figure 10. Ces étapes sont explicitées dans la suite de cette section.

2.7.1 Format des images

Les examens d'imagerie sont stockés au format standard international *Digital Imaging and Communications in Medicine* (DICOM). Un fichier DICOM comprend l'image, et également des métadonnées (attributs) telles que des données cliniques sur le patient (*e.g.*, identité, nom du centre, nom du médecin prescripteur de l'examen), et les modalités d'acquisition (*e.g.*, type d'imagerie, matériel d'imagerie, données sur l'injection de contraste, données sur la résolution).

La sérialisation est le processus de conversion d'un objet en flux d'octets pour stocker l'objet dans une base de données ou un fichier ou de le charger dans la mémoire. Son principal objectif est d'enregis-




FIGURE 10 : Schéma des étapes utilisées pour générer le modèle final de DL. À partir des données d'imagerie, la silhouette cardiaque est segmentée, et fournie à un modèle pour entraînement.

trer l'état d'un objet afin de pouvoir le recréer si nécessaire. L'attribut "Transfer Syntax UID" renseigne sur la méthode utilisée pour la sérialisation ainsi que sur l'existence d'une méthode de compression des images. Concernant nos données, quelle que soit la marque du scanner, la méthode utilisée pour la sérialisation est "Explicit VR Little Endian", et nos images ne sont pas compressées.

Afin de visualiser les différents éléments des fichiers DICOM, nous avons utilisé le langage de programmation Python 3.8.10 avec sa bibliothèque Pydicom.

2.7.2 Les convolutions, base de l'architecture de DL "ResNet"

Les réseaux de neurones convolutifs (CNN – *Convolutional Neural Networks*) sont des modèles de DL utilisant des couches dites de convolution, où chaque neurone est responsable d'un fragment de l'image. Ils sont inspirés du cortex visuel et adaptés aux problèmes de vision par ordinateur (*e.g.*, la classification ou la segmentation d'images). Ils sont associés en plusieurs couches entièrement connectées, qui décomposent les caractéristiques de l'image en une multitude de motifs différents (*feature maps*). Cette décomposition peut être répétée plusieurs fois de façon séquentielle au sein de l'architecture (Figure 11).

Les couches de convolution constituent un élément central du traitement d'image par l'apprentis-

sage profond. Habituellement, en vision, on réalise des convolutions 2D, mais celles-ci (bien que moins courantes) existent également en 3D. Nous avons donc utilisé une architecture de réseau de neurones adaptée aux données 3D que nous manipulons, appelée "ResNet 3D", inspirée des modèles ResNet de référence pour la classification d'images 2D^[33].

L'implémentation des modèles a été réalisée en utilisant le langage Python 3.8.10 avec sa bibliothèque Pytorch. Les calculs ont été réalisés sur un GPU Nvidia-rtx-3090.




FIGURE 11 : Représentation d'une convolution avec un noyau de taille 3×3 et un pas de 2^4 .

2.7.3 Pré-traitements sur les images DICOM

Dans un premier temps, nous concaténons toutes nos images 2D en une image 3D en les ordonnant sur l'axe z , grâce à l'attribut "ImagePositionPatient" / "SliceLocation" contenu dans les métadonnées DICOM. Ensuite, nous ré-échelonnons les valeurs de nos images grâce à la transformation "Modality LUT". Cette transformation converti les valeurs de pixels dépendantes du fabricant en valeurs de pixels significatives pour la modalité, et indépendantes du fabricant. Cela permet d'unifier les acquisitions provenant de différentes marques. Il s'agit d'une transformation linéaire, qui utilise les informations issues des des métadonnées : "Rescale Slope" (0028, 1053) et "Rescale Intercept" (0028, 1052).

Similairement aux modèles de ML nous avons effectué une étape de normalisations des images. Pour cela nous utilisons la méthode de la "Z-Normalisation". Ainsi, pour chaque image, nous avons soustrait à la valeur de l'intensité de chacun de ses pixels l'intensité moyenne de l'image et nous les divisons par la valeur de l'écart-type de l'intensité de l'image.

Nous utilisons pour ces traitements le langage de programmation Python 3.8.10 avec sa bibliothèque Torchio.

⁴Source : <https://www.imaios.com/fr>.

2.7.4 Segmentation

Dans le cadre de ce projet nous utilisons des images TDM 3D de forte résolution (voir [Section 2.4](#)). De par cette caractéristique, l'utilisation de ce type d'image dans des réseaux de neurones augmente drastiquement les besoins en puissance de calcul et la taille de la mémoire vive nécessaire. Ainsi, afin de réduire la résolution de nos images, nous avons décidé de réduire la taille de ces dernières en les recadrant autour du cœur. Pour cela, nous avons au préalable réalisé une segmentation du cœur afin d'exclure les structures adjacentes : tissus pulmonaire, digestif et pariétal. Pour cela, nous avons adapté le code issu d'une compétition Kaggle "Chest-ct-segmentation"^[34], pour le faire fonctionner sur nos données. Ce code entraîne un modèle "U-net" (famille de modèles de DL classique en segmentation d'image) sur un jeu de données d'images scanographiques 2D (scanner thoracique)^[35], capable de segmenter le cœur, les poumons et la trachée.

Nos images scanographiques étant centrées sur le cœur, elles ne correspondent donc pas totalement aux images utilisées pour le développement du modèle de segmentation. Ainsi, nous avons ré-entraîné leur architecture sur leur jeu de données, en le rendant invariant aux zooms grâce à des traitement de "random-resize-crop" dans l'entraînement du modèle. Cette technique consiste à ne pas entraîner le modèle sur l'image complète mais sur un patch aléatoire et zoomé au sein de celle-ci. Chaque image est considérée plusieurs fois pour entraîner le modèle à partir de portions différentes.

Une fois le modèle ré-entraîné, nous avons fait passer nos images 3D comme une suite d'images 2D successives afin d'en extraire des masques du cœur. Suite à cela, nous en avons extrait des boîtes de délimitation cubiques (en 3D), en corrigeant manuellement les erreurs de segmentation. Celles-ci permettent de réduire la taille de nos images en les recadrant ([Figure 12](#)).




FIGURE 12 : Segmentation d'une coupe 2D. En vert le masque obtenu grâce au U-net et en rouge le cadre déduit du masque.

2.7.5 Entraînement du modèle

Dans l'état actuel, le modèle est entraîné sur l'une des trois modalités (calcique, systole, diastole) à la fois afin de prédire l'IPM. Utiliser plusieurs séquences en même temps aurait nécessité une procédure et une architecture plus complexes (plusieurs canaux sur l'entrée du réseau ou alors plusieurs entrées) ainsi qu'un coût en calcul plus fort, mais amènerait probablement à un modèle fournissant de meilleures

performances.

Similairement aux méthodes de ML, nous réalisons plusieurs fois nos entraînements en utilisant une *cross-validation* avec 5 sous-ensembles (et non plus une validation croisée imbriquée pour des raisons de ressources en calculs nécessaires), afin d'éviter le sur-apprentissage et estimer au mieux les performances de nos modèles. Le jeu de données est séparé aléatoirement en 85% pour le *training set* et 15%, pour le *test set*. Nous réalisons toute la procédure 10 fois afin d'estimer la variance de notre modèle. Le modèle sélectionné à la fin de l'entraînement par *cross-validation* est le modèle ayant les meilleures performances sur le *validation set*, que nous évaluons ensuite sur le *test set*.

Plus explicitement, nous avons utilisé l'"entropie croisée binaire", comme fonction de perte pour l'entraînement du modèle. Il s'agit de la fonction de perte la plus standard pour la classification binaire. Afin de savoir quand arrêter l'entraînement nous utilisons une fonction d'*early stopping* qui permet d'arrêter l'entraînement une fois que la fonction de perte évaluée sur le *training set* ne décroît plus. Nous utilisons "Adam" comme *optimizer* et un *batch size* de 8 (choix lié à la quantité de mémoire vive disponible sur la carte graphique).

3 Résultats

3.1 Principaux résultats sur $\mathcal{D}_{num}$

3.1.1 Performance des modèles dans la prédiction de l'IPM à 28 jours.

A l'issue des étapes d'optimisation décrites en [Section 2.6.5](#), chaque modèle a été entraîné en utilisant la chaîne de traitements des données lui permettant de maximiser ses performances.

En utilisant comme métrique de performance le *F1 score* (pertinente dans notre cas car notre cible de prédiction est déséquilibrée, *i.e.*, 18.8% d'IPM), les performances obtenues étaient, par ordre décroissant : 67.26% $\pm$ 9.72 (SVM), 62.18% $\pm$ 13.91 (GB), 62.25% $\pm$ 13.1 (XGBoost), 66.04% $\pm$ 9.79 (LR), 60.58% $\pm$ 13.34 (RF), 58.8% $\pm$ 9.11 (NB), 62.66% $\pm$ 10.83 (MLP), 56.13% $\pm$ 13.03 (DT).

Les courbes AUC-ROC et AUC-PR de tous les modèles sont représentées en [Figure 13](#). Sur ces courbes On observe des performances très similaires entre les modèles SVM, GB, XGBoost, LR et RF au dessus des performances des GNB, MLP et DT selon ces deux métriques.

Comme décrit dans [Section 2.6.5](#), le SVM ayant obtenu les meilleures performances selon les deux métriques, ce dernier sera donc utilisé dans les sections ci-dessous pour la présentation des autres résultats du ML.

3.1.2 Variables utilisées pour générer les prédictions de notre modèle final

En utilisant les éléments de la chaîne de traitements ayant amené aux meilleurs performances du SVM (ROS, imputation des valeurs manquantes par la médiane, standardisation) décrits en [Section 2.6.5](#) et en sélectionnant les variables les plus pertinentes pour générer les prédictions ([Section 2.6.6](#)), nous avons obtenu après entraînement final du modèle une AUC-ROC de 92.1% $\pm$ 4.7 et une PR-ROC de 77.6% $\pm$ 9.9.




FIGURE 13 : Performances de l'ensemble des modèles.

La sélection de variables par SHAP, nous permet d'étudier les 22 variables utilisées par le modèle pour générer ces résultats, à savoir 8 variables scanographiques, 7 variables ECG, 2 variables ETT, 3 variables liée à la procédure et 2 variables cliniques. Les résultats du SHAP sont données en Figure 14 (a). En Figure 14 (b), on présente la matrice de confusion issue de l'ensemble des prédictions réalisées par notre modèle. Après analyse de cette matrice, on obtient seulement 3.4% de faux négatifs (patients prédits par notre modèle comme n'ayant pas été implantés d'un pacemaker alors qu'ils ont finalement été implantés) et 8.7% de faux positifs (patients prédits par notre modèle comme ayant été implantés d'un pacemaker alors qu'ils ne l'ont pas été).

3.2 Variables complémentaires

Jusqu'à présent les résultats que nous avons présentés étaient issus de l'entraînement des modèles sur les données post-TAVI (en utilisant donc l'ensemble des variables pré + per + post). Dans cette section, nous présentons également les performances du SVM en n'utilisant que les données acquises en pré-TAVI, puis en ajoutant les données per-TAVI (*i.e.*, pré + per). L'ajout des données per- et post- permet un gain de performance par rapport à l'utilisation isolée des données pré-TAVI comme on le constate sur les données du Table 2.

	pré	pré + per	pré + per + post
AUC-ROC	89.7 ± 5.2	90.8 ± 6.0	92.1 ± 4.7
Score F1	65.1 ± 9.0	67.3 ± 8.9	71.8 ± 9.9
Accuracy	83.6 ± 5.1	84.7 ± 4.9	87.8 ± 4.7
Precision	55.7 ± 10.4	57.5 ± 10.0	64.9 ± 11.3
Recall	80.2 ± 12	83.0 ± 12.6	81.9 ± 12.9

TABLE 2 : Influence des variables pré-, per- et post-opératoires sur les performances de prédiction du SVM.




FIGURE 14 : (a) Importance des variables sélectionnées avec RFE + SHAP pour le SVM. En bleu les variables dont la diminution de la valeur augmente la prédiction d'IPM (corrélées négativement), et en rouge celles dont l'augmentation de la valeur augmente la prédiction (corrélées positivement). (b) Matrice de confusion du modèle SVM utilisant les variables ainsi sélectionnées.


Abréviations : dMSL – diastolic Membranous septal length, LVEF – left ventricular ejection fraction, dMSL – diastolic Membranous septal length, MR – Mitral regurgitation, NCC – Non-Coronary Cusp, NYHA – New-York Heart Association (heart failure functional classification), RCC – Right Coronary Cusp, sPAP – systolic pulmonary arterial pressure, TTE – transthoracic echocardiograph, Δ QRS – difference between the baseline QRS, Δ sMSL – difference between MSL in diastolic phase and in systolic phase measurements (dMSL - sMSL), VP – vrai positif, FP – faux positif, FN – faux négatif, VN – vrai négatif.

3.3 Place des données d'imagerie pour prédire l'IPM


En [Section 3.1.2](#), nous avons constaté l'importance des variables scanographiques dans l'entraînement des modèles (8 variables sur les 22 utilisées par le modèle). Afin de confirmer cela, nous avons entraîné notre meilleur modèle (SVM) en utilisant seulement les données de chaque modalité (clinique, ECG, ETT, scanner, données en lien avec la procédure), à l'exclusion des autres. Dans la [Figure 15](#), les résultats de ces analyses confirment la place centrale des données d'imagerie, au premier rang desquelles on retrouve les données issues du scanner. En effet, le fait d'utiliser seulement des données scanner nous fait obtenir d'excellentes performances, qui se rapprochent des prédictions utilisant toutes les variables déterminées comme importantes. En [Annexe F](#), les variables sélectionnées par SHAP + RFE sont données pour chaque type de modalité.

3.4 Comparaisons aux autres études

Afin d'analyser nos performances avec celles des autres études, nous avons inclus dans la comparaison les 4 études récentes réalisant les prédictions à partir de modèles de ML ([Section 1.4](#)). Nous présentons dans la [Table 3](#) les résultats. Nous avons également comparé les prédictions de notre modèle aux prédictions du *EMORY risk score*^[36] sur nos données. Ce score de risque a été dérivé d'une régression logistique multivariée et non pas d'un modèle de ML. Ce score utilisant des données pré- et per-TAVI nous l'avons comparé avec notre modèle entraîné sur les données pré- et per-TAVI. Les résultats de cette comparaison sont visible en [Figure 16](#). Notre approche obtient les meilleures performances quelle que soit la métrique utilisée ou le type de données utilisées (pré, pré + per, pré + per + post).



(a) Courbe ROC.




(b) Courbe précision-rappel.

FIGURE 15 : Influence des données d'imagerie sur les performances.


Abréviations : Imagery – données d'imagerie comprenant à la fois les données scanner et les données ETT, MDCT – Multi-detector computed tomography, TTE – ETT

Données utilisées	Notre approche		Gomes <i>et al.</i> ^[18]	Truong <i>et al.</i> ^[19]	Tsushima <i>et al.</i> ^[20]	Agasthi <i>et al.</i> ^[21]
AUC-ROC	pré+per+post	pré+per	pré+per+post	pré+per+post	pré+per	pré+per
F1 score	92.1%	90.8%	61%	81%	81%	65%
Accuracy	72.1%	67.3%	N/A	49%	72.6%	N/A
Population	87.8%	84.7%	70%	76%	74%	N/A
Cible prédite	520	451	557	1160	964	964
Modèle	IPM à 28 jours	IPM	IPM pendant hospitalisation	IPM pendant l'hospitalisation	IPM pendant l'hospitalisation	IPM à 30 jours
	SVM	SVM	RF	RL	GB	

TABLE 3 : Comparaison des performances de notre modèle avec celles des autres études.



(a) Courbe ROC.



(b) Courbe précision-rappel.

FIGURE 16 : Comparaison de notre modèle avec le score EMORY.

3.5 Analyses des performances avec la cible "trouble de haut grade"

En passant de la cible "implantation d'un pacemaker" (IPM) à "trouble de haut grade" (THG), on observe – et cela quelle que soit la métrique utilisée – une diminution dans la performance notre modèle (SVM). Les résultats de cette analyse sont donnés en [Table 4](#).

	Cible IPM	Cible THG
AUC-ROC	92.1 $\pm$ 4.7	85.4 $\pm$ 6.7
Score F1	71.8 $\pm$ 9.9	55.8 $\pm$ 9.6
Accuracy	87.8 $\pm$ 4.7	79.8 $\pm$ 5.3

TABLE 4 : Comparaison des performances selon la cible prédite, avec les variables pré + per + post.

3.6 Performances obtenues sur $\mathcal{D}_{img}$

Les performances des modèles de DL ont été retranscrites dans Table 5. L'architecture est un ResNet 10 adapté aux images 3D. Le nombre d'*epochs* moyen par entraînement est de 89, ce qui équivaut à environ 1h20 d'entraînement (une *epoch* est dite terminée quand l'ensemble des individus du *training set* est passé à travers le modèle). Pour rappel, l'arrêt de l'entraînement se fait sur un critère d'*early stopping* déterminé au préalable.

	Calcique	Systole	Diastole
AUC-ROC	70.2 $\pm$ 0.3	62.3 $\pm$ 0.5	60.1 $\pm$ 0.4
Score F1	50.1	39.8	31.1
Accuracy	78.0	71.7	70.4

TABLE 5 : Performances du ResNet 3D selon les séquences scanographiques utilisées pour l'entraînement.

4 Discussion

4.1 Forces de notre travail

Les principaux résultats de notre travail sont donc :

- La réalisation d'une étude exhaustive des éléments de traitement des données amenant à l'entraînement de modèles performants pour la prédiction d'IPM et de THG ;
- La mise en place d'un modèle de prédiction (SVM) performant dépassant les performances des autres études dans la prédiction de l'IPM dans les suites d'un TAVI ;
- La prise en compte de données scanographiques (non utilisées dans les autres études) et l'identification de celles-ci comme facteurs d'augmentation des performances ;
- La mise en évidence de deux variables, qui n'ont jamais été utilisées dans la littérature comme facteurs d'augmentation des performances de prédiction du risque d'IPM en post-TAVI : la mesure diastolique du MS, et la variation de la longueur du MS à travers le cycle cardiaque ;
- Un travail d'exploitation des images scanographiques 3D en utilisant des réseaux de neurones à base de convolutions 3D (DL), pour prédire la même cible.

4.1.1 Apprentissage automatique sur $\mathcal{D}_{num}$

Premièrement, nous nous sommes attachés à mettre en place une analyse des pré-traitements ainsi qu'un protocole d'entraînement nous permettant de maximiser nos performances et de diminuer la variance de nos résultats, afin d'apporter de la fiabilité dans les performances de nos modèles. Ce genre

d’approches dans les études médicales utilisant du ML restent peu réalisées, et les résultats des études sont souvent difficiles à reproduire en l’absence d’une description rigoureuse et exhaustive de la méthodologie, et difficiles à interpréter en l’absence d’intervalles de confiance.

Deuxièmement nous avons également comparé en [Section 3.4](#) les performances de notre modèle final avec celui des autres études. Bien que cette approche est standard en recherche médicale, cette comparaison doit être nuancée. En effet, pour pouvoir comparer de manière fiable plusieurs modèles effectuant la même prédiction (issus de plusieurs études), il aurait été nécessaire de les tester sur le même jeu de données, chose que n’avons pas réalisée (pour des raisons multiples à la tête desquelles l’impossibilité de partage de données médicales). De plus, ces études ne reportent pas d’intervalle de confiance sur leurs prédictions. Il serait donc nécessaire de reproduire leurs approches en détails pour une comparaison plus fine des résultats.

Troisièmement, à travers les techniques de sélection de variables, nous avons mis en évidence la place prépondérante des données scanner quantitatives dans la genèse des prédictions. En effet, en entraînant notre modèle seulement sur les données scanner, et après élimination récursive des variables une à une (technique de la RFE), notre modèle réussit à prédire l’IPM avec une AUC-ROC de 88.5%, en utilisant seulement 4 variables (la mesure diastolique du MS, le diamètre systolique de l’anneau, le degré de calcification global de la région autour des voies de conductions et la différence entre les mesures diastolique et systolique du MS).

Plus globalement, le scanner cardiaque a joué un rôle important dans la *success story* du TAVI. Initialement utilisé pour déterminer la voie d’abord, le scanner occupe désormais une place essentielle dans le *sizing* valvulaire afin de minimiser le risque de complications telles que les fuites péri-prothétiques, l’occlusion coronaire, le *mismatch* et la rupture de l’anneau. De plus les images scanner peuvent également être utilisées pour réduire l’incidence des troubles inductifs générés par la procédure, notamment à travers l’analyse du MS et de la distribution des calcifications autour de la valve aortique, comme cela a été confirmé dans notre étude.

Quatrièmement, concernant les variables sélectionnées dans notre étude pour effectuer les prédictions, toutes les variables utilisées par nos modèles sont cohérentes avec les études précédentes de la littérature. Cependant, nous sommes les premiers à décrire la mesure diastolique du MS et son interaction avec sa valeur systolique caractérisée par la variable $\Delta dsMS$ dans la prédiction de l’IPM. Le septum membraneux est connu pour être un repère anatomique visible au scanner, dont la localisation est corrélée avec l’emplacement du noeud atrio-ventriculaire et la branche gauche du faisceau de His. Dans une méta-analyse de dix-huit études portant sur 5 740 patients, les auteurs ont confirmé que la faible longueur du MS et le faible $\Delta sMSID$ sont associés à un risque plus élevé de troubles de la conduction en post-TAVI^[37]. Dans les précédentes études portant sur l’analyse du MS, les mesures de la longueur du MS sont effectuées en systole, alors que dans notre étude, nous avons choisi d’intégrer également sa mesure diastolique et sa variation de longueur en fonction du cycle cardiaque $\Delta dsMS$. Ces deux éléments se sont avérés associés à une augmentation de la performance de prédiction. $\Delta dsMS$ peut être interprété comme un marqueur de la rigidité du MS, et une diminution de sa valeur pourrait indiquer une diminution de l’élasticité du MS. Cette augmentation de rigidité peut s’expliquer en cas de calcification dans la région du MS (que notre étude retrouve comme facteur de risque d’IPM en [Figure 20 \(b\)](#) fournie en

Annexe F), mais pourrait également se voir en cas de maladie cardiaque infiltrative telle que l’amylose à TTR (environ 1 patient sur 7 implanté d’un TAVI aurait une amylose cardiaques à TTR^[38]). Il est ainsi concevable que cette rigidité puisse expliquer la plus grande fragilité du MS et donc le plus grand risque de traumatisme de la voie de conduction conduisant à une IPM.

Des études antérieures ont rapporté que le type de valve est un facteur de risque de lésion de la conduction. Dans notre modèle, l’utilisation d’une valve ACURATE ou COREVALVE a été retrouvée comme un facteur prédictif d’IPM dans les modèles utilisant les données per- et post-TAVI. Avec une diminution du taux d’IPM en utilisant la valve ACURATE et une augmentation de son taux avec la COREVALVE. Ces deux dispositifs sont des valves auto-expandables (Figure 2). Ce type de valve applique une force radiale continue sur l’anneau aortique et, en cas d’implantation plus profonde, également au niveau des structures environnantes de la chambre de chasse du ventricule gauche. Cette force de déploiement n’est pas homogène entre les différents dispositifs auto-expandables commercialisés. En effet, les patients implantés d’une COREVALVE ont plus souvent besoin de l’implantation d’un pacemaker dans les suites de la procédure que les patients traités par la valve SAPIEN 3 d’EDWARDS^[39]. En utilisant la valve ACURATE, les auteurs d’une étude multicentrique ont constaté un faible taux d’implantation de stimulateurs cardiaques de l’ordre de 6%^[40]. Ce faible taux d’IPM a été justifié par la distribution de la force radiale qui était très faible autour de la zone de conduction en raison de l’architecture du dispositif^[41].

Cinquièmement, dans cette étude, nous avons analysé l’impact des données pré-, per- et post-TAVI sur les performances. Afin d’établir cela, nous avons développé trois modèles : un modèle entraîné avec les données pré-TAVI uniquement, un modèle entraîné avec les données pré+per-TAVI et un modèle entraîné avec toutes les données (pré+per+post) (Section 3.2). Pour faciliter l’utilisation de ces trois modèles par les cliniciens, nous les avons implémentés en ligne *lien*. En entrant simplement les variables nécessaire pour chaque modèle, un pourcentage de risque d’IPM serait donné par cet outil. Cela devrait permettre d’utiliser le modèle le plus approprié en fonction du stade de prise en charge du patient (*i.e.*, pré-, per- ou post-TAVI). Grâce à cet outil pratique et facile à utiliser, les cliniciens seront en mesure d’estimer le risque post-opératoire d’IPM et par conséquent, d’optimiser la prise en charge des patients. Une étude prospective permettant de définir les niveaux de probabilité de risque devant mener à une modification des pratiques est nécessaire pour valider l’applicabilité de notre outils. Mais l’on pourrait d’ores et déjà imaginer qu’en cas de faible probabilité d’IPM générée par le modèle, une sortie rapide de l’hôpital pourrait s’envisager, et a contrario en cas de forte probabilité une surveillance scopée plus prolongée serait à envisager. De plus le MS et son interaction avec la profondeur d’implantation de la prothèse $\Delta sMSID$ se sont avérés être de puissants indicateurs de l’IPM. Dans une approche basée sur la médecine personnalisée, il est possible, chez des patients présentant un risque élevé d’IPM selon notre modèle d’apprentissage automatique, que l’opérateur du TAVI ajuste la profondeur d’implantation de la prothèse en fonction de la mesure du MS.

4.1.2 Apprentissage profond sur $\mathcal{D}_{img}$

Dans la deuxième partie de notre travail, nous avons développé de modèles de *deep learning* ayant pour vocation de prédire le risque d’IPM directement à partir d’imagerie 3D. Nous obtenons des résultats positifs, mais pour le moment en dessous de ceux des modèles entraînés sur les données de $\mathcal{D}_{num}$.

Cependant, il reste de nombreuses pistes d'améliorations à explorer.

4.1.3 Résultats complémentaires

En parallèle de projet, deux éléments dépassant le cadre de cette étude ont été analysés :

- Comme nous l'avons vu en [Section 1.4](#), tous les patients inclus dans cette étude ont bénéficié d'un scanner cardiaque dans le cadre du bilan pré-TAVI. En plus de ce scanner cardiaque, un scanner permettant l'analyse de l'abord vasculaire couvrant l'intégralité de l'aorte (des troncs supra-aortiques aux axes fémoraux) est réalisé (non étudié pour répondre à notre question de recherche). De par la nature de ses mécanismes d'apparition, le cancer est une maladie dont le risque augmente avec l'âge. Dans cette étude, la moyenne d'âge des patients étant de 84 ans, une étude de la prévalence des incidentalomes sur les scanners nous a paru pertinente. En [Annexe H](#), nous présentons ces découvertes fortuites que nous avons classées en trois catégories : vasculaire (36 patients), tumorale (29 patients) et autre (26 patients). Concernant les lésions tumorales, celles-ci ont toutes mené à un bilan complémentaire en préopératoire, qui a permis de déterminer qu'elles étaient accessibles à un traitement et/ou que l'espérance de vie du patient était compatible avec l'implantation d'un TAVI. Afin de déterminer la prévalence de l'ensemble des lésions tumorales sur les scanners pan-aortiques du bilan pré-TAVI, une étude future incluant à la fois les patients implantés et non implantés d'un TAVI serait à réaliser. En effet, aucun des patients chez qui une lésion de "mauvais pronostic" a été identifiée n'a été inclus dans l'analyse (le bénéfice/risque du TAVI n'ayant pas été en faveur de l'implantation chez ces patients) ;
- Dans notre étude, nous avons étudié la survenue de l'IPM en post-TAVI qui est la complication la plus fréquente. La survenue d'un accident vasculaire cérébral (AVC) cliniquement significatif, bien que moins fréquent (environ 2.5% des patients^[42]) peut être considérée comme étant l'une des complications les plus redoutables. Bien que notre étude n'ait pas eu vocation à prédire cet événement, nous avons également prédit en utilisant un modèle de ML cette autre cible à partir des données de $\mathcal{D}_{num}$ en utilisant la même méthodologie que notre étude. Des résultats prometteurs ont été atteints avec une AUC-ROC de 84.7%, et après analyse des variables utilisées par le modèle pour effectuer les prédictions (en utilisant SHAP+RFE), celles-ci sont en accord avec les données de la littérature (les 5 premiers critères étant : l'insuffisance rénale, la présence de calcifications de la crosse aortique, la présence de calcification de la chambre de chasse du ventricule gauche, et un antécédent d'AVC). Les résultats de cette analyse sont consultables en [Annexe J](#). Ce résultat prometteur supporte l'application de notre méthodologie à d'autre type de cible de prédiction, et ouvre la voie à de prochains travaux.

4.2 Limites

Premièrement, et cela est par définition inhérent aux études rétrospectives monocentriques, nous ne pouvons extrapoler les performances de notre modèle à d'autres centres. Par ailleurs, d'autres types de variables, et notamment scanographiques ou cliniques, auraient pu être incluses dans les prédictions (*e.g.*, mesure de septum inter-ventriculaire, calcifications mitrales, mesure de l'angle entre l'anneau aortique et l'aorte ascendante), mais également un plus grand nombre de patients auraient pu être inclus.

Nous sommes bien conscients de ces lacunes, constituant clairement des limites à notre études. Pour y remédier, la mise en place de notre outils en ligne, simple d'utilisation pourrait permettre de valider notre modèle au sein d'études prospectives, et multicentriques.

Deuxièmement comme nous l'avons signalé en [Section 2.2](#), le choix de l'IPM en post-TAVI critiquable. Pour y palier, nous avons également entraîné nos modèles sur une cible moins discutables (troubles de la conduction de haut grade), mais nos modèles n'ont pas obtenu des performances similaires à l'IPM. Une autre piste aurait été de choisir comme cible l'utilisation du pacemaker (variable binaire) à 6 mois ou 1 an après son implantation, mais plusieurs éléments constituent actuellement des freins à ce choix. Le premier élément est le choix du seuil de stimulation qui définirait l'utilisation du pacemaker (1% ?, 50% ?, 80% ?), le deuxième étant que les seuils de fréquence cardiaque déclenchant la stimulation ("activation du pacemaker") varient en fonction de la marque du pacemaker (chaque fabricant utilise des algorithmes spécifiques ayant pour but notamment de favoriser la conduction native en "tolérant" certaines anomalies) mais également selon le type de programmation effectuée par le cardiologue pour répondre au besoin du patient (*e.g.*, programmation d'un pacemaker différente selon le mode de vie du patient, l'indication initiale du pacemaker...).

Du fait de cette problématique (sous-utilisation des pacemakers implantés en post-TAVI), et afin de ne pas implanter de pacemaker de manière systématique, certains patients de notre étude ont été implantés d'un Holter ECG de longue durée avant la sortie d'hospitalisation. Dans le cadre de notre recueil de données, nous avons également recueilli cette information. Puis, nous avons analysé l'évolution de ces patients à 18 mois. Cette analyse est fournie dans l'annexe [Annexe I](#). Ainsi, nous constatons que parmi les 25 patients implantés d'un Holter ECG, 9 patients ont finalement présenté un trouble de la conduction qui a mené à la mise en place d'un pacemaker. Enfin, au sein de ces patients implantés d'un stimulateur cardiaque, nous avons analysé le délai de son implantation.

Troisièmement, de notre point de vue, le principal biais de notre étude est un biais de mesure et notamment de la mesure de la longueur du septum membraneux. D'une part il est connu que sur des études histologique (voir [Figure 21](#) en [Annexe G](#)) certains septums membraneux ne sont pas organisés de manière rectiligne mais plutôt de manière arquée voire même repliés sur eux même ; or cette subtilité est difficile à distinguer avec la résolution d'un scanner TDM où le MS est considéré comme un élément rectiligne. D'autre part, la réalisation de la mesure du MS n'est pas effectuée en pratique quotidienne chez tous les patients. De plus, selon la qualité de l'imagerie (influencée notamment par la qualité de la synchronisation cardiaque et/ou de l'injection) la mesure du MS (élément de petite taille en moyenne à 8 mm dans notre étude (mesure systolique) peut être mise à défaut. Enfin cette mesure MS peut être mesurée par deux approches différentes : sur une coupe coronale modifiée et sur une coupe infra-annulaire modifiée, ce qui conduit à des résultats différents. Jusqu'à présent, il n'y a pas de consensus clair, c'est pourquoi nous avons choisi d'utiliser l'approche coronale qui semble être plus proche de la vue angiographique (utilisée pour déterminer la profondeur d'implantation (ID)). Ces éléments constituent clairement une limite à la diffusion de notre modèle issue de $\mathcal{D}_{num}$ en conditions réelles.

4.3 Perspectives

Nous obtenons des résultats intéressants, notamment sur les données de $\mathcal{D}_{num}$ via les modèles de ML. Ainsi, un article formaté pour JACC CVI est en cours de finalisation. L'idée est d'illustrer l'intérêt des modèles de ML utilisant des données scanner pour la prédiction de risque d'IPM.

Plus concrètement, d'un point de vue clinique, au vu des limites énoncées, il est intéressant d'avoir un modèle capable de prédire le risque de pacemaker sans avoir besoin d'intervention humaine supplémentaire (qui peut être biaisée) comme des mesures ou des extractions de variables spécifiques. De ce fait, la démarche par analyse d'images scanner est intéressante pour palier à cela. De plus, elle permet d'explorer le cœur dans sa totalité, et pourrait, si des bonnes performances sont atteintes, permettre de découvrir de nouveaux liens entre la morphologie et le risque d'IPM, en utilisant par exemple des outils de visualisation des portions d'images amenant à la prédiction (e.g., GradCAM^[43]).

De nombreuses pistes restent à explorer pour améliorer l'approche à base d'images 3D :

- Une première piste serait d'utiliser des techniques de *data augmentation* afin d'augmenter artificiellement le *training set*. Nous envisageons plusieurs techniques d'augmentation (voir Figure 17) ;
- Une seconde piste serait d'utiliser les différentes séquences scanner en même temps dans l'entraînement des réseaux. Une manière consisterait à combiner les prédictions issues de 3 modèles en les moyennant ou en entraînant un modèle simple dessus. Des méthodes plus complexes peuvent également être envisagées, comme entraîner un plus gros réseau avec plusieurs entrées, ou plusieurs canaux d'entrées, afin de permettre au modèle d'extraire de l'information jointe des différentes séquences ;
- Enfin une des pistes les plus prometteuses, de notre point de vue, serait de fusionner les données de $\mathcal{D}_{num}$ et les images scanner de $\mathcal{D}_{img}$ pour entraîner un modèle avec toute l'information à disposition. Les MLP étant assez performants dans les résultats en Section 3.1.1, une première approche sera d'étudier la littérature en fusion de données hétérogènes pour le *deep learning*, ce qui permettra de coupler dans un même modèle des données numériques, catégorielles et d'imagerie scanner.

5 Conclusion

Les travaux de cette thèse portent principalement sur la prédiction de l'implantation d'un pacemaker (IPM) après un TAVI en se basant sur les outils de l'intelligence artificielle.

Dans un premier temps, nous avons prédit l'IPM à l'aide d'un modèle d'apprentissage automatique (ML – Machine Learning) entraîné sur les données de 520 patients implantés d'un TAVI au CHU de BREST entre 2019 et 2021. Pour chaque patient, on dispose de 67 variables numériques et catégorielles (20 données cliniques, 11 données ECG, 12 données sur la procédure de TAVI, 12 données ETT et 12 données scanners TDM). Nous avons appliqué une analyse exhaustive de la chaîne de traitements de ces données et utilisé une validation croisée imbriquée (pour l'entraînement et l'évaluation des modèles). L'utilisation de la validation croisée imbriquée permet de réduire la variance des résultats et de simuler une cohorte externe. Nous avons ainsi obtenu le meilleur modèle (SVM) parmi l'ensemble des modèles




FIGURE 17 : Techniques de *data augmentation* 3D envisagées : (a) Coupe 2D de l'image d'origine ; (b) Changement de contraste ; (c) Bruitage ; (d) Déformation élastique ; (e) Rotation + Zoom ; (f) Échange aléatoire de cubes 3D.

évalués. Par la suite une méthode de sélection des variables pertinentes (grâce à l'utilisation de RFE + SHAP) nous a permis de réduire le nombre de variables nécessaires ayant mené à générer un modèle SVM performant (AUC-ROC 92.1 % $\pm$ 4.7). Ces performances dépassent les résultats issus des études de la littérature médicale actuelle. Par ailleurs, grâce à la technique de sélection de variables, les données scanners ont été identifiées comme facteurs d'augmentation des performances du modèle de prédiction. En outre, cette méthodologie a permis de mettre en évidence deux variables (mesure diastolique du septum membraneux et la variation de la longueur du septum membraneux à travers le cycle cardiaque) comme étant pertinente pour prédire l'IPM. A notre connaissance ces deux variables n'ont jamais été utilisées à ce jour dans la littérature.

Ces données scanners numériques et catégorielles ayant été mises en évidence comme parmi les plus importantes pour générer la prédiction de l'IPM, nous avons exploité, dans une deuxième partie de ce travail, une prédiction de l'IPM directement à partir des données scanners 3D au format DICOM en utilisant un modèle d'apprentissage profond (DL – Deep-Learning). Pour aboutir à ce modèle de DL, plusieurs phases ont été réalisées : traitement et préparation des données scanners DICOM, segmentation de la silhouette cardiaque, entraînement d'un modèle à base de convolution (ResNet 3D). Les performances de ce modèle (AUC-ROC 70.2 % $\pm$ 0.3 pour la séquence calcique, AUC-ROC 62.3 % $\pm$ 0.5 pour la séquence en systole et AUC-ROC 60.1 % $\pm$ 0.4 pour la séquence en diastole) sont en deçà des performances du modèle de ML précédent, néanmoins constituent une innovation en terme de prédiction de l'IPM en post TAVI en se basant sur les images TDM directement.

Afin de valider l'application de notre méthodologie (ML) à la prédiction de nouvelles cibles, nous avons implémenté un modèle de ML pour prédire l'AVC. De bonnes performances ont été constatées.

Le modèle ML de prédiction de l'IPM est disponible en ligne pour permettre sa future utilisation. De nombreuses pistes restent à explorer pour améliorer l'approche à base d'images 3D ([Section 4.3](#)).

Notre travail confirme aujourd'hui la place des outils de l'intelligence artificielle dans le domaine médical, en particulier dans la prédiction du risque d'implantation d'un pacemaker après un TAVI.

Références

- [1] Brian R Lindman, Marie-Annick Clavel, Patrick Mathieu, Bernard Iung, Patrizio Lancellotti, Catherine M Otto, and Philippe Pibarot. Calcific aortic stenosis. *Nature reviews Disease primers*, 2(1) :1–28, 2016.
- [2] Alec Vahanian, Friedhelm Beyersdorf, Fabien Praz, Milan Milojevic, Stephan Baldus, Johann Bauersachs, Davide Capodanno, Lenard Conradi, Michele De Bonis, Ruggero De Paulis, et al. 2021 esc/eacts guidelines for the management of valvular heart disease : developed by the task force for the management of valvular heart disease of the european society of cardiology (esc) and the european association for cardio-thoracic surgery (eacts). *European heart journal*, 43(7) :561–632, 2022.
- [3] Gry Wisthus Eveborn, Henrik Schirmer, Geir Heggelund, Per Lunde, and Knut Rasmussen. The evolving epidemiology of valvular aortic stenosis. the tromsø study. *Heart*, 99(6) :396–400, 2013.
- [4] Steven J Lester, Brett Heilbron, Ken Gin, Arthur Dodek, and John Jue. The natural history and rate of progression of aortic stenosis. *Chest*, 113(4) :1109–1114, 1998.
- [5] Blase A Carabello. Transcatheter aortic-valve implantation for aortic stenosis in patients who cannot undergo surgery. *Current Cardiology Reports*, 13(3) :173–174, 2011.
- [6] Craig R Smith, Martin B Leon, Michael J Mack, D Craig Miller, Jeffrey W Moses, Lars G Svensson, E Murat Tuzcu, John G Webb, Gregory P Fontana, Raj R Makkar, et al. Transcatheter versus surgical aortic-valve replacement in high-risk patients. *New England Journal of Medicine*, 364(23) :2187–2198, 2011.
- [7] Michael J Reardon, Nicolas M Van Mieghem, Jeffrey J Popma, Neal S Kleiman, Lars Søndergaard, Mubashir Mumtaz, David H Adams, G Michael Deeb, Brijeshwar Maini, Hemal Gada, et al. Surgical or transcatheter aortic-valve replacement in intermediate-risk patients. *New England journal of medicine*, 376(14) :1321–1331, 2017.
- [8] Jeffrey J Popma, G Michael Deeb, Steven J Yakubov, Mubashir Mumtaz, Hemal Gada, Daniel O'Hair, Tanvir Bajwa, John C Heiser, William Merhi, Neal S Kleiman, et al. Transcatheter aortic-valve replacement with a self-expanding valve in low-risk patients. *New England Journal of Medicine*, 380(18) :1706–1715, 2019.
- [9] Michael J Mack, Martin B Leon, Vinod H Thourani, Raj Makkar, Susheel K Kodali, Mark Russo, Samir R Kapadia, S Chris Malaisrie, David J Cohen, Philippe Pibarot, et al. Transcatheter aortic-

- valve replacement with a balloon-expandable valve in low-risk patients. *New England Journal of Medicine*, 380(18) :1695–1705, 2019.
- [10] Vincent Auffret, Rishi Puri, Marina Urena, Chekrallah Chamandi, Tania Rodriguez-Gabella, François Philippon, and Josep Rodés-Cabau. Conduction disturbances after transcatheter aortic valve replacement : current status and future perspectives. *Circulation*, 136(11) :1049–1069, 2017.
- [11] Yasser Sammour, Amar Krishnaswamy, Arnav Kumar, Rishi Puri, Khaldoun G Tarakji, Najdat Bazarbashi, Serge Harb, Brian Griffin, Lars Svensson, Oussama Wazni, et al. Incidence, predictors, and implications of permanent pacemaker requirement after transcatheter aortic valve replacement. *Cardiovascular Interventions*, 14(2) :115–134, 2021.
- [12] George CM Siontis, Peter Jüni, Thomas Pilgrim, Stefan Stortecky, Lutz Büllesfeld, Bernhard Meier, Peter Wenaweser, and Stephan Windecker. Predictors of permanent pacemaker implantation in patients with severe aortic stenosis undergoing tavr : a meta-analysis. *Journal of the American College of Cardiology*, 64(2) :129–140, 2014.
- [13] Ashraf Hamdan, Victor Guetta, Robert Klempfner, Eli Konen, Ehud Raanani, Michael Glikson, Orly Goitein, Amit Segev, Israel Barbash, Paul Fefer, et al. Inverse relationship between membranous septal length and the risk of atrioventricular block in patients undergoing transcatheter aortic valve implantation. *JACC : Cardiovascular Interventions*, 8(9) :1218–1228, 2015.
- [14] George Latsios, Ulrich Gerckens, Lutz Buellesfeld, Ralf Mueller, Daniel John, Seyrani Yuecel, Joerg Syring, Barthel Sauren, and Eberhard Grube. “device landing zone” calcification, assessed by msct, as a predictive factor for pacemaker implantation after tavi. *Catheterization and cardiovascular interventions*, 76(3) :431–439, 2010.
- [15] Yasser Sammour, Kinjal Banerjee, Arnav Kumar, Hassan Lak, Sanchit Chawla, Cameron Incognito, Jay Patel, Manpreet Kaur, Omar Abdelfattah, Lars G Svensson, et al. Systematic approach to high implantation of sapien-3 valve achieves a lower rate of conduction abnormalities including pacemaker implantation. *Circulation : Cardiovascular Interventions*, 14(1) :e009407, 2021.
- [16] Gilbert HL Tang, Syed Zaid, Iassen Michev, Hasan Ahmad, Ryan Kaple, Cenap Undemir, Martin Cohen, and Steven L Lansman. “cusp-overlap” view simplifies fluoroscopy-guided implantation of self-expanding valve in transcatheter aortic valve replacement. *JACC : Cardiovascular Interventions*, 11(16) :1663–1665, 2018.
- [17] Dagmar F Hernandez-Suarez, Yeunjung Kim, Pedro Villablanca, Tanush Gupta, Jose Wiley, Brenda G Nieves-Rodriguez, Jovaniel Rodriguez-Maldonado, Roberto Feliu Maldonado, Istoni da Luz Sant’Ana, Cristina Sanina, et al. Machine learning prediction models for in-hospital mortality after transcatheter aortic valve replacement. *Cardiovascular Interventions*, 12(14) :1328–1338, 2019.
- [18] Bruna Gomes, Maximilian Pilz, Christoph Reich, Florian Leuschner, Mathias Konstandin, Hugo A Katus, and Benjamin Meder. Machine learning-based risk prediction of intrahospital clinical outcomes in patients undergoing tavi. *Clinical Research in Cardiology*, 110 :343–356, 2021.

- [19] Vien T Truong, Daniel Beyerbach, Wojciech Mazur, Matthew Wigle, Emma Bateman, Akhil Pallerla, Tam NM Ngo, Satya Shreenivas, Justin T Tretter, Cassady Palmer, et al. Machine learning method for predicting pacemaker implantation following transcatheter aortic valve replacement. *Pacing and Clinical Electrophysiology*, 44(2) :334–340, 2021.
- [20] Takahiro Tsushima, Sadeer Al-Kindi, Fahd Nadeem, Guilherme F Attizzani, Yakov Elgudin, Alan Markowitz, Marco A Costa, Daniel I Simon, Mauricio S Arruda, Judith A Mackall, et al. Machine learning algorithms for prediction of permanent pacemaker implantation after transcatheter aortic valve replacement. *Circulation : Arrhythmia and Electrophysiology*, 14(3) :e008941, 2021.
- [21] Pradyumna Agasthi, Hasan Ashraf, Sai Harika Pujari, Marlene Girardo, Andrew Tseng, Farouk Mookadam, Nithin Venepally, Matthew R Buras, Bishoy Abraham, Banveet K Khetarpal, et al. Prediction of permanent pacemaker implantation after transcatheter aortic valve replacement : The role of machine learning. *World Journal of Cardiology*, 15(3) :95, 2023.
- [22] Guangming Zhang, Rong Liu, Min Pu, and Xiaobo Zhou. Biomechanical identification of high-risk patients requiring permanent pacemaker after transcatheter aortic valve replacement. *Frontiers in bioengineering and biotechnology*, 9 :615090, 2021.
- [23] Valeria Galli, Filip Loncaric, Giorgia Rocatello, Patricio Astudillo, Laura Sanchis, Ander Regueiro, Ole De Backer, Martin Swaans, Johan Bosmans, Joana Maria Ribeiro, et al. Towards patient-specific prediction of conduction abnormalities induced by transcatheter aortic valve implantation : a combined mechanistic modelling and machine learning approach. *European Heart Journal-Digital Health*, 2(4) :606–615, 2021.
- [24] Michael Glikson, Jens Cosedis Nielsen, Mads Brix Kronborg, Yoav Michowitz, Angelo Auricchio, Israel Moshe Barbash, José A Barrabés, Giuseppe Boriani, Frieder Braunschweig, Michele Brignole, et al. 2021 esc guidelines on cardiac pacing and cardiac resynchronization therapy : Developed by the task force on cardiac pacing and cardiac resynchronization therapy of the european society of cardiology (esc) with the special contribution of the european heart rhythm association (ehra). *EP Europace*, 24(1) :71–164, 2022.
- [25] Giuliano Costa, Paolo Zappulla, Marco Barbanti, Arianna Cirasa, Denise Todaro, Giulia Rapisarda, Andrea Picci, Francesco Platania, Antonio Tosto, Angelo Di Grazia, et al. Pacemaker dependency after transcatheter aortic valve implantation : incidence, predictors and long-term outcomes. *EuroIntervention*, 15(10) :875–883, 2019.
- [26] Philipp Blanke, Jonathan R Weir-McCall, Stephan Achenbach, Victoria Delgado, Jörg Hausleiter, Hasan Jilaihwai, Mohamed Marwan, Bjarne L Nørgaard, Niccolo Piazza, Paul Schoenhagen, et al. Computed tomography imaging in the context of transcatheter aortic valve implantation (tavi)/transcatheter aortic valve replacement (tavr) an expert consensus document of the society of cardiovascular computed tomography. *JACC : Cardiovascular Imaging*, 12(1) :1–24, 2019.
- [27] Tania Pawade, Tej Sheth, Ezequiel Guzzetti, Marc R Dweck, and Marie-Annick Clavel. Why and how to measure aortic valve calcification in patients with aortic stenosis. *JACC : Cardiovascular Imaging*, 12(9) :1835–1848, 2019.

- [28] MZ Khawaja, R Rajani, A Cook, A Khavandi, A Moynagh, S Chowdhary, MS Spence, S Brown, SQ Khan, N Walker, et al. Permanent pacemaker insertion after corevalve transcatheter aortic valve implantation : incidence and contributing factors (the uk corevalve collaborative). *Circulation*, 123(9) :951–960, 2011.
- [29] Chris Ding and Hanchuan Peng. Minimum redundancy feature selection from microarray gene expression data. *Journal of bioinformatics and computational biology*, 3(02) :185–205, 2005.
- [30] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in neural information processing systems*, 30, 2017.
- [31] Zhi-Hua Zhou. *Machine learning*. Springer Nature, 2021.
- [32] Shay Cohen, Eytan Ruppín, and Gideon Dror. Feature selection based on the shapley value. In *Proceedings of the 19th international joint conference on Artificial intelligence*, pages 665–670, 2005.
- [33] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [34] <https://www.kaggle.com/datasets/polomarco/chest-ct-segmentation>.
- [35] 2020 Kónya et al. Lung segmentation dataset, <https://www.kaggle.com/sandorkonya/ct-lung-heart-trachea-segmentation>.
- [36] Soroosh Kiani, Norihiko Kamioka, George B Black, Marvin Louis Roy Lu, John C Lisko, Birju Rao, Andenet Mengistu, Patrick T Gleason, James P Stewart, Hope Caughron, et al. Development of a risk score to predict new pacemaker implantation after transcatheter aortic valve replacement. *JACC : Cardiovascular Interventions*, 12(21) :2133–2142, 2019.
- [37] Michel Pompeu Sá, Jef Van den Eynde, Xander Jacquemyn, Ozgun Erten, Roberto Rodriguez, Scott Goldman, Paul M Coady, Eric Gnall, William A Gray, Harish Jarrett, et al. Computed tomography-derived membranous septum length as predictor of conduction abnormalities and permanent pacemaker implantation after tavi : A meta-analysis of observational studies. *Catheterization and Cardiovascular Interventions*, 2023.
- [38] Adam Castano, David L Narotsky, Nadira Hamid, Omar K Khaliq, Rachelle Morgenstern, Albert DeLuca, Jonah Rubin, Codruta Chiuza, Tamim Nazif, Torsten Vahl, et al. Unveiling transthyretin cardiac amyloidosis and its predictors among elderly patients with severe aortic stenosis undergoing transcatheter aortic valve replacement. *European heart journal*, 38(38) :2879–2887, 2017.
- [39] Wieneke Vlastra, Jaya Chandrasekhar, Antonio J Muñoz-Garcia, Didier Tchétché, Fabio S de Brito Jr, Marco Barbanti, Ran Kornowski, Azeem Latib, Augusto D’Onofrio, Flavio Ribichini, et al. Comparison of balloon-expandable vs. self-expandable valves in patients undergoing transfemoral transcatheter aortic valve implantation : from the center-collaboration. *European heart journal*, 40(5) :456–465, 2019.

- [40] Andreas Rück, Won-Keun Kim, Mohamed Abdel-Wahab, Holger Thiele, Tanja K Rudolph, Alexander Wolf, Jan Martin Wambach, Ole De Backer, Lars Sondergaard, Christian Hengstenberg, et al. The early neo2 registry : Transcatheter aortic valve implantation with accurate neo2 in a european population. *Journal of the American Heart Association*, 12(15) :e029464, 2023.
- [41] Stefan Toggweiler, Henrik Nissen, Brynjolfur Mogensen, Florim Cuculi, Christian Fallesen, Karsten Tange Veien, Miriam Brinkert, Richard Kobza, and Andreas Rück. Very low pacemaker rate following accurate neo transcatheter heart valve implantation. *EuroIntervention*, 13(11) :1273–80, 2017.
- [42] Samir R Kapadia, Raj Makkar, Martin Leon, Mohamed Abdel-Wahab, Thomas Waggoner, Steffen Massberg, Wolfgang Rottbauer, Samuel Horr, Lars Sondergaard, Juhana Karha, et al. Cerebral embolic protection during transcatheter aortic-valve replacement. *New England Journal of Medicine*, 387(14) :1253–1263, 2022.
- [43] Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam : Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE international conference on computer vision*, pages 618–626, 2017.
- [44] Nitesh V Chawla, Kevin W Bowyer, Lawrence O Hall, and W Philip Kegelmeyer. Smote : synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16 :321–357, 2002.
- [45] Tomokazu Kawashima and Fumi Sato. Visualizing anatomical evidences on atrioventricular conduction system for tavi. *International journal of cardiology*, 174(1) :1–6, 2014.

Annexe A Détails sur les métriques utilisées

A.1 Précision, Rappel, Score F1

La précision et le rappel se concentrent sur la performance du modèle concernant les individus positifs. La précision correspond au taux de prédictions correctes parmi les prédictions positives. Elle mesure donc la capacité du modèle à ne pas faire d'erreur lors d'une prédiction positive. Le *rappel* (ou sensibilité) correspond au taux d'individus positifs détectés par le modèle. Il mesure la capacité du modèle à détecter l'ensemble des individus positifs.

Le score F1 est une métrique de classification qui mesure la capacité d'un modèle à bien prédire les individus positifs, tant en termes de précision (taux de prédictions positives correctes) qu'en termes de rappel (taux de positifs correctement prédits). Il correspond en effet à la moyenne harmonique de ces indicateurs.

A.2 Accuracy

Cette métrique de performance évalue la capacité d'un modèle de classification à bien prédire à la fois les individus positifs et les individus négatifs. Elle mesure le taux de prédictions correctes sur l'ensemble des prédictions.

L'*accuracy* a en commun avec le score F1 de résumer la performance d'un modèle en un seul indicateur pour chaque seuil de classification. Le score F1 est plus complexe mais a l'avantage d'être plus robuste en présence de données déséquilibrées.

A.3 Matrice de confusion

La matrice de confusion (Table 6) est le socle des différentes métriques de classification utilisées en ML. Elle consiste en un tableau à 4 valeurs représentant les différentes combinaisons de valeurs réelles et valeurs prédites (Vrai Positif, Faux Positif, Vrai Négatif, Faux Négatif).

		Classe prédite	
		Positive	Négative
Classe réelle	Positive	Vrai Positif (VP)	Faux Négatif (FN)
	Négative	Faux Positif (FP)	Vrai Négatif (VN)

Mesure	Formule
Accuracy	$(VP+VN)/(VP+FP+FN+VN)$
Précision	$TP/(TP+FP)$
Rappel	$TP/(TP+FN)$
Score F1	$2*Précision*Rappel/(Précision+Rappel)$


TABLE 6 : Matrice de confusion.

A.4 Courbe ROC, AUC-ROC, AUC-PR


La courbe *Receiver operating characteristic* (ROC) est une représentation graphique de la relation existante entre la sensibilité et la spécificité (1-spécificité) d'un test pour tous les seuils possibles. Cette courbe permet de calculer la métrique de l'aire sous la courbe ROC (AUC-ROC), consistant à sommer les surfaces des trapèzes verticaux reliant deux points successifs.

Similairement, la métrique AUC-PR consiste à calculer l'aire sous la courbe *Précision-Rappel*. C'est une métrique de performance adaptée à la classification quand les données sont déséquilibrées.


Annexe B Paramètres influençant la qualité de l'imagerie



(a) Nombre de coupes (slices) par acquisition (axe z).



(b) Distance entre le centre de deux pixels adjacents (pixel spacing, axes x et y).



(c) Épaisseur des coupes (slice thickness, axe z).

FIGURE 18 : Nombres de scanners réalisés en fonction des paramètres influençant la qualité de l'imagerie. Pour chaque patient sont réalisées : une séquence non injectée (calcique), et deux séquences injectées en systole et en diastole.

Dans le cadre du bilan pré-opératoire, est réalisé pour chaque patient de manière systématique un scanner cardiaque. Ce dernier comporte deux phases : une première séquence en contraste spontané puis une séquence injectée. Les images ont été analysées à l'aide d'un logiciel de post-traitement (*Syngo.via* ; *Siemens Healthcare*).

B.1 Références des scanners :

Dans notre étude deux scanners tomodensitométriques multidétecteurs ont été utilisés :

- SIEMENS-EDGE (SE) (*Siemens Medical Solutions USA*) pour 230 patients.
- TOSHIBA-ACQUILLION (TA) ONE GENESIS (*Toshiba America Medical Systems, Tustin, Californie*) pour 290 patients.

Quelle que soit la marque, la matrice de résolution des coupes scanner reconstruites (selon les axes

x et y) est de 512×512 pixels.

B.2 Paramètres d'acquisition des séquences non injectées

- Largeur de collimation d'une seule coupe de 0.5 mm (TA) et de 1.2 mm (SE);
- Énergie délivrée : 150 mA à 120 kV (TA) et de 190 mA à 100 kV (SE);
- Épaisseur de coupe de 0.5 mm (TA) et de 3 mm (SE).

B.3 Paramètres d'acquisition des séquences injectées

- Largeur de collimation d'une seule coupe de 0.5 mm (TA) et 0.6 mm (SE);
- Temps de rotation : 275 ms (TA) et 280 ms (SE);
- Injection intraveineuse de 75 ml de produit de contraste iodé (*Iomeron 350, Bracco, Milan, Italie*) à un débit de 3.5 ml/s, suivie d'un rinçage au sérum physiologique de 40 ml;
- Modulation automatique de l'énergie délivrée avec des valeurs moyennes de 710 mA à 120 kV (TA) et 460 mA à 100 kV (SE);
- Une apnée brève est réalisée par le patient pendant que l'électrocardiogramme était enregistré simultanément;
- Toutes les images ont été reconstruites de manière rétrospective avec une épaisseur de coupe de 0.5 mm (TA) et de 0.6 mm (SE). Cette reconstruction des données brutes acquises en scanner permet d'obtenir une acquisition de l'ensemble du cœur en diastole et en systole.

Annexe C Caractéristiques de la population

Features	All (n=520)	Pacemaker (n=98)	No Pacemaker (n=422)	p-value
Age (years)	84,3 ± 5,5	84,7 ± 5,9	84,2 ± 5,4	0,25
Women	48,2% (251)	35,7% (35)	51,2% (216)	0,04
BMI (kg/m ²)	26,5 ± 4,7	26,7 ± 5,4	26,4 ± 4,6	0,94
Clinical data :				
Prior surgical aortic bioprosthesis	4,4% (23)	0,0% (0)	5,4% (23)	0,02
Prior CABG	6,5% (34)	7,1% (7)	6,4% (27)	0,966
Prior PCI	19,2% (100)	19,3% (19)	19,1% (81)	0,968
Prior peripheral arterial disease	8,6% (45)	8,1% (8)	8,7% (37)	0,854
Mellitus diabetes	17,6% (92)	16,3% (16)	18% (76)	0,721
Chronic respiratory failure	5,0% (26)	6,1% (6)	4,7% (20)	0,581
Previous stroke	7,3% (38)	11,2% (11)	6,4% (27)	0,111
Chronic kidney disease				0,004
stage 3	51,7% (269)	50% (49)	52,1% (220)	
stage 4	4,8% (25)	5,1% (5)	4,7% (20)	
stage 5	0,6% (3)	3,1% (3)	0,0% (0)	
Creatinine	90,2 ± 41	103 ± 72,1	87,1 ± 30,4	0,022
Logistic euroSCORE	9,5 ± 7,7	9,3 ± 7,5	9,6 ± 7,8	0,793
Acute coronary syndrome <100days	1,3% (7)	1% (1)	1,4% (6)	0,657
Dyspnea NYHA 3 or 4	37,8% (197)	42,9% (42)	36,7% (155)	0,757
Syncope in the past year	3,6% (19)	11,2% (11)	1,9% (8)	<0,001
Angina CCS 3 or 4	0,3% (2)	0,0% (0)	0,5% (2)	0,495
Anticoagulant therapy	27,3% (142)	32,6% (32)	26,0% (110)	0,26
Electrocardiogram data :				
Atrial fibrillation/flutter	20,1% (105)	19,4% (19)	20,4% (86)	0,844
PR time interval (ms)	186 ± 38	205 ± 48	181 ± 34	<0,001
QRS time interval (ms)	104 ± 22	114 ± 24	102 ± 21	<0,001
First degree AV block	73,6% (383)	56,1% (55)	77,7% (328)	0,024
Right bundle branch block	10,6% (55)	25,5% (25)	7,1% (30)	<0,001
Left bundle branch block	9,6% (50)	8,1% (8)	9,9% (42)	0,606
TTE data :				
LVEF (%)	55,7 ± 10	55 ± 10	55,8 ± 10,3	0,256
Aortic valve systolic area	0,71 ± 0,2	0,73 ± 0,2	0,71 ± 0,2	0,107
Aortic valve systolic mean gradient	51 ± 20	51 ± 9	51 ± 2	0,283
sPAP (mmhg)	40 ± 13	39 ± 14	41 ± 13	0,117
AR				0,559
I	34,8% (181)	39,8% (39)	33,6% (142)	
II	7,5% (39)	7,1% (7)	7,6% (32)	
III	1,3% (7)	2,1% (2)	1,2% (5)	
IV	1,5% (8)	0% (0)	1,9% (8)	
MR				0,370
I	28,1% (146)	22,4% (22)	29,3% (124)	
II	8,6% (45)	6,1% (6)	9,2% (39)	
III	0,9% (5)	1% (1)	0,9% (4)	
IV	0,5% (3)	0,0% (0)	0,7% (3)	

MDCT data				
Minimal aortic annulus diameter (mm)	21,2 ± 2,25	21,5± 2,2	21 ± 2,2	0,045
Maximal aortic annulus diameter (mm)	26,1 ± 2,68	26,8 ± 2,6	25,9 ± 2,6	0,003
Systolic area (mm²)	482,6 ± 84	507,4 ± 89,2	476,5± 82,1	0,003
Diastolic area (mm²)	480,1 ± 88,6	504,8 ± 89,7	474,3 ± 87,5	0,004
Aortic calcium score	3789,7 ± 2021	4530,65 ± 2544	3606,8 ± 1827	0,001
LCC calcification				0,02
0	2,1% (11)	1,0% (1)	2,3% (10)	
1	65,1% (339)	63,2% (62)	65,6% (277)	
2	24,6% (128)	29,5% (29)	23,4% (99)	
3	3% (16)	6,1% (6)	2,3% (10)	
RCC calcification				0,003
0	2,6% (14)	1% (1)	3% (13)	
1	73,6% (383)	72,45% (71)	73,93% (312)	
2	15,77% (82)	19,39% (19)	14,93% (63)	
3	2,69% (14)	7,14% (7)	1,66% (7)	
NCC calcification				0,002
0	0,19% (1)	0,0% (0)	0,24% (1)	
1	46,1% (240)	35,7% (35)	48,5% (205)	
2	40,3% (210)	51% (50)	37,9% (160)	
3	8,1% (42)	13,3% (13)	6,9% (29)	
Calcium in basal septum				0,024
0	84,2% (438)	75,5% (74)	86,2% (364)	
1	15,6% (81)	24,5% (24)	13,5% (57)	
Calcium in LVOT				0,21
0	69,2% (360)	62,2% (61)	70,8% (299)	
1	30,5% (159)	37,7% (37)	28,9% (122)	
MSL (mm)				
diastole (dMSL)	8,7 ± 2,44	7,3 ± 1,98	9,3± 2,06	<0,001
systole (sMSL)	8 ± 2,01	6,3 ± 2,16	8,2 ± 1,99	<0,001
Aortic arch calcification	6,3% (33)	6,1% (6)	6,4% (27)	0,922
Intraprocedural features				
Annulus diameter used for TAVI selection	23,1 ± 2,36	23,8 ± 2,13	22,9 ± 2,39	0,001
Access site				0,702
transfemoral	93,1% (484)	91,8% (90)	93,3% (394)	
transaortique	0,9% (5)	1% (1)	0,9% (4)	
transapical	0,6% (3)	0,0% (0)	0,7% (3)	
carotid	5,4% (28)	7,1% (7)	4,9% (21)	
Procedure location				0,729
catheterization lab	88,4% (460)	85,7% (84)	89,1% (376)	
hybrid catheterization lab	4,6% (24)	6,1% (6)	4,2% (18)	
cardiac surgery operating room	6,7% (35)	8,1% (8)	6,4% (27)	
Valve size (mm)				0,004
23	20,2% (105)	14,3% (14)	21,5% (91)	
25	4,8% (25)	1% (1)	5,7% (24)	
26	34,2% (178)	30,6% (30)	35,1% (148)	
27	4% (21)	2% (2)	4,5% (19)	

29	30,2% (157)	39,8% (39)	27,9% (118)	
34	6,5% (34)	12,2% (12)	5,2% (22)	
Device type				0,067
EDWARS Sapien III	53,8% (280)	55,1% (54)	53,5% (226)	
COREVALVE	36,3% (189)	41,8% (41)	35,0% (148)	
evolut R	15,9% (83)	23,4% (23)	14,2% (60)	
evolut pro	20,3% (106)	18,3% (18)	20,8% (88)	
ACURATE	8,6% (45)	2% (2)	10,1% (43)	
Neo S	0,9% (5)	0,0% (0)	1,2% (5)	
Neo M	4% (21)	1% (1)	4,7% (20)	
Neo L	3,6% (19)	1% (1)	4,3% (18)	
PORTICO	1% (6)	1% (1)	1,2% (5)	
Transcatheter heart valve nominal area (mm²)	490,5± 100,3	516,1 ± 99,1	484,6 ± 99,6	0,013
Area oversizing (%)	3,2 ± 9	1,5 ± 10	3,6 ± 9	0,15
Pre-dilatation	48,3% (251)	46,9% (46)	48,6% (205)	0,833
Post-dilatation	3,8% (20)	4,1% (4)	3,8% (16)	0,895
ID	5,3 ± 2,9	6,3 ± 3,1	5 ± 2,9	<0,001
Post-procedural features				
Electrocardiogram data :				
Atrial fibrillation/flutter	23,3% (121)	22,4% (22)	23,4% (99)	0,852
PR time interval (ms)	194,5 ± 40,1	225,6 ± 50,4	189,3 ± 35,6	<0,001
QRS time interval (ms)	121,5 ± 27,7	135,9 ± 29,1	119,0 ± 26,7	<0,001
Right bundle branch block	14,4% (75)	35,7% (35)	9,4% (40)	<0,001
Left bundle branch block	37,8% (197)	41,8% (41)	36,9% (156)	0,48
TTE :				
LVEF (%)	58,8 ± 10,2	59,1 ± 9,4	58,7 ± 10,4	0,972
Aortic valve systolic area (cm²)	1,8 ± 0,6	1,9 ± 0,6	1,8 ± 0,6	0,154
Aortic Valve Systolic Mean Gradient	10,9 ± 4,7	10,8 ± 4,6	11 ± 4,7	0,995
Pulmonary artery pressure	39,4 ± 10,8	40,0 ± 12,3	39,31 ± 10,5	0,914
AR				0,37
I	28,1% (146)	22,4% (22)	29,4% (124)	
II	8,6% (45)	6,1% (6)	9,2% (39)	
III	0,9% (5)	1% (1)	0,9% (4)	
IV	0,6% (3)	0,0% (0)	0,7% (3)	
Regurgitation localization				0,835
Peri-prosthetic AR	34,8% (181)	36,7% (36)	34,3% (145)	
Central-prosthetic AR	0,1% (1)	0,0% (0)	0,2% (1)	
Peri and central-prosthetic AR	0,4% (2)	0,0% (0)	0,5% (2)	
MR				0,455
I	26,5% (138)	20,4% (20)	27,9% (118)	
II	6,5% (34)	5,1% (5)	6,9% (29)	
III	0,3% (2)	0,0% (0)	0,4% (2)	
IV	0,6% (3)	0,0% (0)	0,7% (3)	

TABLE 7 : Caractéristique de la population. Les variables continues sont données sous forme d'une moyenne $\pm$ écart type. Les variables catégorielles sous forme de % et (valeur absolue).

Abréviations : AR : Aortic regurgitation, AV : Atrioventricular, BMI : body mass index, CCS : Canadian Cardiovascular Society (Angina Grade), ECG : Electrocardiogram, PCI : percutaneous coronary intervention, CABG : coronary artery bypass grafting, ID : implantation depth, LCC : Left Coronary Cusp, LVEF : left ventricular ejection fraction, LVOT : Left ventricular outflow track, MDCT : multi-detector computed tomography, MSL : Membranous septal length, MR : Mitral regurgitation, NCC : Non-Coronary Cusp, NYHA : New-York Heart Association (heart failure functional classification), RCC : Right Coronary Cusp, sPAP : systolic pulmonary arterial pressure, TTE : transthoracic echocardiograph

Annexe D Ensemble des méthodes de préparation des données pour l'apprentissage

D.1 Prise en compte des valeurs extrêmes

On appelle valeur extrême toute observation d'une variable différant grandement des autres observations de la même variable. Certains algorithmes de ML sont sensibles à ce type de données. En effet, de telles valeurs peuvent biaiser la construction des modèles. Il existe plusieurs manières de traiter les valeurs extrêmes. Dans notre travail, nous avons considéré deux traitements possibles de ces données :

- Pas de traitement des données extrêmes ;
- Troncature au dessus d'un certain seuil (Figure 19), défini à partir du Z-score (standardisation). On supprime alors de notre jeu de données les valeurs dont la valeur absolue est supérieur ou égale à la valeur absolue de 3 déviations standards. Le Z-score est calculé en soustrayant la moyenne et en divisant par l'écart-type.




FIGURE 19 : Procédure de suppression des valeurs extrêmes (outliers) à partir du Z-score⁵.

D.2 Prise en compte des données manquantes

Certains algorithmes étant également sensibles aux données manquantes, pour faire face à cette problématique, nous avons utilisé et comparé quatre approches :

- Remplacement par la valeur de la moyenne ;
- Remplacement par la valeur de la médiane ;
- Remplacement par la valeur du mode (valeur la plus fréquente) ;
- Imputation par k plus proches voisins ($kNN - k$ nearest neighbors), i.e., remplacement des valeurs manquantes par la moyenne des valeurs des k plus proches voisins.

D.3 Normalisation et encodage

La normalisation est une étape de pré-traitement qui permet de changer l'échelle des variables numériques. Cette étape permet de redimensionner les variables numériques pour qu'elles soient comparables sur une échelle commune. Elle permet ainsi d'éviter la contribution plus importante de variables

⁵Source : <https://www.analyticsvidhya.com/blog/2022/08/dealing-with-outliers-using-the-z-score-method/>.

simplement en raison d’une distribution plus large dans l’entraînement des modèles. Nous avons considéré les approches suivantes :

- Pas de normalisation des données ;
- Standardisation des données : cette technique consiste à ramener pour chaque variable la moyenne à 0 et l’écart-type à 1 et rendre ainsi normale la distribution de nos variables. Pour ce faire, on soustrait pour chaque valeur de la variable la moyenne du *training set*, puis on divise le résultat par l’écart-type du *training set* ;
- Normalisation par MinMax : cette technique consiste à soustraire le minimum, puis diviser par la soustraction du maximum et du minimum, afin de placer les valeurs entre 0 et 1. Ainsi la valeur minimale sera de 0, la maximale de 1, et les écarts entre les valeurs normalisées resteront proportionnels à leurs valeurs d’origine.

Comme certains algorithmes de ML ne peuvent pas traiter les variables catégorielles, nous avons utilisé la méthode du *one-hot encoding*, qui transforme chaque valeur de caractéristique catégorielle en une valeur binaire, c’est-à-dire que nous créons un nombre de nouvelles variables binaires égal au nombre de catégories possibles de la variable catégorielle initiale.

D.4 Prise en compte du caractère déséquilibré de la cible

Dans notre *dataset*, la cible principale de prédiction (IPM) est survenue chez 18.8% des patients. Notre ensemble de données est donc déséquilibré par rapport à la cible de prédiction. Le déséquilibre des classes est un problème courant en apprentissage automatique, en particulier en classification binaire. Les modèles de ML visent généralement à minimiser l’erreur de prédiction et donc à maximiser l’*accuracy* (voir [Annexe A](#) pour plus de détails sur les métriques utilisées). Dans le cas de données déséquilibrées, la prédiction systématique de la classe majoritaire maximisera l’*accuracy*, ce qui nous donnera une fausse impression de la qualité de prédiction de notre modèle.

Pour faire face à cela, nous avons d’abord analysé plusieurs métriques d’évaluation autres que l’*accuracy*, puis nous avons utilisé et comparé des techniques de ré-échantillonnage :

- Pas de prise en compte du caractère déséquilibré des classes ;
- Sur-échantillonnage aléatoire (ROS – *random oversampling*), qui duplique aléatoirement des éléments de la classe minoritaire pour équilibrer le jeu de données ;
- Sur-échantillonnage synthétique (SMOTE^[44] – *Synthetic minority oversampling technique*), qui fonctionne en sélectionnant des exemples (de la même classe) qui sont similaires, et génère un nouvel exemple entre eux par interpolation.

Quelle que soit la technique utilisée (ROS ou SMOTE) le rééquilibrage est effectué seulement sur le *training set*. Les autres *datasets* quand à eux sont laissés déséquilibrés car leur répartition est inconnue dans un contexte d’application réelle.

D.5 Sélection de variables

La sélection de variables est le processus qui permet d'évaluer la pertinence des variables dans la prédiction des résultats. Cette étape est cruciale pour améliorer l'apprentissage automatique en sélectionnant les variables les plus importantes et en éliminant les variables redondantes et non pertinentes pour prédire avec précision la variable cible.

Nous avons choisi d'implémenter l'élimination récursive des variables (RFE – *recursive feature elimination*). Cette technique sélectionne récursivement des ensembles de plus en plus petits de variables. À chaque itération, nous entraînons notre modèle sur un ensemble de données de plus en plus petit, en commençant par l'ensemble du *training set*, puis nous estimons l'importance de nos variables pour éliminer la ou les moins importantes. Nous itérons jusqu'à ce qu'à atteindre une seule variable et évaluons la performance de notre modèle à chaque étape. Ainsi nous pouvons choisir les variables les plus pertinentes et leur nombre en fonction des performances de prédictions du modèle.

Nous avons comparé plusieurs techniques d'évaluation de l'importance de nos variables afin d'identifier lors des itérations de la RFE les variables les moins pertinentes :

- Sélection de caractéristiques statistiquement significatives (en débutant avec $p < 0.05$);
- Sélection par MRMR^[29];
- Sélection par SHAP^[32].

Annexe E Préparation des données pour l'apprentissage

Ré-échantionnage	Valeurs aberrantes	Normalisation	Données manquantes
ROS	Oui	Standard	Moyenne
ROS	Oui	Standard	Médiane
ROS	Oui	Standard	Mode
ROS	Oui	Standard	k NN
ROS	Oui	MinMax	Moyenne
ROS	Oui	MinMax	Médiane
ROS	Oui	MinMax	Mode
ROS	Oui	MinMax	k NN
ROS	Oui	-	Moyenne
ROS	Oui	-	Médiane
ROS	Oui	-	Mode
ROS	Oui	-	k NN
ROS	-	Standard	Moyenne
ROS	-	Standard	Médiane
ROS	-	Standard	Mode
ROS	-	Standard	k NN
ROS	-	MinMax	Moyenne
ROS	-	MinMax	Médiane
ROS	-	MinMax	Mode
ROS	-	MinMax	k NN
ROS	-	-	Moyenne
ROS	-	-	Médiane
ROS	-	-	Mode
ROS	-	-	k NN
SMOTE	Oui	Standard	Moyenne
SMOTE	Oui	Standard	Médiane
SMOTE	Oui	Standard	Mode
SMOTE	Oui	Standard	k NN
SMOTE	Oui	MinMax	Moyenne
SMOTE	Oui	MinMax	Médiane
SMOTE	Oui	MinMax	Mode
SMOTE	Oui	MinMax	k NN
SMOTE	Oui	-	Moyenne
SMOTE	Oui	-	Médiane
SMOTE	Oui	-	Mode
SMOTE	Oui	-	k NN
SMOTE	-	Standard	Moyenne

SMOTE	-	Standard	Médiane
SMOTE	-	Standard	Mode
SMOTE	-	Standard	k NN
SMOTE	-	MinMax	Moyenne
SMOTE	-	MinMax	Médiane
SMOTE	-	MinMax	Mode
SMOTE	-	MinMax	k NN
SMOTE	-	-	Moyenne
SMOTE	-	-	Médiane
SMOTE	-	-	Mode
SMOTE	-	-	k NN
-	Oui	Standard	Moyenne
-	Oui	Standard	Médiane
-	Oui	Standard	Mode
-	Oui	Standard	k NN
-	Oui	MinMax	Moyenne
-	Oui	MinMax	Médiane
-	Oui	MinMax	Mode
-	Oui	MinMax	k NN
-	Oui	-	Moyenne
-	Oui	-	Médiane
-	Oui	-	Mode
-	Oui	-	k NN
-	-	Standard	Moyenne
-	-	Standard	Médiane
-	-	Standard	Mode
-	-	Standard	k NN
-	-	MinMax	Moyenne
-	-	MinMax	Médiane
-	-	MinMax	Mode
-	-	MinMax	k NN
-	-	-	Moyenne
-	-	-	Médiane
-	-	-	Mode
-	-	-	k NN

TABLE 8 : Ensemble des configurations possibles de traitements sur les données. Dans cette table, un "-" dénote l'absence du traitement correspondant.

Annexe F Analyse des variables sélectionnées suite aux entraînements sur chaque modalité de variables.




FIGURE 20 : Importance des variables sélectionnées avec RFE + SHAP par le SVM entraîné successivement sur chaque modalité de variables. En bleu les variables dont la diminution de la valeur augmente la prédiction, et en rouge celles dont l'augmentation de la valeur augmente la prédiction.

Annexe G Variabilité histologique du septum membraneux




FIGURE 21 : Variation positionnelle du septum membraneux (SM) en anatomopathologie⁶. (A) SM rectiligne; (B) SM incurvé (acronymes dans l'image — RV : ventricule droit; TV : valve tricuspide; AVB : noeud atrio-ventriculaire; RA : oreillette droite; MS : septum membraneux; LV : ventricule gauche; RC : cusp coronaire droite; VS : septum inter ventriculaire).

⁶Source : Kawashima *et al.* [45]

Annexe H Découvertes fortuites sur les TDM




FIGURE 22 : Découvertes fortuites sur les scanners TDM (520 patients). (A) Vasculaires ; (B) Tumorales suspectes ; (C) Autres.

Annexe I Analyse à 18 mois des Holter implantables




FIGURE 23 : Évolution à 18 mois des 25 patients ayant été implantés d’un Holter ECG avant la sortie d’hospitalisation

Annexe J Prédiction des AVC en post TAVI




FIGURE 24 : Performance de notre modèle pour prédire l'AVC en post-TAVI : (a) courbe AUC-ROC, (b) courbe précision-rappel, (c) Importance des variables sélectionnées avec RFE + SHAP par le SVM entraîné à prédire la survenue d'un AVC en post TAVI. En bleu les variables dont la diminution de la valeur augmente la prédiction, et en rouge celles dont l'augmentation de la valeur augmente la prédiction.



IMPRIME 4 – AUTORISATION D'IMPRIMER

THESE DE DOCTORAT EN MEDECINE

INTERNE

Monsieur Amine EL OUAHIDI
Inscrit-e en DES de Médecine Cardiovasculaire

Titre définitif de la thèse soutenue :

Utilisation de méthodes d'apprentissage automatique pour prédire l'implantation d'un pacemaker dans les suites d'une procédure de TAVI

ACCORD DU PRESIDENT DU JURY DE THESE SUR L'IMPRESSION DE LA THESE

OUI : ☒

NON : ☐

La présente autorisation d'imprimer sa thèse est délivrée à l'interne susmentionné.

Brest, le 30/08/2023v

Le Président du jury de thèse

La Directrice de l'UFR de médecine et des

sciences de la santé de Brest

Béatrice COCHENER-LAMARD

