



Université RENNES 1
Master 2 mention Biologie – Santé
Parcours Neurosciences Cliniques

Hybrid machine learning approach to evaluate the prognosis of spontaneous cerebral hemorrhages on the population-based Brest Stroke Registry

QUERE Victor

Département « Logique des Usages des Sciences Sociales et de l'Information »
UMR 6285 Lab-STICC, pôle CID, Équipe DECIDE
IMT Atlantique Bretagne-Pays de la Loire, campus de Brest, France

Encadrement :

Professeur Philippe LENCA, Habilité à Diriger des Recherches et responsable du département LUSI

Docteur Sorin MOGA, Enseignant-chercheur au département LUSI

Professeur Serge TIMSIT, Habilité à Diriger des Recherches, Chef de service de neurologie du CHRU de Brest, et Directeur scientifique du Registre des AVC du Pays de Brest

Mémoire présenté le 02/09/2020

Remerciements

A Monsieur le Professeur Philippe LENCA,

Pour avoir accepté de diriger ce mémoire et m'avoir donné l'opportunité de découvrir la science des données, pour vos conseils et votre bienveillance. En espérant d'autres projets à venir.

A Monsieur le Professeur Serge TIMSIT,

Pour m'avoir soutenu dès le départ dans mon projet de Master 2, pour vos conseils et votre disponibilité tout au long de celui-ci. J'ai découvert un domaine passionnant que j'aurai plaisir à développer dans les années futures.

A Monsieur le Docteur Sorin MOGA,

Pour le partage de votre expérience et vos explications. Pour votre présence tout au long de ce projet qui m'aura permis de progresser à chacun de nos échanges.

A Monsieur le Docteur Bastien PASDELOUP,

Pour ton dynamisme, ton expertise et ta disponibilité. Tu as répondu présent pour m'aider à chacune de mes interrogations malgré les conditions sanitaires difficiles... Merci encore !

A l'équipe du département LUSSI,

Dont je garderai de très bons souvenirs.

A l'équipe de neurologie du CHRU de Brest,

Pour votre soutien et votre amitié.

A tous les patients dont les données ont été recueillies,

Qui permettent ce travail.

A ma promotion de Master 2,

De belles rencontres, à bientôt j'espère !

A mes parents, ma sœur et mon amie Manon,

Pour votre amour (et votre patience) !

Table des matières

1. Description de l'équipe de recherche et de ses thématiques et contexte de l'étude au sein du laboratoire de recherche	4
2. Rôle tenu par l'étudiant	5
3. Déclaration de non plagiat	5
4. Résumé scientifique	6
5. Abstract	7
6. Liste des abréviations	9
7. Introduction	10
8. Matériels et méthodes	11
8.1 Données	11
8.1.1 Population étudiée	11
8.1.2 Variables recueillies	12
8.2 Modélisation	13
8.2.1 Traitement des données manquantes	13
8.2.2 Arbre de décision	13
8.2.3 Algorithme de K-moyennes	14
8.2.4 Machine à Vecteur de Support	15
8.2.5 Sélection des hyperparamètres et évaluation des résultats	16
9. Résultats	17
9.1 Caractéristiques de la cohorte étudiée	17
9.2 Traitement des données manquantes	17
9.3 Sélection de variable par un arbre de décision	18
9.4 Clustering par algorithme de K-moyennes	18
9.5 Classification par SVM et analyse des résultats	19
10. Discussion	20
11. Conclusion	22
12. Bibliographie	23

1. Description de l'équipe de recherche et de ses thématiques et contexte de l'étude au sein du laboratoire de recherche

L'établissement scolaire IMT Atlantique de Brest héberge au sein du département Logistique des Usages, des Sciences Sociales et de l'Information (LUSSI) plusieurs équipes de recherche. Dans le cadre de ce master, j'ai travaillé avec l'équipe DECIDE, subdivision du pôle Connaissances, Information, Décision (CID) du laboratoire des Sciences et Techniques de l'Information, de la Communication et de la Connaissance (Lab-STICC UMR 6285).

Cette équipe pluridisciplinaire, au carrefour des Mathématiques, de l'Informatique et des Sciences Humaines, est spécialisée dans la création d'outils d'aide à la décision prenant en compte des données complexes et hétérogènes.

Le développement d'un outil d'aide à la décision performant est un challenge. Il ne se résume pas à préconiser des décisions adaptées et cohérentes au besoin de l'utilisateur. En effet, il doit aussi permettre l'identification, la modélisation et la compréhension des informations extraites à partir des données. De même, dans un souci de transparence et de qualité, essentielles au domaine médical, les modélisations doivent détailler au mieux chacune des étapes d'une décision afin que celles-ci restent toujours compréhensibles et justifiables. Enfin, il faut identifier les potentielles zones d'incertitude pour lesquelles il faudra trouver un compromis acceptable à l'ensemble des utilisateurs.

Pour cela, l'équipe DECIDE travaille autour de 4 axes principaux qui sont : l'exploration de données, l'intégration de l'information et sa qualité, l'ingénierie des supports de décision et l'aide à la décision.

Dans le cadre de ce Master 2, je me suis intéressé à l'étude des données du registre populationnel des AVC du Pays de Brest sous la co-direction des professeurs LENCA et TIMSIT, respectivement responsable du département LUSSI et chef de service de neurologie au CHRU de Brest. L'objectif de cette coopération entre nos deux établissements était de proposer une approche centrée sur la science des données afin d'explorer, d'analyser puis de développer un outil pronostic de la mortalité à 30 jours des patients victimes d'hémorragies intra-cérébrales spontanées.

2. Rôle tenu par l'étudiant

- Définition de la question scientifique : oui
- Recherche bibliographique : oui
- Choix de la méthodologie : oui
- Mise au point de la méthodologie : oui
- Programmation de l'expérience ou du modèle : oui
- Recrutement des sujets : non
- Test des sujets : non
- Recueil, dépouillement, codage des données : non
- Analyse statistique des données : oui
- Interprétation des résultats : oui

3. Déclaration de non plagiat

Je soussigné Victor QUERE déclare être pleinement conscient que le plagiat de documents ou d'une partie d'un document publié sur toutes formes de support, y compris l'internet, constitue une violation des droits d'auteur ainsi qu'une fraude caractérisée. En conséquence, je m'engage à citer toutes les sources que j'ai utilisées pour écrire ce mémoire.



Victor QUERE

4. Résumé scientifique

Title : Hybrid machine learning approach to evaluate the prognosis of spontaneous intracerebral hemorrhages on the population-based Brest Stroke Registry

Author : Victor QUERE ¹, Philippe LENCA ¹, Serge TIMSIT ², Sorin MOGA ¹, Bastien PASDELOUP ¹

Author's affiliation :

¹ IMT Atlantique, Lab-STICC, UMR CNRS 6285, F-29238, Brest, France

² Department of neurology and neurovascular unit, Brest University Hospital, France

Wordcount :

Abstract : 400 words

Main text : 4929 words (excluding legends and references)

Keywords : Spontaneous intracerebral hemorrhages, prognosis, decision tree, clustering, support vector machine

5. **Abstract :**

Background : Spontaneous Intracerebral Hemorrhages (SICH) account for one to two million cases per year worldwide with a severe prognosis and without any specific therapy having shown benefits. Prognostic tools are useful to facilitate streamline assessment, communication between providers and may contribute to the emergence of new therapeutic studies. Current tools lack of transparency, precision and do not take into account missing data. However, there are solutions using machine learning that meet these criteria. Consequently, the objective of this study was, without excluding missing data, to develop a powerful machine learning model which efficiently describes each step of the decision, while remaining interpretable.

Methods : We worked on data from the population-based Brest Stroke Registry from 2008 to 2017. Demographic, related to medical history, clinic, laboratory and imaging data were considered as interesting variables to assess mortality at 30 days. Missing data were imputed either by a one-hot method or the median of observations. We performed variables selection using mean decrease in Gini from a classification and regression tree (CART). Then, after dividing the data into training and testing sets, we performed a clustering using a K-means algorithm. Finally, we trained and optimized a support vector machine (SVM) for each cluster. The overall model was evaluated using the area under the ROC curve (AUC), accuracy, recall and F1 score.

Results : The data of 1077 validated cases of SICH, were included. 18 variables were analyzed. Of these, eight (SICH volume, glucose, history of RANKIN score, age, Glasgow score, NIHSS, systolic and diastolic blood pressure) were selected using a CART. In addition to Glasgow score and SICH volume, NIHSS and glucose were found to be informative. According to the results of elbow method, data were divided into four groups during the clustering step. Among the clusters, two had characteristics not yet described in the literature. After training the SVMs, the overall AUC of the model was 0.75, the accuracy 0.74, the recall 0.81 and the F1 score 0.77.

Conclusions : We have developed, without excluding missing data, an easily explainable machine learning model to predict 30-day mortality from SICH. Preliminary results showed that high NIHSS and glucose appear to be linked to poor prognosis. Moreover, we described a group of patients with high blood pressure on which it would be interesting to

conduct therapeutic studies. Although comparison was not possible, the overall performance appears to be inferior to the previous models.

6. Liste des abréviations

AUC : Area Under the Curve ou aire sous la courbe de ROC
ARS : Agence Régionale de Santé
AVC : Accident Vasculaire Cérébral
CART : Classification And Regression Tree ou Arbre de décision
CH : Centre Hospitalier
CHRU : Centre Hospitalier Régional Universitaire
CV : Cross Validation ou Validation croisée
GCS : Glasgow Coma Scale ou Score de Glasgow
HIA : Hôpital d'Instruction des Armées
HIC : Hémorragie Intra-Cérébrale
HTA : Hypertension Artérielle
KM : K-Moyennes
MAV : Malformation Artério-Veineuse
MDG : Mean Decrease in Gini ou Décroissance moyenne du Gini
OCSF : Oxford Community Stroke Project
PAD : Pression Artérielle Diastolique
PAS : Pression Artérielle Systolique
PMSI : Programme de Médicalisation des Systèmes d'Information
Se : Sensibilité
SSE : Sum of Squared Errors ou Somme des Erreurs Quadratiques
SVM : Support Vector Machine ou Machine à Vecteur de Support
TVC : Thrombose Veineuse Cérébrale
VPP : Valeur Prédictive Positive

7. Introduction

Les Hémorragies Intra-Cérébrales (HIC) sont une cause majeure de décès et de handicap à travers le monde. Leur incidence est évaluée à 24,6 pour 100 000 personnes-années dont 40% d'issues fatales, particulièrement à la phase aiguë avec 50% des décès survenant dans les deux premiers jours. Après un tel événement, on estime qu'entre 12 et 39% des patients retrouvent une autonomie ([van Asch, 2010](#)). En comparaison aux accidents vasculaires cérébraux (AVC) ischémiques, les soins prodigués sont principalement des soins de support et des incertitudes demeurent sur l'attitude à adopter dans bon nombre de situations ([Steiner, 2014](#) ; [Hemphill, 2015](#)).

C'est dans ce contexte qu'il est apparu nécessaire de développer des outils pronostics afin de guider les cliniciens dans leurs décisions thérapeutiques. En exploitant les résultats de plusieurs études épidémiologiques mettant en valeur les facteurs prédictifs d'intérêt, des outils ont d'abord été proposés sous la forme de scores, dérivés d'équations de régression logistique. On retiendra par exemple le populaire score ICH ([Hemphill, 2001](#)) qui utilise le score de Glasgow, le volume de l'hématome, la présence d'une hémorragie intra-ventriculaire, l'origine sous-tentorielle et l'âge du patient pour déterminer le pronostic. Or, ces méthodes statistiques traditionnelles nécessitent l'utilisation de variables indépendantes, ce caractère indépendant étant sans doute à l'origine d'un manque de performance ([Hilbe, 2009](#)). En effet, certaines variables dépendantes éliminées pourraient contenir des informations permettant d'évaluer le pronostic ou aider à la décision. Par ailleurs, l'amélioration d'un score peut être évaluée par d'autres critères tels que l'interprétabilité, l'utilisation de données facilement accessibles ou encore l'utilisation d'un modèle explicable.

C'est la raison pour laquelle on a vu l'essor, dès la fin des années 1990 d'outils pronostics utilisant des algorithmes d'intelligence artificielle ([Edwards, 1999](#)). Depuis cette étude princeps, on observe un intérêt grandissant concernant l'application des algorithmes d'apprentissage automatique pour prédire l'issue d'un hématome intra-cérébral spontané à la phase initiale. On compte déjà 7 études sur le sujet qui, lorsque la comparaison est effectuée, concluent à la supériorité de ces méthodes innovantes face aux équations de régression logistique ([Flemming, 2001](#) ; [Takahashi, 2006](#) ; [Peng, 2010](#) ; [Lukić, 2012](#) ; [Çelik, 2014](#) ; [Chiu, 2016](#)). Or, comme on peut s'en apercevoir dans les derniers travaux de méta-analyse réalisées ([Gregório, 2018](#)), dont l'objectif était de recenser et comparer les outils pronostics en matière d'HIC spontanée jusqu'en 2016, il persiste des défauts importants aux modèles proposés.

En effet, malgré l'amélioration de la précision des outils, on déplore une compréhension difficile des informations extraites des données et le manque de transparence des étapes algorithmiques menant à la décision. D'autre part, en dépit de l'existence de méthodes informatiques pour traiter les données manquantes et de la capacité de certains algorithmes à travailler sur des bases de données incomplètes, les articles précédents ont en grande majorité opté pour l'élimination des observations à données manquantes. Pourtant, il est possible que l'absence de ces données ne soit pas liée au hasard et ignorer les observations à données manquantes serait alors à l'origine d'un biais d'attrition (Vickers, 2013).

La méthodologie proposée par l'équipe de Chiu H et al. (2016) a pour avantage d'exploiter des algorithmes simples d'utilisation, facilement compréhensibles et de décrire clairement les étapes de la décision (Chiu, 2016). Elle associe une sélection de variables par un arbre de décision, suivie par la création de groupes de patients grâce à un algorithme de K-moyennes (KM) et enfin une classification à l'aide d'une machine à vecteur de support (SVM) par groupe. De plus, cette méthode avait montré une excellente précision de 95,23% qui était alors supérieure aux autres modèles testés. Pour autant, le faible nombre de patients inclus amenait à tester ces résultats sur de plus grands échantillons.

Fort d'une importante base clinique et para-clinique grâce au registre populationnel des AVC du Pays de Brest (Timsit, 2014), nous proposons ici un travail dont l'objectif principal sera, en nous inspirant de la méthode décrite par l'équipe de Chiu H et al., de développer un outil pronostic précis et décrivant bien les étapes de la décision, sans exclure les observations à données manquantes. Notre hypothèse est qu'il est possible de développer un modèle performant et facilement explicable à partir d'algorithmes d'apprentissage automatique sans exclure les observations à données manquantes.

8. Matériels et méthodes

8.1 Données

8.1.1 Population étudiée

La cohorte de notre étude est issue du registre populationnel du Pays de Brest débuté en 2008. Il couvre l'ensemble des 360 000 résidents dans le Pays de Brest à l'exclusion de la Communauté de Communes de la Presqu'île de Crozon-Aulne Maritime. Afin d'obtenir un registre exhaustif, 5 sources de données ont été sélectionnées : les services des urgences du

Centre Hospitalier Régional Universitaire (CHRU) de la Cavale Blanche, du CH (Centre Hospitalier) de Landerneau et de l'HIA (Hôpital d'Instruction des Armées), les médecins généralistes et neurologues libéraux, les radiologues libéraux, l'ARS (Agence Régionale de Santé) via les certificats de décès et la base de données informatiques hospitalières dite PMSI (Programme de Médicalisation des Systèmes d'Information) avec les codes 430, 434 et 436, conformément à la neuvième Classification Internationale des Maladies. Tous les patients de ce fichier ont été victimes d'un AVC selon une définition stricte vérifiée pour chaque cas par un comité de validation composé de neurologues du CHRU de Brest, spécialisés en neurologie vasculaire.

Ont été inclus dans notre étude les patients adultes victimes d'un AVC hémorragique, comme défini par l'Oxford Community Stroke Project (OCSP) ([Bamford, 1990](#)) et confirmé par une imagerie cérébrale entre le 1^{er} janvier 2008 et le 31 décembre 2017. Les critères d'exclusion étaient : les HIC d'origine traumatique, en lien avec une MAV (malformation artério-veineuse), un cavernome, un anévrisme intra-cérébral, une TVC (thrombose veineuse cérébrale), une tumeur et dans un contexte post-chirurgical.

8.1.2 Variables recueillies

L'ensemble des 18 variables utilisées étaient disponibles au moment de l'évaluation initiale du patient.

Des données d'interrogatoire : antécédent de diabète, antécédent de dyslipidémie, antécédent d'hypertension artérielle (HTA), antécédent de maladie athéromateuse (artériopathie oblitérante des membres inférieurs, sténose carotidienne opérée, coronaropathie), antécédent de score de RANKIN, âge, sexe, traitement par antiagrégant plaquettaire à l'entrée, traitement par anticoagulant à l'entrée (anti-vitamine K, héparine ou nouveaux anticoagulants), traitement par anti-hypertenseur à l'entrée et traitement par statine à l'entrée.

Des données d'imagerie : localisation profonde, lobaire ou sous-tentorielle de l'AVC et volume de l'AVC en ml.

Des données clinico-biologiques : pression artérielle systolique (PAS), pression artérielle diastolique (PAD), score NIHSS, score de Glasgow (GCS) et glycémie en g/L.

Le volume de l'HIC a été déterminé sur la première imagerie réalisée à l'aide de la méthode ABC/2, A étant le plus grand diamètre de l'hématome, B le diamètre orthogonal à A et C le nombre de coupe axiale multiplié par l'épaisseur de chaque coupe ([Broderick J P, 1993](#)).

8.2 Modélisation

Pour plus de clarté, chaque étape a été schématisée sur la **figure 1**.

8.2.1 Traitement des données manquantes

Nous avons choisi de travailler avec les données manquantes afin de ne pas risquer d'introduire un biais d'attrition. En effet, nous avons émis l'hypothèse qu'il s'agissait de données manquantes de façon non aléatoire. C'est-à-dire que la probabilité d'absence d'une valeur serait en lien avec d'autres variables observées ou non. Afin de chercher des corrélations entre le taux de données manquantes et les variables de notre jeu de données, nous avons effectué des représentations graphiques des données absentes sous forme de carte thermique pour chacune des variables disponibles.

Concernant les méthodes d'imputation, celles-ci étaient différentes en fonction du type de variable.


Pour les variables qualitatives, nous avons opté pour un encodage « un parmi n » (dit encodage « *one-hot* ») en ajoutant une modalité « variable manquante ». Cette méthode permet de traiter les données sous forme vectorielle en créant automatiquement un vecteur de valeur binaire et de dimensions égales au nombre de modalités de la variable encodée. Bien que cette technique augmente le nombre de dimensions du jeu de données, en créant un nombre de variables égal au nombre de modalités de la donnée qualitative encodée, elle permet d'inclure les valeurs manquantes dans l'analyse pour potentiellement en tirer des informations dans le cas de valeurs manquantes de façon non aléatoire ([VanderPlas, 2016](#)).

Pour les variables quantitatives discrètes et continues, les valeurs manquantes ont été remplacées par la médiane des observations. Contrairement à la moyenne, la médiane permet de s'affranchir de l'influence des valeurs extrêmes et s'avère donc préférable à celle-ci.

8.2.2 Arbre de décision

Afin de sélectionner les variables les plus informatives concernant le pronostic, nous avons utilisé les résultats d'un arbre de décision (CART). Le code a été écrit et testé sur le logiciel Spider version 4.0.1 en langage python version 3.7.6. La fonction `DecisionTreeClassifier` de la librairie `scikit-learn` version 0.22.1 a été utilisée. Lien vers le code

Figure 1. *Etapes de la modélisation*



*CV : cross validation. ¹Sélection de variables en fonction de la décroissance moyenne du GINI dans l'arbre de décision. ²Séparation des données en échantillons d'entraînement (80%) et de test (20%). ³Clustering des données d'entraînement par K-moyennes puis application aux données de test. ⁴Optimisation d'un SVM par cluster par k-fold cross validation. ⁵Test des SVM sur les données de test.

source: <https://github.com/VictorQuere/Hybrid-machine-learning-approach-for-the-prognosis-of-SICH-on-the-Brest-Stroke-Registry>).

Il s'agit d'un algorithme d'apprentissage supervisé utilisé pour la classification et la régression. Son caractère non paramétrique, sa capacité à travailler avec des variables de tous types sans hypothèse de distribution, sa simplicité d'interprétation et de visualisation en font un modèle intuitif. Il consiste à construire un arbre binaire en utilisant la variable (et la valeur seuil de celle-ci pour les données quantitatives) qui permet d'optimiser l'homogénéité des sous-ensembles créés par la division d'un l'ensemble à chaque nœud. Le critère de segmentation utilisé dans notre étude est l'indice de Gini. Il correspond à la somme de la probabilité pour chaque observation d'être sélectionnée, multipliée par la probabilité qu'elle soit mal classée. L'indice de Gini va ainsi estimer l'impureté du sous-ensemble créé, un indice de zéro traduisant une impureté minimale et un indice de un (théorique car non atteignable) une impureté maximale. Afin de diminuer les dimensions de notre jeu de données, nous avons donc retenu les variables dont la décroissance moyenne du Gini (MDG) était la plus élevée. La MDG correspond à la moyenne de diminution d'impureté d'une variable à chaque nœud, pondérée par la proportion de la population passant par ces nœuds. Ainsi, plus la MDG augmente, plus la capacité d'une variable à diminuer l'impureté au sein de l'arbre est grande (Breiman, 1984).

Avant de poursuivre nos analyses, les données ont été séparées en un échantillon d'entraînement (80%) et un échantillon de test (20%).

8.2.3 Algorithme de K-moyennes

Sur les données d'entraînement, nous avons ensuite effectué un clustering à partir d'un algorithme de KM. L'objectif était de former des groupes de patients au sein des données pour ensuite les traiter séparément lors de la dernière étape. En plus de possiblement améliorer la précision de la classification finale, le résultat de cette phase permet une analyse exploratoire des données avec de potentielles pistes d'analyses ultérieures. Le code a été écrit et testé sur le logiciel Spider version 4.0.1 en langage python version 3.7.6, la fonction KMeans de la librairie scikit-learn version 0.22.1 a été utilisée. Lien vers le code source: <https://github.com/VictorQuere/Hybrid-machine-learning-approach-for-the-prognosis-of-SICH-on-the-Brest-Stroke-Registry>).

Le KM est un algorithme non supervisé qui permet le partitionnement automatique des données. L'hyperparamètre principal à renseigner est le nombre de clusters désiré.

L'algorithme va ensuite placer un nombre équivalent de points (appelés centroïdes) au sein des données. Un cluster va être attribué à chaque observation en fonction du centroïde le plus proche. Par itération, l'algorithme va progressivement déplacer le centroïde attribué à chaque cluster pour minimiser la somme des carrés des distances de chaque observation à celui-ci (Arthur, 2007).

Dans notre étude, nous avons déterminé le nombre optimal de cluster (k) grâce à la méthode du coude. Il s'agit de représenter, sur un graphique linéaire, la somme des erreurs quadratiques (SSE) pour chaque valeur de k . La SSE va naturellement diminuer avec l'augmentation de k jusqu'à ce que chaque observation soit superposée à son propre centroïde. On cherche donc sur le graphique la zone du coude qui correspond à une petite valeur de SSE et à partir de laquelle on obtient des rendements décroissants en augmentant k (Yuan, 2019).

Enfin, avant toute analyse, les données ont été standardisées (pour les centrer sur zéro et imposer une variance de un) afin de permettre un fonctionnement optimal de l'analyse. L'algorithme de KM ainsi paramétré sur les données d'entraînement, nous avons partitionné à leur tour les données de test selon les mêmes modalités.

8.2.4 Machine à Vecteur de Support

Sur chaque cluster, nous avons finalement optimisé puis testé un algorithme de SVM utilisant une fonction noyau de base radiale (dit « *RBF kernel* ») afin de classer les patients décédés ou non à 30 jours. Le code a été écrit et testé sur le logiciel Spider version 4.0.1 en langage python version 3.7.6. La fonction SVC de la librairie scikit-learn version 0.22.1 a été utilisée. Lien vers le code source: <https://github.com/VictorQuere/Hybrid-machine-learning-approach-for-the-prognosis-of-SICH-on-the-Brest-Stroke-Registry>).

L'algorithme de SVM repose sur la notion de marge. Elle correspond à la frontière entre deux échantillons dont les plus proches sont nommés vecteurs supports. Le problème de classification revient alors à maximiser la marge en optimisant la frontière de séparation à partir d'échantillons d'entraînement. La plupart du temps, les données n'étant pas linéairement séparables, la SVM va utiliser la technique de l'astuce du noyau. Cela revient à augmenter les dimensions de l'espace de représentation des données à l'aide d'une fonction noyau pour trouver une séparation linéaire entre celles-ci (Scholkopf, 2000).

Les hyperparamètres principaux d'une SVM utilisant une fonction noyau de base radiale sont C et γ . Le paramètre C permet de faire un compromis entre l'optimisation de la

marge et le taux de classifications correctes des données d'entraînement. Par ailleurs, le paramètre gamma va permettre de définir la distance d'influence d'une observation sélectionnée comme vecteur de support. Ainsi, un paramètre C élevé va favoriser la classification correcte aux dépens de l'optimisation de la marge et un paramètre gamma élevé va diminuer le rayon d'influence des observations sélectionnées comme vecteur de support.

8.2.5 Sélection des hyperparamètres et évaluation des résultats

Afin de sélectionner les meilleurs hyperparamètres et de limiter le surapprentissage de nos SVM, nous avons utilisé une validation croisée (CV) à k blocs (dite « *k-fold cross-validation* ») en testant alternativement différentes valeurs pour C et gamma. Le code a été écrit et testé sur le logiciel Spider version 4.0.1 en langage python version 3.7.6. La fonction GridSearchCV de la librairie scikit-learn version 0.22.1 a été utilisée. Lien vers le code source: <https://github.com/VictorQuere/Hybrid-machine-learning-approach-for-the-prognosis-of-SICH-on-the-Brest-Stroke-Registry>).

Le surapprentissage correspond à une fidélité trop importante d'un algorithme d'apprentissage automatique aux données d'entraînement. Il s'agit d'un apprentissage « par cœur » des observations qui va avoir pour conséquence une mauvaise généralisation et donc une altération des pouvoirs de prédiction du modèle. La CV est l'une des méthodes couramment utilisées pour lutter contre les problèmes de surapprentissage (Hawkins, 2004). Celle-ci revient à diviser aléatoirement les données d'entraînement en k échantillons. Un des échantillons est désigné comme l'ensemble de validation et le reste comme ensemble d'apprentissage. La performance du modèle, créé sur l'ensemble d'apprentissage, va ainsi pouvoir être évaluée sur l'ensemble de validation. L'opération va être répétée jusqu'à ce que chacun des k échantillons ait été utilisé comme ensemble de validation. Au final, on obtient k scores de performance dont la moyenne et l'écart type représentent un score global sur les k ensembles de validation. Nous avons donc répété cette méthode, pour des valeurs de C et de gamma entre 10^{-9} et 10^9 , dans l'objectif de sélectionner les hyperparamètres avec les meilleures performances avant l'évaluation finale sur les données de test.

Chaque SVM optimisé dans chaque cluster a finalement été utilisé sur les données de test précédemment partitionnées. En accord avec la littérature sur le sujet, le critère d'évaluation principal était l'aire sous la courbe de ROC (AUC). Par ailleurs, nous avons aussi évalué la

précision (ou valeur prédictive positive), le rappel (ou sensibilité) et la F-mesure (ou F1 score) qui correspond à la moyenne harmonique de la précision et du rappel.

9. Résultats

9.1 Caractéristiques de la cohorte étudiée

Nous avons collecté les données de 1140 patients victimes d'HIC entre 2008 et 2017. Après l'exclusion de 73 patients (20 hémorragies en lien avec une MAV, 14 avec un anévrisme intra-cérébral, 13 avec un cavernome, 12 avec une tumeur, trois hémorragies post-chirurgicales et une avec une TVC), 1077 patients ont finalement été inclus dans notre étude. L'âge moyen était de 76 ans (de 26 à 100 ans) et 43.4% étaient des hommes. 32.3% étaient traités par antiagrégants plaquettaires et 23,1% par anticoagulants. La mortalité globale à 30 jours s'élevait à 40.7%. L'ensemble des autres caractéristiques sont résumées dans la **Table 1**.

Concernant les données manquantes, seuls l'antécédent de score de RANKIN (31%), le score de NIHSS d'entrée (18.6%) et la glycémie (32.5%) comportaient plus de 15% d'observations absentes. Les variables relatives aux traitements d'entrée, à l'âge et au sexe ne comportaient aucune valeur manquante. D'après l'analyse graphique de la répartition des données manquantes en fonction du GCS (**figure 2**), il semble que l'absence de certaines observations soit liée à la sévérité clinique et donc non aléatoire, ce qui justifie l'importance de maintenir ces observations dans l'analyse finale.

9.2 Traitement des données manquantes

18 variables dont huit quantitatives (quatre continues et quatre discrètes) ainsi que dix qualitatives (toutes nominatives) ont été étudiées. Les données manquantes quantitatives ont été remplacées par la médiane des observations afin de limiter l'influence des valeurs extrêmes auxquelles est soumise la moyenne. La médiane était de 79 ans pour l'âge, d'un pour le score de RANKIN, de 89 mmHg pour la PAD, de 192 mmHg pour la PAS, de 1.3 g/L pour la glycémie, de 15 pour le GCS, de 11 pour le score de NIHSS initial et de 15.4 ml pour le volume de l'hémorragie. Les variables qualitatives ont été encodées selon la méthode « un parmi n » ce qui a eu pour effet de générer autant de colonnes que de modalité (en comptant l'ajout d'une modalité « variable manquante ») pour chacune d'entre elles. Pour simplifier le travail algorithmique sans nuire à la qualité de l'information, la première modalité de chaque variable

Table 1. Statistiques descriptives des patients inclus

Variables	Décédés (n = 438)	Vivants (n = 639)	Total (n = 1077)	Données manquantes (%)
Antécédent de diabète (%)	49 (13%)	77 (12.3%)	126 (12.6%)	6.9
Antécédent d'hypertension (%)	257 (65.6%)	388 (37.9%)	645 (36.6%)	5.6
Antécédent de dyslipidémie (%)	131 (35.8%)	214 (35.1%)	345 (35.3%)	9.4
Antécédent de maladie athéromateuse ^a (%)	82 (18.7%)	100 (15.6%)	182 (16.9%)	4.5
Antécédent de score de RANKIN (moyenne $\pm \sigma$)	2.2 $\pm$ 1.6	1.3 $\pm$ 1.5	1.6 $\pm$ 1.6	31
Age en année (moyenne $\pm \sigma$)	79 $\pm$ 10.8	74.3 $\pm$ 12.8	76.2 $\pm$ 12.2	0
Sexe masculin (%)	174 (39.7%)	294 (46%)	468 (43.4%)	0
Traitement par antiagrégant plaquettaire à l'entrée ^b (%)	143 (32.6%)	205 (32.1%)	348 (32.3%)	0
Traitement par anticoagulant à l'entrée ^c (%)	123 (28.1%)	126 (19.7%)	249 (23.1%)	0
Traitement par statine à l'entrée (%)	106 (24.2%)	165 (25.8%)	271 (25.2%)	0
Traitement par anti-hypertenseur à l'entrée (%)	229 (47.7%)	334 (47.7%)	563 (47.7%)	0
Localisation (%)				5.5
Profonde	195 (50.8%)	289 (45.6%)	484 (47.5%)	
Lobaire	133 (34.6%)	276 (43.5%)	409 (40.2%)	
Sous-tentorielle	56 (50.8%)	69 (10.9%)	125 (12.3%)	
Volume de l'AVC en ml (moyenne $\pm \sigma$)	68.1 $\pm$ 62.5	19.9 $\pm$ 30.3	37.5 $\pm$ 50.5	13.3
Pression artérielle diastolique en mmHg (moyenne $\pm \sigma$)	89.1 $\pm$ 21.7	90 $\pm$ 19.1	89.7 $\pm$ 20.2	13.2
Pression artérielle systolique en mmHg (moyenne $\pm \sigma$)	171.2 $\pm$ 36.1	170.5 $\pm$ 30.8	170.8 $\pm$ 32.9	13.5
Score NIHSS (moyenne $\pm \sigma$)	24.6 $\pm$ 13.3	9.2 $\pm$ 8.7	14.9 $\pm$ 12.9	18.6
Score de Glasgow (moyenne $\pm \sigma$)	8.9 $\pm$ 4.5	13.8 $\pm$ 2.4	11.9 $\pm$ 4.2	8.8
Glycémie en g/L (moyenne $\pm \sigma$)	1.5 $\pm$ 0.5	1.3 $\pm$ 0.4	1.4 $\pm$ 0.4	32.5

^aArtériopathie oblitérante des membres inférieurs, sténose carotidienne opérée ou coronaropathie. ^bMono ou bi-antiagrégation. ^cAnti-vitamine K, héparine ou nouveaux anticoagulants.

a été supprimée. Au final, les dimensions du jeu de données analysé étaient de 1077 lignes pour 29 colonnes.

9.3 Sélection de variables par un arbre de décision

A l'aide d'un CART, nous avons tracé un graphique en barre représentant la MDG pour l'ensemble des variables (**figure 3**). Le GCS, le volume de l'hémorragie, le score de NIHSS, la glycémie, la PAD, la PAS, l'antécédent de score de RANKIN et l'âge sont apparus nettement supérieurs aux autres variables disponibles avec un MDG supérieur à 0.05. Sur la base de ces constatations, seules ces variables ont été sélectionnées pour la suite de l'analyse, réduisant les dimensions du jeu de données à 1077 lignes pour 8 colonnes.

Avant de poursuivre notre analyse, nos données ont été divisées aléatoirement en un jeu d'entraînement (80%, soit 861 patients) et un jeu de test (20%, soit 216 patients).

9.4 Clustering par algorithme de K-moyennes

Afin de déterminer le nombre optimal de clusters, nous avons opté pour la méthode du coude. Sur les données d'entraînement ont été testés alternativement de deux à 14 clusters. La représentation graphique de ce nombre croissant de clusters en fonction de la SSE apparaît sur **la figure 4**. L'infléchissement de la courbe est maximal pour un nombre de cluster égal à quatre. Au-delà, on observe un rendement décroissant de la diminution de la SSE. Les données d'entraînement ont donc été divisées en quatre clusters dont les caractéristiques principales sont décrites sur la **Table 2**.

Le cluster zéro compte 182 (21.1%) patients dont 70% sont vivants à 30 jours. Il s'agit de patients plus âgés (82.3 ans) et avec un antécédent de score de RANKIN (3.3) en moyenne plus élevé que l'ensemble des autres groupes.

Le cluster un compte 360 (41.8%) patients dont 76% ont survécus à 30 jours. Il comporte des patients plus jeunes (73.6 ans) et avec un antécédent de score de RANKIN (0.6) en moyenne plus bas que le reste des clusters. Par ailleurs, ces patients semblent souffrir d'AVC moins symptomatiques avec un GCS (14.3) et un score de NIHSS initial (9.1) qui sont en moyenne moins graves.

Le cluster deux compte 134 (15.6%) patients dont 64% sont vivants à 30 jours. Comparativement aux autres groupes, seules les PAS (214 mmHg) et PAD (117.3 mmHg) moyennes diffèrent. On observe en effet des pressions artérielles nettement supérieures aux autres clusters.

Figure 2. Représentation graphique des données manquantes (en blanc) en fonction du score de Glasgow





Figure 3. Représentation par graphique en barre des variables les plus discriminantes.



Enfin, le cluster trois compte 185 (21.5%) patients dont seulement 13.5% de survivants à 30 jours. Dans ce groupe, on remarque des AVC plus importants en volume (91.8 ml) et plus symptomatiques avec un GCS (6.3) moyen plus bas et un NIHSS (28.2) moyen bien plus haut.

L'algorithme de KM a ensuite été utilisé pour étiqueter les données de test de la même manière que les données d'entraînement.

9.5 Classification par SVM et analyse des résultats

Dans chacun des clusters issus des données d'entraînement, il a été optimisé une SVM pour obtenir la meilleure AUC, en réalisant une CV avec quatre groupes. Des valeurs comprises entre 10^{-9} et 10^9 ont été testées pour les hyperparamètres gamma et C. En raison du caractère asymétrique des clusters (les patients décédés du cluster 2 représentant la plus grande des classes minoritaires avec 36% des patients), le paramètre « class_weight » a été utilisé avec le réglage « balanced ». Cela a permis d'appliquer un coefficient inversement proportionnel à la fréquence des classes au paramètre C du SVM afin de limiter l'influence de ce caractère asymétrique sur les résultats.

Dans le cluster zéro, avec des paramètres $C = 10^2$ et $\text{gamma} = 10^{-2}$, l'AUC moyenne de la CV était de 0.79. Sur les données de test, l'AUC était de 0.70, la sensibilité (Se) de 0.88, la valeur prédictive positive (VPP) de 0.71 et le F score de 0.79.

Dans le cluster un, avec des paramètres $C = 10^4$ et $\text{gamma} = 10^{-4}$, l'AUC moyenne de la CV était de 0.80. Sur les données de test, l'AUC était de 0.70, la Se de 0.73, la VPP de 0.85 et le F score de 0.79.

Dans le cluster deux, avec des paramètres $C = 10^{-1}$ et $\text{gamma} = 10^{-2}$, l'AUC moyenne de la CV était de 0.85. Sur les données de test, l'AUC était de 0.79, la Se de 0.81, la VPP de 0.85 et le F score de 0.83.

Dans le cluster trois, avec des paramètres $C = 10^2$ et $\text{gamma} = 10^{-2}$, l'AUC moyenne de la CV était de 0.85. Sur les données de test, l'AUC était de 0.56, la Se de 0.14, la VPP de 0.50 et le F score de 0.22.

Enfin, concernant les résultats du modèle dans sa globalité (rassemblant clustering et chacun des SVM), l'AUC était de 0.75 avec une Se de 0.81, une VPP de 0.74 et un F score de 0.77.

Figure 4. Détermination du nombre optimal de clusters par la méthode du coude. L'infléchissement est maximal pour 4 clusters.




Table 2. Description des clusters issus de l'algorithme de K-moyennes

Variabes	Cluster 0 (n = 182)	Cluster 1 (n = 360)	Cluster 2 (n = 134)	Cluster 3 (n = 185)
Survivants à 30 jours (%)	128 (70%)	275 (76%)	87 (64%)	25 (13.5%)
Score de Glasgow (moyenne $\pm$ σ)	13.5 $\pm$ 2.7	14.3 $\pm$ 1.6	12.7 $\pm$ 3.5	6.3 $\pm$ 3.6
Glycémie en g/L (moyenne $\pm$ σ)	1.4 $\pm$ 0.3	1.2 $\pm$ 0.2	1.3 $\pm$ 0.3	1.5 $\pm$ 0.4
Score NIHSS (moyenne $\pm$ σ)	11.5 $\pm$ 8.9	9.1 $\pm$ 7.3	12.3 $\pm$ 10.6	28.2 $\pm$ 11.9
Pression artérielle diastolique en mmHg (moyenne $\pm$ σ)	83 $\pm$ 14.4	85 $\pm$ 12	117.3 $\pm$ 14.8	84.9 $\pm$ 17.4
Pression artérielle systolique en mmHg (moyenne $\pm$ σ)	162.7 $\pm$ 23.9	162.3 $\pm$ 20.9	214 $\pm$ 22.5	164.9 $\pm$ 30.8
Volume de l'AVC en ml (moyenne $\pm$ σ)	17.1 $\pm$ 19.9	20 $\pm$ 24.6	19.2 $\pm$ 22.4	91.8 $\pm$ 67.5
Antécédent de score de RANKIN (moyenne $\pm$ σ)	3.3 $\pm$ 0.9	0.6 $\pm$ 0.5	1.4 $\pm$ 1.2	1.3 $\pm$ 1.1
Age en année (moyenne $\pm$ σ)	82.3 $\pm$ 8.1	73.6 $\pm$ 13.1	76.4 $\pm$ 12	77.5 $\pm$ 10.7

10. Discussion

Avec plus de dix fois le nombre de patients de l'étude princeps ([Edwards, 1999](#)), il s'agit à ce jour, à notre connaissance, de la plus grande base de données d'HIC analysée à l'aide d'outils d'apprentissage automatique. L'utilisation d'un jeu de données de cette envergure est possible grâce à l'intégration des données manquantes. Jusqu'ici, un seul article sur le sujet avait choisi d'intégrer des valeurs manquantes dans sa modélisation, sans pour autant décrire l'encodage effectué ([Takahashi, 2006](#)). Or, comme semble le montrer l'analyse graphique de nos données, l'absence d'un certain nombre de valeurs ne serait pas aléatoire mais pourrait par exemple être liée à la gravité de l'accident. L'exclusion de ces observations aurait alors pu être à l'origine d'un biais d'attrition. La méthode d'imputation « un parmi n », ici appliquée aux données qualitatives, a pour avantage de potentiel de dévoiler l'information contenue par l'absence d'une valeur en l'analysant comme une modalité à part entière ([VanderPlas, 2016](#)). En contrepartie, il a de ce fait été impossible d'appliquer les scores précédemment développés comme le score ICH auquel il aurait été intéressant de comparer nos résultats ([Hemphill, 2001](#)). De plus, cette méthode ne permet pas de traiter les données quantitatives que nous avons choisi de remplacer par la médiane des observations. Ce choix a pour conséquence possible d'avoir affecté nos résultats en réduisant la variance estimée de celles-ci. A l'avenir, d'autres méthodes, comme l'imputation par le plus proche voisin, pourraient nous permettre un remplacement des valeurs manquantes en limitant la réduction de la variance et en conservant des possibilités de comparaison ([Hastie, 2001](#)).

La sélection des variables par un arbre de décision a permis de confirmer le rôle essentiel du GCS et du volume de l'hématome dans le pronostic des HIC. D'autre part, il est intéressant de souligner que, malgré 18.6% de données manquantes, le score NIHSS initial a apporté une information complémentaire au GCS. Il est capable de prédire la mortalité et le pronostic fonctionnel chez les patients victimes d'AVC ischémiques ([Brott, 1989](#)), mais sa potentielle utilité dans le pronostic des HIC est moins décrite et notre étude semble aller dans ce sens ([Finocchi, 2018 ; Mantero, 2020](#)). De même, malgré 32.5% de données manquantes, la glycémie apparaît comme étant la quatrième variable la plus discriminante. Ce résultat est en accord avec la récente méta-analyse de Jun Zheng et al. en 2018 qui collecte le résultat de 16 études et qui tend à montrer que l'élévation de la glycémie serait liée à un mauvais pronostic ([Zheng, 2018](#)). Au contraire, le traitement par anticoagulant à l'entrée, pourtant sélectionné lors

de l'analyse multivariée d'une de nos précédentes études ([Goupil, 2019](#)), n'a pas été retenu par notre modèle.

Le clustering réalisé sur les données, en plus de participer à l'interprétabilité et à l'explicabilité des résultats, permet une analyse exploratoire intéressante. Le choix de nous arrêter à quatre clusters a été justifié par la méthode du coude. Or, bien que les résultats soient cohérents avec la clinique, il se pourrait que ce nombre varie en fonction de la technique utilisée, du nombre et de la qualité des données explorées ([Yuan, 2019](#)). En ce qui concerne l'analyse descriptive de ces groupes, il semble que les clusters un et trois correspondent à des groupes déjà décrits ([Takahashi, 2006](#) ; [Chiu, 2016](#)). En effet le cluster un semble être un groupe à faible risque (avec des patients plus jeunes, plus autonomes et avec des AVC moins symptomatiques) et, au contraire, le cluster trois apparaît comme un groupe à haut risque (avec des AVC plus volumineux et symptomatiques). Les clusters zéro et deux sont par contre des groupes de patients dont la description est nouvelle. Le cluster zéro est composé de patients plus âgés que la moyenne et dont l'antécédent de score de RANKIN est supérieur aux autres groupes. Pour autant, il s'avère que la mortalité reste inférieure à la mortalité globale pour ces patients. Ce résultat soutiendrait les travaux effectués depuis plusieurs années mettant en garde contre les prophéties auto-réalisatrices dont seraient notamment victimes les patients âgés et peu autonomes suite à une HIC. Ces constatations appellent à des travaux complémentaires concernant le pronostic fonctionnel de ces patients afin de déterminer le degré de handicap à la sortie, indépendamment de la survie ([Rabinstein, 2016](#) ; [Muñoz Venturelli 2017, 2018](#), [Tilling, 2019](#)). Le cluster 2, quant à lui, est un groupe de risque intermédiaire avec 36% de décès dans notre étude. Il est constitué par des patients dont la PAD et PAS paraissent nettement supérieures à la moyenne des autres. Il semble par contre que la gravité des scores cliniques, l'âge, le handicap antérieur à l'accident, la glycémie et le volume de l'hémorragie sont semblables aux caractéristiques globales de nos données. Ce résultat est particulièrement intéressant dans le contexte actuel où le principal traitement médical de l'HIC est le contrôle tensionnel et qu'il persiste des incertitudes concernant l'efficacité clinique de ce type de prise en charge ([Anderson, 2008, 2013](#) ; [Butcher, 2013](#)). Peut-être que les patients ayant un profil similaire à celui de ce cluster bénéficieraient d'autant plus des thérapies anti-hypertensives à la phase aiguë de leurs accidents. Ces hypothèses mériteraient d'être testées au cours d'une étude thérapeutique dédiée.

Enfin, concernant la précision de notre modèle, bien que la comparaison n'ait pas été possible en raison de notre stratégie de traitement des données manquantes, l'AUC de 0.75 est

inférieure aux chiffres rapportés dans la littérature sur le sujet. D'abord, comme évoqué précédemment, il est possible que la méthode d'imputation ait réduit la variance estimée des variables quantitatives, ce qui aurait pu altérer nos résultats. D'autre part, nous n'avons pas encore intégré certaines variables qui se sont montrées informatives sur le pronostic au cours d'études précédentes, comme la présence d'une hémorragie intraventriculaire ([Hemphill, 2001](#)) ou plus récemment l'œdème peri-hémorragique ([Volbers, 2018](#)) et le black hole sign ([Li Qi, 2016](#)). En conclusion, le caractère très asymétrique des clusters, notamment du cluster 3 qui a montré les moins bons résultats lors de la classification par la SVM, a sans doute impacté les résultats de notre étude. Et ce, malgré notre tentative d'équilibrage des poids de chaque classe. A l'avenir, il serait intéressant de comparer plusieurs algorithmes de classification après l'étape de clustering afin de déterminer si l'un d'entre eux se montre plus discriminant que la SVM, tout en conservant la transparence et l'explicabilité de cette méthode.

11. Conclusion

Nous avons développé un nouveau modèle pronostic concernant la mortalité à 30 jours des HIC spontanées. Il s'agit d'un modèle capable de prendre en compte les données manquantes, bénéficiant d'une transparence et explicabilité indispensable au domaine médical. Le score de NIHSS initial et la glycémie d'entrée apparaissent comme étant des variables informatives supplémentaires et émergentes concernant le pronostic des HIC en plus des variables qui étaient plus étudiées telles que le score de Glasgow et les caractéristiques d'imagerie. La performance de cet outil n'a pas pu toutefois être comparée aux scores antérieurs, l'ajout de variables et une nouvelle méthode d'imputation seront requises pour cela. La réalisation d'un clustering a permis de définir des groupes de patients dont l'analyse spécifique appelle à de nouveaux travaux.

12. Bibliographie

- Anderson, Craig S., Yining Huang, et al. « Intensive Blood Pressure Reduction in Acute Cerebral Haemorrhage Trial (INTERACT): A Randomised Pilot Trial ». *The Lancet. Neurology*, vol. 7, n° 5, mai 2008, p. 391-99. *PubMed*, doi:[10.1016/S1474-4422\(08\)70069-3](https://doi.org/10.1016/S1474-4422(08)70069-3).
- Anderson, Craig S., Emma Heeley, et al. « Rapid Blood-Pressure Lowering in Patients with Acute Intracerebral Hemorrhage ». *The New England Journal of Medicine*, vol. 368, n° 25, juin 2013, p. 2355-65. *PubMed*, doi:[10.1056/NEJMoa1214609](https://doi.org/10.1056/NEJMoa1214609).
- Arthur, David, et Sergei Vassilvitskii. *K-Means++: The Advantages of Careful Seeding*. 2007, p. 1027-35. *ResearchGate*, doi:[10.1145/1283383.1283494](https://doi.org/10.1145/1283383.1283494).
- Bamford, J., et al. « A prospective study of acute cerebrovascular disease in the community: the Oxfordshire Community Stroke Project--1981-86. 2. Incidence, case fatality rates and overall outcome at one year of cerebral infarction, primary intracerebral and subarachnoid haemorrhage. » *Journal of Neurology, Neurosurgery, and Psychiatry*, vol. 53, n° 1, janvier 1990, p. 16-22.
- Breiman, Leo, et al. *Classification and Regression Trees*. New Ed, Chapman and Hall/CRC, 1984.
- Broderick J P, et al. « Volume of intracerebral hemorrhage. A powerful and easy-to-use predictor of 30-day mortality. » *Stroke*, vol. 24, n° 7, American Heart Association, juillet 1993, p. 987-93. *ahajournals.org (Atypon)*, doi:[10.1161/01.STR.24.7.987](https://doi.org/10.1161/01.STR.24.7.987).
- Brott, T., et al. « Measurements of Acute Cerebral Infarction: A Clinical Examination Scale ». *Stroke*, vol. 20, n° 7, juillet 1989, p. 864-70. *PubMed*, doi:[10.1161/01.str.20.7.864](https://doi.org/10.1161/01.str.20.7.864).
- Butcher, Kenneth S., et al. « The Intracerebral Hemorrhage Acutely Decreasing Arterial Pressure Trial ». *Stroke*, vol. 44, n° 3, mars 2013, p. 620-26. *PubMed*, doi:[10.1161/STROKEAHA.111.000188](https://doi.org/10.1161/STROKEAHA.111.000188).
- Çelik, Güner, et al. « Predicting 10-Day Mortality in Patients with Strokes Using Neural Networks and Multivariate Statistical Methods ». *Journal of Stroke and Cerebrovascular Diseases*, vol. 23, n° 6, juillet 2014, p. 1506-12. *DOI.org (Crossref)*, doi:[10.1016/j.jstrokecerebrovasdis.2013.12.018](https://doi.org/10.1016/j.jstrokecerebrovasdis.2013.12.018).
- Chiu, Hui-Chu, et al. « To Explore Intracerebral Hematoma with a Hybrid Approach and Combination of Discriminative Factors ». *Methods of Information in Medicine*, vol. 55, n° 05, 2016, p. 450-54. *DOI.org (Crossref)*, doi:[10.3414/ME15-01-0137](https://doi.org/10.3414/ME15-01-0137).

- Df, Edwards, et al. « Artificial Neural Networks Improve the Prediction of Mortality in Intracerebral Hemorrhage. » *Neurology*, vol. 53, n° 2, juillet 1999, p. 351-57. *europepmc.org*, doi:[10.1212/wnl.53.2.351](https://doi.org/10.1212/wnl.53.2.351).
- Finocchi, Cinzia, et al. « National Institutes of Health Stroke Scale in Patients with Primary Intracerebral Hemorrhage ». *Neurological Sciences: Official Journal of the Italian Neurological Society and of the Italian Society of Clinical Neurophysiology*, vol. 39, n° 10, octobre 2018, p. 1751-55. *PubMed*, doi:[10.1007/s10072-018-3495-y](https://doi.org/10.1007/s10072-018-3495-y).
- Flemming, K. D., et al. « Can We Predict Poor Outcome at Presentation in Patients with Lobar Hemorrhage? » *Cerebrovascular Diseases (Basel, Switzerland)*, vol. 11, n° 3, 2001, p. 183-89. *PubMed*, doi:[10.1159/000047636](https://doi.org/10.1159/000047636).
- Goupil et al. « An Early Mortality Prognostic Score in Intracerebral Hemorrhage Established on the Population-Based Brest Stroke Registry, General Interest Sessions ». *European Stroke Journal*, vol. 4, n° 1_suppl, mai 2019, p. 3-95. *DOI.org (Crossref)*, doi:[10.1177/2396987319845560](https://doi.org/10.1177/2396987319845560).
- Gregório, Tiago, et al. « Prognostic Models for Intracerebral Hemorrhage: Systematic Review and Meta-Analysis ». *BMC Medical Research Methodology*, vol. 18, n° 1, décembre 2018, p. 145. *DOI.org (Crossref)*, doi:[10.1186/s12874-018-0613-8](https://doi.org/10.1186/s12874-018-0613-8).
- Hastie, Trevor, et al. « Imputing Missing Data for Gene Expression Arrays ». *Technical report, Stanford Statistics Department*, vol. 1, décembre 2001.
- Hawkins, Douglas M. « The Problem of Overfitting ». *Journal of Chemical Information and Computer Sciences*, vol. 44, n° 1, American Chemical Society, janvier 2004, p. 1-12. *ACS Publications*, doi:[10.1021/ci0342472](https://doi.org/10.1021/ci0342472).
- Hemphill, J. C., et al. « The ICH Score: A Simple, Reliable Grading Scale for Intracerebral Hemorrhage ». *Stroke*, vol. 32, n° 4, avril 2001, p. 891-97. *PubMed*, doi:[10.1161/01.str.32.4.891](https://doi.org/10.1161/01.str.32.4.891).
- Hemphill, J. Claude, et al. « Guidelines for the Management of Spontaneous Intracerebral Hemorrhage: A Guideline for Healthcare Professionals From the American Heart Association/American Stroke Association ». *Stroke*, vol. 46, n° 7, juillet 2015, p. 2032-60. *PubMed*, doi:[10.1161/STR.0000000000000069](https://doi.org/10.1161/STR.0000000000000069).
- Hilbe, Joseph M. *Logistic Regression Models*. First Edition, CRC Press, 2009.
- Li Qi, et al. « Black Hole Sign ». *Stroke*, vol. 47, n° 7, American Heart Association, juillet 2016, p. 1777-81. *ahajournals.org (Atypon)*, doi:[10.1161/STROKEAHA.116.013186](https://doi.org/10.1161/STROKEAHA.116.013186).

- Lukić, Stevo, et al. « Artificial Neural Networks Based Early Clinical Prediction of Mortality after Spontaneous Intracerebral Hemorrhage ». *Acta Neurologica Belgica*, vol. 112, n° 4, décembre 2012, p. 375-82. *DOI.org (Crossref)*, doi:[10.1007/s13760-012-0093-2](https://doi.org/10.1007/s13760-012-0093-2).
- Mantero, Vittorio, et al. « NIHSS as Predictor of Clinical Outcome at 6 Months in Patients with Intracerebral Hemorrhage ». *Neurological Sciences*, vol. 41, n° 3, mars 2020, p. 717-19. *Springer Link*, doi:[10.1007/s10072-019-04070-4](https://doi.org/10.1007/s10072-019-04070-4).
- Muñoz Venturelli, Paula, et al. « Withdrawal of Active Treatment after Intracerebral Haemorrhage in the INTERACT2 Study ». *Age and Ageing*, vol. 46, n° 2, mars 2017, p. 329-32. *DOI.org (Crossref)*, doi:[10.1093/ageing/afw187](https://doi.org/10.1093/ageing/afw187).
- Peng, S. Y., et al. « Random Forest Can Predict 30-Day Mortality of Spontaneous Intracerebral Hemorrhage with Remarkable Discrimination: Random Forest Predicts Mortality of SICH ». *European Journal of Neurology*, vol. 17, n° 7, juillet 2010, p. 945-50. *DOI.org (Crossref)*, doi:[10.1111/j.1468-1331.2010.02955.x](https://doi.org/10.1111/j.1468-1331.2010.02955.x).
- Rabinstein, Alejandro A. « Prognosis after ICH: A Necessity despite Uncertainties ». *Neurology*, vol. 86, n° 20, mai 2016, p. 1854-55. *DOI.org (Crossref)*, doi:[10.1212/WNL.0000000000002684](https://doi.org/10.1212/WNL.0000000000002684).
- Scholkopf, B., et al. « New Support Vector Algorithms ». *Neural computation*, vol. 12, juin 2000, p. 1207-45. *ResearchGate*, doi:[10.1162/089976600300015565](https://doi.org/10.1162/089976600300015565).
- Steiner, Thorsten, et al. « European Stroke Organisation (ESO) Guidelines for the Management of Spontaneous Intracerebral Hemorrhage ». *International Journal of Stroke: Official Journal of the International Stroke Society*, vol. 9, n° 7, octobre 2014, p. 840-55. *PubMed*, doi:[10.1111/ijss.12309](https://doi.org/10.1111/ijss.12309).
- Takahashi, O., et al. « Risk Stratification for In-Hospital Mortality in Spontaneous Intracerebral Haemorrhage: A Classification and Regression Tree Analysis ». *QJM*, vol. 99, n° 11, septembre 2006, p. 743-50. *DOI.org (Crossref)*, doi:[10.1093/qjmed/hcl107](https://doi.org/10.1093/qjmed/hcl107).
- Tilling, Elliot J., et al. « Do Clinicians Overestimate the Severity of Intracerebral Hemorrhage? ». *Stroke*, vol. 50, n° 2, février 2019, p. 344-48. *DOI.org (Crossref)*, doi:[10.1161/STROKEAHA.118.022606](https://doi.org/10.1161/STROKEAHA.118.022606).
- Timsit, S., et al. « High Completeness of the Brest Stroke Registry Evidenced by Analysis of Sources and Capture-Recapture Method ». *Neuroepidemiology*, vol. 42, n° 3, 2014, p. 186-95. *PubMed*, doi:[10.1159/000358802](https://doi.org/10.1159/000358802).
- van Asch, Charlotte Jj, et al. « Incidence, Case Fatality, and Functional Outcome of Intracerebral Haemorrhage over Time, According to Age, Sex, and Ethnic Origin: A Systematic Review

- and Meta-Analysis ». *The Lancet. Neurology*, vol. 9, n° 2, février 2010, p. 167-76. *PubMed*, doi:[10.1016/S1474-4422\(09\)70340-0](https://doi.org/10.1016/S1474-4422(09)70340-0).
- VanderPlas, Jake. *Python Data Science Handbook*. First Edition, O'Reilly Media, 2016.
- Vickers, Andrew J., et Douglas G. Altman. « Statistics Notes: Missing Outcomes in Randomised Trials ». *BMJ*, vol. 346, British Medical Journal Publishing Group, juin 2013. *www.bmj.com*, doi:[10.1136/bmj.f3438](https://doi.org/10.1136/bmj.f3438).
- Volbers, Bastian, et al. « Peak Perihemorrhagic Edema Correlates with Functional Outcome in Intracerebral Hemorrhage ». *Neurology*, vol. 90, n° 12, mars 2018, p. e1005-12. *DOI.org (Crossref)*, doi:[10.1212/WNL.00000000000005167](https://doi.org/10.1212/WNL.00000000000005167).
- Yuan, Chunhui, et Haitao Yang. « Research on K-Value Selection Method of K-Means Clustering Algorithm ». *J — Multidisciplinary Scientific Journal*, vol. 2, n° 2, 2, Multidisciplinary Digital Publishing Institute, juin 2019, p. 226-35. *www.mdpi.com*, doi:[10.3390/j2020016](https://doi.org/10.3390/j2020016).
- Zheng, Jun, et al. « Association Between Blood Glucose and Functional Outcome in Intracerebral Hemorrhage: A Systematic Review and Meta-Analysis ». *World Neurosurgery*, vol. 114, juin 2018, p. e756-65. *ScienceDirect*, doi:[10.1016/j.wneu.2018.03.077](https://doi.org/10.1016/j.wneu.2018.03.077).