

# Hybrid machine learning approach to evaluate the prognosis of spontaneous cerebral hemorrhages on the population-based Brest Stroke Registry

Victor Quéré

Laboratoire de Logique des Usages, des Sciences Sociales et de l'Information (LUSSI – UMR 6285)

Le 02/09/20

UMR 1078



UMR 6285



**IMT Atlantique**

Bretagne-Pays de la Loire  
École Mines-Télécom

## CONTEXTE

Hématomes  
intracérébraux (HIC) :  
15% des AVC, 50% de  
mortalité

Principalement des soins  
de support

Incertitude en matière de  
prise en charge



## SCORE ICH

Equation de régression  
logistique

Incapacité à traiter les  
relations non linéaires

Peu utilisé en pratique

GCS score

3–4

2

5–12

1

13–15

0

ICH volume, cm<sup>3</sup>

≥30

1

<30

0

IVH

Yes

1

No

0

Infratentorial origin of ICH

Yes

1

No

0

Age, y

≥80

1

<80

0

Total ICH Score

0–6

GCS score indicates GCS score on initial presentation (or after resuscitation); ICH volume, volume on initial CT calculated using *ABC/2* method; and IVH, presence of any IVH on initial CT.

# L'IA DANS LE PRONOSTIC DE L'ICH

## Edwards *et al.* 1999

- 14 patients test
- Erreurs Méthodologiques

## 7 Etudes

- Multiples architectures d'algorithme
- Jusqu'à 423 patients et 20 variables

## Méta-analyse : Gregorio *et al.* 2018

- Tendance à de meilleurs précisions des algorithmes d'IA
- Manque de transparence
- Pas de traitement des données manquantes

## LE PROJET

### Objectif primaire :

Développer un outil pronostic précis concernant la mortalité à 30 jours des hémorragies intra-cérébrales

### Objectifs secondaires :

- Décrivant bien les étapes de la décision
- Sans exclure les observations à données manquantes


## POPULATION

REGISTRE  
POPULATIONNEL DES AVC  
DU PAYS DE BREST

1140 patients victimes d'HIC  
Entre 2008 et 2017

1077 patients inclus


18 variables retenues




## LES DONNÉES MANQUANTES

Données manquantes  
**quantitatives** :  
médiane

Données manquantes  
**qualitatives** :  
encodage « un parmi  
n »




## ETAPES DE LA MODÉLISATION



## SÉLECTION DE VARIABLES

- AGE
- SCORE DE GLASGOW
- ANTECEDENT DE RANKIN
- VOLUME DE L'HEMATOME
- PRESSION ARTERIELLE SYSTOLIQUE
- PRESSION ARTERIELLE DIASTOLIQUE
- GLYCEMIE
- NIHSS INITIAL



## CLUSTERING

| Variables                                                         | Cluster 0 (n = 182) | Cluster 1 (n = 360) | Cluster 2 (n = 134) | Cluster 3 (n = 185) |
|-------------------------------------------------------------------|---------------------|---------------------|---------------------|---------------------|
| Survivants à 30 jours (%)                                         | 128 (70%)           | 275 (76%)           | 87 (64%)            | 25 (13.5%)          |
| Score de Glasgow (moyenne $\pm$ $\sigma$ )                        | 13.5 $\pm$ 2.7      | 14.3 $\pm$ 1.6      | 12.7 $\pm$ 3.5      | 6.3 $\pm$ 3.6       |
| Glycémie en g/L (moyenne $\pm$ $\sigma$ )                         | 1.4 $\pm$ 0.3       | 1.2 $\pm$ 0.2       | 1.3 $\pm$ 0.3       | 1.5 $\pm$ 0.4       |
| Score NIHSS (moyenne $\pm$ $\sigma$ )                             | 11.5 $\pm$ 8.9      | 9.1 $\pm$ 7.3       | 12.3 $\pm$ 10.6     | 28.2 $\pm$ 11.9     |
| Pression artérielle diastolique en mmHg (moyenne $\pm$ $\sigma$ ) | 83 $\pm$ 14.4       | 85 $\pm$ 12         | 117.3 $\pm$ 14.8    | 84.9 $\pm$ 17.4     |
| Pression artérielle systolique en mmHg (moyenne $\pm$ $\sigma$ )  | 162.7 $\pm$ 23.9    | 162.3 $\pm$ 20.9    | 214 $\pm$ 22.5      | 164.9 $\pm$ 30.8    |
| Volume de l'AVC en ml (moyenne $\pm$ $\sigma$ )                   | 17.1 $\pm$ 19.9     | 20 $\pm$ 24.6       | 19.2 $\pm$ 22.4     | 91.8 $\pm$ 67.5     |
| Antécédent de score de RANKIN (moyenne $\pm$ $\sigma$ )           | 3.3 $\pm$ 0.9       | 0.6 $\pm$ 0.5       | 1.4 $\pm$ 1.2       | 1.3 $\pm$ 1.1       |
| Age en année (moyenne $\pm$ $\sigma$ )                            | 82.3 $\pm$ 8.1      | 73.6 $\pm$ 13.1     | 76.4 $\pm$ 12       | 77.5 $\pm$ 10.7     |

## PERFORMANCES DU MODÈLE

**Aire sous la Courbe de ROC (AUC) : 0,75**

**Sensibilité : 0,81**

**Valeur prédictive positive : 0,74**

**F score :0,77**

**Pas de comparaison possible** en raison de la méthode d'imputation mais  
l'AUC semble inférieure aux études précédentes

## APPORTS PERSONNELS

**L'intégration dans une équipe de recherche :**

- **Participations aux réunions de département**
- **Et présentations de projets de fin d'étude**

**L'apprentissage du langage Python :**

- **1 MOOC de 40 heures**

**Initiation à la sciences des données :**

- **Au laboratoire lors d'échanges formels ou non**
- **En ligne avec 6 MOOC soit plus de 90 heures de formations**

**La découverte des réglementations et protocoles inhérents à la protection des données de santé**

## LIMITES ET PERSPECTIVES

**Nouvelles méthodes d'imputation**

**Extraction de données encore inexploitées**

**Test de nouveaux algorithmes de classification**

**Comparaison avec les scores statistiques traditionnels**

MERCI POUR VOTRE ATTENTION

# LIMITATIONS DES SCORES ACTUELS


En régression  
logistique

➡ Impossibilité d'utiliser des variables ayant une relation linéaire en elles car l'inversion de matrice est rendue impossible par la multi-colinéarité

➡ Pas de détection des relations non linéaires

# LE SCORE BRESTOIS

| Prognostic factors                    |        | Points    |
|---------------------------------------|--------|-----------|
| VKA                                   |        | 1         |
| Age $\geq$ 80 years                   |        | 2         |
| Glasgow coma scale                    | < 5    | 4         |
|                                       | 5 à 12 | 2         |
|                                       | > 12   | 0         |
| Volume $\geq$ 30 ml                   |        | 2         |
| No admission in intensive stroke unit |        | 1         |
| Intraventricular hemorrhage           |        | 2         |
| <b>Total</b>                          |        | <b>12</b> |



# COEFFICIENT DE GINI

$$\text{Gini} = 1 - \sum_{\text{classe}} \left( \frac{n_{\text{samples in class}}}{n_{\text{samples}}} \right)^2$$

Le coefficient de GINI :


C'est la mesure de la **probabilité qu'une observation soit mal classée si il lui était aléatoirement attribuée une classe**, selon la répartition au sein de l'échantillon de cette classe.

La décroissance moyenne du GINI dans un arbre :  
moyenne du **GINI d'une variable à chaque nœud où elle intervient, pondérée par la part de l'échantillon passant par ce nœud.**


## ENCODAGE « 1 PARMI N »

| Color  |  | Red | Yellow | Green |
|--------|--|-----|--------|-------|
| Red    |  | 1   | 0      | 0     |
| Red    |  | 1   | 0      | 0     |
| Yellow |  | 0   | 1      | 0     |
| Green  |  | 0   | 0      | 1     |
| Yellow |  |     |        |       |


# VALIDATION CROISÉE




# KNN




# K-MOYENNE




# MÉTHODE DU COUDE



# SVM




# KERNEL TRICK



# ARBRE DE DÉCISION



# RELATION NON LINÉAIRE



## LIMITER L'EFFET DE SUR-ENTRAÎNEMENT

Utilisation de méthodes de Cross-Validation ou k-fold cross validation

Utilisation d'un maximum de données

Sélection des données d'intérêt pour résoudre le problème posé

Limitation du nombre de répétition dans les phases d'entraînement

Utilisation de paramètres contraignant l'apprentissage des algorithmes

Utilisation de méthodes *d'ensembling*