


Thèse de doctorat en médecine

Comparaison de méthodes de régression avec des algorithmes de forêts aléatoires pour prédire la mortalité précoce des hémorragies intracérébrales spontanées à partir du registre populationnel des AVC du pays de Brest



▶ 15% des AVC, 50% de mortalité
[2]

▶ Principalement des soins de support

▶ Incertitudes en matière de prise en charge

[1] Dichgans M et al. *Circ Res.* 2017

[2] Van Asch CJ et al. *Lancet Neurol.* 2017


Score ICH

- ▶ Equation de régression logistique
- ▶ Manque de précision
- ▶ Peu utilisé en pratique

Component	ICH Score Points
GCS score	
3–4	2
5–12	1
13–15	0
ICH volume, cm ³	
≥30	1
<30	0
IVH	
Yes	1
No	0
Infratentorial origin of ICH	
Yes	1
No	0
Age, y	
≥80	1
<80	0
Total ICH Score	0–6

GCS score indicates GCS score on initial presentation (or after resuscitation); ICH volume, volume on initial CT calculated using *ABC/2* method; and IVH, presence of any IVH on initial CT.

[3]



Edwards *et al.* 1999

- 14 patients test
- Erreurs Méthodologiques

7 Etudes

- Multiples architectures d'algorithme
- Jusqu'à 423 patients et 20 variables

Méta-analyse : Gregorio *et al.* 2018

- Tendance à de meilleurs précisions des algorithmes d'IA
- Manque de transparence
- Pas de traitement des données manquantes

Objectifs

Primaire :


Développer et comparer des modèles pronostic précis à partir d'équations de régression et de machine learning concernant la mortalité à 30 jours des hémorragies intra-cérébrales spontanées

Secondaire :


- Interprétables
- Traitement bien documenté des observations à données manquantes

Registre des AVC du pays de Brest

- ▶ 360 000 habitants,
prospectif et multicentrique
- ▶ 738 patients inclus entre
janvier 2008 et décembre
2017
- ▶ 25 variables étudiées




Pourcentage de
données manquantes



Pourcentage de données manquantes par variable

Une répartition homogène des données manquantes ?

- ▶ Comparaison des population **avec** et **sans** données manquantes :
- ▶ Hémorragie > 30cm^3 : **36%** versus **28%**
- ▶ Glasgow < à 5 : **11,1%** versus **3,1%**
- ▶ Décès : **33,5%** versus **13,5%**



Répartition des données manquantes par variable en fonction du score de Glasgow

Data

Spontaneous
intracerebral hemorrhages
2008-2017
Y = 30 days mortality

Etapes de la modélisation

Predictive Mean Matching

Modèle de régression

Pour chaque variable avec des données manquantes.

01.

Prédiction

Pour chaque individu, à partir du modèle de régression.

02.

03.

Sélection

De l'individu sans données manquantes avec la valeur **prédite** la plus proche.

04.

Imputation

A partir de la variable **observée** pour cet individu.

➡ Valeurs imputées « réelles »

Création des scores statistiques

- ▶ Sélection des variables significativement associées au décès à 30 jours au cours de **l'analyse univariée**
- ▶ Création d'un **modèle multivarié** à partir de ces variables puis exclusion des variables non contributives par la **méthode du « pas à pas descendante »**
- ▶ **Score de risque pondéré** en divisant le coefficient de regression de chaque variable par le plus petit avant d'arrondir le résultat à l'unité supérieure


Arbre de décision



Données d'entraînement




Données de test



Échantillon aléatoire
des observations

X dataset

Échantillon aléatoire
des variables



La décroissance moyenne du GINI :

Moyenne du GINI d'une variable à chaque nœud où elle intervient, pondérée par la part de l'échantillon passant par ce nœud.

Validation croisée



Données d'entraînement



	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 1	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 2	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 3	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 4	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 5	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5





Données de test



GridSearch



Données d'entraînement



Données de test



	Tested parameters
<i>n_estimators</i>	100, 500, 1000, 1500, 2000
<i>max_features</i>	sqrt, log2, None
<i>min_samples_split</i>	From 2 to 100
<i>max_depth</i>	3, 6, 9, 12, 15, 20, Nones

Description des données

DONNÉES COMPLETES

- ▶ Age moyen : 71 ans
- ▶ Sexe : 49,2% sont des hommes
- ▶ Glasgow < 5 : 3,1%
- ▶ NIHSS > 15 : 25,2%
- ▶ Volume d'hémorragie > 30cm³ : 28%
- ▶ Traitements :
 - ▶ 23,3% antiagrégants plaquettaires
 - ▶ 15,9% anticoagulants
- ▶ 13,5% de mortalité à 30 jours

DONNÉES NON IMPUTÉES

- ▶ Age moyen : 73,2 ans
- ▶ Sexe : 45,7% sont des hommes
- ▶ Glasgow < 5 : 11,1%
- ▶ NIHSS > 15 : 35,0%
- ▶ Volume d'hémorragie > 30cm³ : 36%
- ▶ Traitements :
 - ▶ 24,1% antiagrégants plaquettaires
 - ▶ 20,7% anticoagulants
- ▶ 33,3% de mortalité à 30 jours

Description des données



Description identique
suite à l'imputation
des données
manquantes

DONNÉES NON IMPUTÉES



- ▶ Age moyen : 73,2 ans
- ▶ Sexe : 45,7% sont des hommes
- ▶ Glasgow < 5 : 11,1%
- ▶ NIHSS > 15 : 35,0%
- ▶ Volume d'hémorragie > 30cm³ : 36%
- ▶ Traitements :
 - ▶ 24,1% antiagrégants plaquettaires
 - ▶ 20,7% anticoagulants
- ▶ 33,3% de mortalité à 30 jours

DONNÉES COMPLETES		OR [IC95%]	p-value	Regression coefficient	Score Points
Age	< 75 y	1.00 (réf)	0.0267	1.3263	0
	>=75 y	3.77 [1.17 ; 12.18]			1
Cardiac arrhythmia	No	1.00 (réf)	0.0158	1.4075	0
	Yes	4.09 [1.30 ; 12.82]			1
Glasgow Score	<5	25.08 [2.80 ; 224.35]	0.0007	3.2220	2
	5-12	6.77 [2.13 ; 21.53]		1.9120	1
	>12	1.00 (réf)			0
Hemorrhage volume (cm ³)	< 30	1.00 (réf)	0.0229	1.2731	0
	>=30	3.57 [1.19 ; 10.69]			1
Total score					0-5

DONNÉES IMPUTÉES		OR [IC95%]	p-value	Regression coefficient	Score points
Age	< 75 y	1.00 (réf)	0.0382	0.5960	0
	>=75 y	1.81 [1.03 ; 3.20]			1
Artheromatic disease	No	1.00 (réf)	0.0085	0.8488	0
	Yes	2.34 [1.24 ; 4.40]			1
Blood glucose level (g/L)	<=1.2	1.00 (réf)	0.0010	0.9561	0
	>1.2	2.60 [1.47 ; 4.60]			2
Syndrome lacunaire	No	6.15 [1.30 ; 29.31]	0.0227	1.8158	3
	Yes	1.00 (réf)			0
Glasgow score	<5	58.01 [17.19 ; 195.75]	<0.001	4.0607	7
	5-12	4.81 [2.73 ; 8.46]		1.5702	3
	>12	1.00 (réf)			0
Lobar hemorrhage	No	5.31 [2.76 ; 10.23]	<0.001	1.6700	3
	Yes	1.00 (réf)			0
Hemorrhage volume (cm ³)	< 30	1.00 (réf)	<0.001	1.9713	0
	>=30	7.18 [3.79 ; 13.61]			3
Prior anticoagulant medication	No	1.00 (réf)	0.0022	0.9829	0
	Yes	2.67 [1.42 ; 5.01]			2
Total score					0-25



Décroissance moyenne du GINI par variable à partir des données complètes et imputées¹⁹

DONNÉES
COMPLETESDONNÉES
IMPUTÉES

Limites

- ▶ Manque de certaines données informatives
- ▶ Absence de comparaison avec le score de référence
- ▶ Utilisation de données brutes ?

Conclusion

▶ Variables :

- ▶ **Confirmées** (Glasgow, âge, volume d'hémorragie)
- ▶ **Plus nouvelles** (glycémie, NIHSS, anticoagulants)

▶ Imputation :

- ▶ Meilleure **représentativité** du jeux de données
- ▶ Meilleure **performance** des scores

▶ Forêts aléatoires et les scores pondérés :

- ▶ **Interprétables**
- ▶ **Faciles d'utilisation**
- ▶ **Performants**

Merci de votre
attention

Serment d'Hippocrate

Au moment d'être admis à exercer la médecine, je promets et je jure d'être fidèle aux lois de l'honneur et de la probité.

Mon premier souci sera de rétablir, de préserver ou de promouvoir la santé dans tous ses éléments, physiques et mentaux, individuels et sociaux.

Je respecterai toutes les personnes, leur autonomie et leur volonté, sans aucune discrimination selon leur état ou leurs convictions. J'interviendrai pour les protéger si elles sont affaiblies, vulnérables ou menacées dans leur intégrité ou leur dignité. Même sous la contrainte, je ne ferai pas usage de mes connaissances contre les lois de l'humanité.

J'informerai les patients des décisions envisagées, de leurs raisons et de leurs conséquences. Je ne tromperai jamais leur confiance et n'exploiterai pas le pouvoir hérité des circonstances pour forcer les consciences.

Je donnerai mes soins à l'indigent et à quiconque me le demandera. Je ne me laisserai pas influencer par la soif du gain ou la recherche de la gloire.

Admis dans l'intimité des personnes, je tairai les secrets qui me seront confiés. Reçu à l'intérieur des maisons, je respecterai les secrets des foyers et ma conduite ne servira pas à corrompre les mœurs.

Je ferai tout pour soulager les souffrances. Je ne prolongerai pas abusivement les agonies. Je ne provoquerai jamais la mort délibérément.

Je préserverai l'indépendance nécessaire à l'accomplissement de ma mission. Je n'entreprendrai rien qui dépasse mes compétences. Je les entretiendrai et les perfectionnerai pour assurer au mieux les services qui me seront demandés.

J'apporterai mon aide à mes confrères ainsi qu'à leurs familles dans l'adversité.

Que les hommes et mes confrères m'accordent leur estime si je suis fidèle à mes promesses ;