

Compte-rendu de stage

SERRE Marc

sommaire

Rappel de la situation et des objectifs :

I ème partie : expériences en oubliant d'apprendre une classe.

II ème partie : expériences en projetant suivant une classe pour l'oublier

III ème partie : expériences dans l'espace des barycentres du train

IV ème partie : expériences dans l'espaces des barycentres du ways.

V ème partie : expériences dans l'espaces des barycentres du ways et du train

VI ème partie : comparaison des espace engendré par les barycentres du ways, du shot labellisée et du shot et des queries.

Piste de recherche

Stratégie à essayer

piste d'amélioration du code

Rappel de la situation et des objectifs :

Nous avons un réseau de neurone qui doit en s'entraînant sur des classes du train pouvoir identifier un autre jeu de classe : celles du ways.

Notre idée:est-ce que certaines classes du train perturbe l'apprentissage du réseau en lui faisant, par exemple, donner une trop grande importance à certain détail.

Des travaux préliminaires ont montrer que si en moyenne apprendre un maximum de chose était positif. Il ont également montrer que pour des ways données, il pouvait être intéressant d'oublier ue classe en particulier qui dépend principalement du ways (mais aussi spécifiquement des image du shot).

Pour rappel, dans ces expériences nous travaillerons avec un jeu d'image d'entraînement repartie en 64 classes différentes.

I ème partie : expériences en oubliant d'apprendre une classe.

Dans cette partie, nous avons un réseau de neurones que nous avons entraîné de 65 manières différentes. Une fois avec toutes les classes c'est le réseau « full ». Il sera le témoin, la barre à dépasser. Et les 64 autres fois avec toutes les classes sauf une. La classe non apprise étant bien sur unique pour chaque modèle.

On associe le modèle à sa classe non apprise

Expériences réalisée pour 1 réalisations avec 100 runs :

a) étude de la dépendance de la performance par rapport à des critères simples

On a essayé de trouver une corrélation entre la performance du modèle et :

- de la distance de sa classe non apprise par rapport au barycentre des données des classes du ways
- de sa distance par rapport au barycentre d'une classe du ways la plus loin de lui
- de sa distance par rapport au barycentre d'une classe du ways la plus près de lui
- de sa distance par rapport au barycentre de tous les données du test
- de sa non centralité par rapport au barycentre des classes du ways (la variance des distances entre lui et les barycentres des classes du ways)
- des angles des barycentres du train par rapport au barycentre de toutes les données du test
- des angles des barycentres du train par rapport au barycentre des classes du ways

Le résultat est que la performance semble indépendante vis à vis de toutes ces critères (aucune corrélation trouvée)

b) attribution de notes aux modèles pour quantifier des phénomènes complexes

L'idée de l'attribution des notes part d'un postulat : Le réseau de neurones associe chaque classe du ways à une classe du train. Il faut donc faciliter cette association.

On va pour pouvoir attribuer les notes au modèle réaliser un mariage parfait entre les barycentre du train et les barycentre du ways à l'avantage de ces dernières.

On attribue 3 notes à chaque modèles :

Une note d'unicité :

C'est la moyenne la moyenne des taux de la distance entre le barycentre de la classe du run et le barycentre de la classe du train juste après la classe du train attribué sur la distance entre le barycentre de la classe attribue et la classe du ways.

C'est une note sur l'infinie. Plus elle est élevée plus la classe attribué et la classe du ways forme un groupe à part.

Le note de séparation :

C'est la moyenne des taux de separation.

taux de separation : inverse du rapport de la distance entre la classe du run et sa classe train attribué sur la distance la classe run et la classe run la plus proche

Elle quantifie à quel point le modèle sépare les données du run. Elle vérifie que les barycentres des classes du ways ne soit pas tous mis au même endroit.


La note de spécificité :

Elle quantifie la spécificité de l'association de la classe du train à la classe du ways. Elle permet de vérifier qu'une classe du train attribué à une classe du ways ne pourrait pas être associé à une autre.

la note est la somme des taux de spécificités

Un taux de spécificité se calcule ainsi : pour chaque barycentre du ways on prend l'inverse du rapport de la distance entre le barycentre de la classe du ways et celui de la classe train attribuée sur la distance entre ce dernier et la deuxième classe du ways la plus proche. Ainsi elle peut attribuer un nombre point plus petit que 1 si la classe du ways à laquelle elle est attribuée est plus n'est pas la plus proche.

On remarque une corrélation positive entre la moyenne des notes et la performance



En revanche la performance semble indépendante vis à vis du coût (le coût classique, voir code) du mariage parfait.

La corrélation n'étant pas parfaite et le postulat qui a inspiré notre notation ne nous satisfaisant pas, nous sommes passé à une autre idée et n'avons pas poursuivi notre recherche dans cette direction.

Un autre travail avait permis de montrer qu'en entraînant le modèle avec tout puis en lui faisant oublié une classe par une projection, on obtenait de meilleur performance, d'autant plus que les temps pour calculer les différents modèles à partir du full est bien plus court que celui pour entraîner 65 fois un réseau de neurone.

II ème partie : expériences en projetant suivant une classe pour l'oublier

a) comparaison à la partie I

Comme dans la partie I, on travaille avec 65 espaces. Le premier étant celui engendré par le réseau full et les 64 autres étant obtenue par une projection suivant le vecteur qui permet déterminer une classe. (un réseau de neurone définit une matrice qu'on multiplie à un vecteur donne le


résultat (un vecteur avec que des 0 sauf en un endroit la position de la classe auxquelles appartient l'objet. On projette suivant le vecteur défini par la ligne i qui permet d'obtenir la classe i).

Cette projection simule une sorte d'oubli de classe.

On refait tous les tests qu'on a fait dans la partie I

La corrélation avec les notes disparaît mais une autre apparaît :

La performance d'un modèle est corrélée à sa non centralité par rapport au barycentre des classes du ways. (plus la variance des distances entre lui et les barycentres des classes du ways plus la performance diminue)



La stratégie qui consiste à prendre celui qui minimise cette variance c'est révélée intéressante augmentant les performances dans 36% des cas (même si en moyenne c'est un peu moins efficace) (Ce n'était jamais la meilleure projection aussi) mais il n'y a que 14% des projections qui augmente la performance. Ce qui signifie que notre stratégie est bien meilleure qu'une sélection aléatoire.

III ème partie : expériences dans l'espace des barycentres du train

Cela nous à amené à nous dire qu'on pouvait projeter suivant des directions de manière à supprimé des dimensions contenant du bruits de la désinformations.

Nous sommes donc passé dans l'espace défini par les barycentres du train. Si on fait une sélection dans cette espace, on remarque que les performances sont presque égale à celle du full (perte de 0,5% de perf dans le cas où il y a deux classes du ways). Cela nous indique que la majorité de l'information est bien contenue dans cette espace. Mais il y en a une petite partie ailleurs. Cela dit il convient de noter qu'avec deux classes dans le ways l'espace des train barycenters est meilleur que celui de départ dans 40% des cas.

Dans cette espace nous avons oublié les dimensions (et donc les classes) suivant lesquels la variances intra classe était supérieur à la variances interclasse mais cela diminue les performances.

Nous avons testé dans cette espace une LDA mais l'utilisation de la Lda quelque soit l'espace de travail semble diminuer les performances. Je pense que cela est du au fait qu'il n'y a pas de directions plus importante que d'autre et que en chercher rajoute du bruit. Par ailleurs faire une LDA dans l'espace défini par les barycentres du train provoque un effondrement de la performance. Cela signifie que en diminuant l'espace on rajoute davantage de bruit en cherchant des directions prioritaires que dans l'espace de départ.

IV ème partie : expériences dans l'espace des barycentres du ways.

On peut supposer qu'une partie non négligeable des informations se trouve dans l'espace définie par les barycentres du ways.

Comme la LDA a l'air inefficace, on va à nouveau utiliser une NCM.

Le test est simple. On cherche à savoir si l'espace défini par les barycentres du ways noté ew est un espace dense en informations. On va donc comparer la performance du réseau de neurone sur cette espace et sur un espace défini aléatoirement de même dimensions que l' ew (les points qui définisse cette espace sont globalement pris dans la même zone que les barycentres du ways)

On remarque que dans 83% des cas quand il y a deux classes et que il est en moyenne 12% plus efficace.

Un détail surprenant : la variance de l'efficacité est bien plus grand avec l' ew qu'avec des espace aléatoires (qui reste plus grande que celle du full).

On peut en conclure que cette espace est dense en informations et qu'il ne faut donc pas l'oublier dans un plan de réduction de l'espace si on ne veut pas perdre des informations.

Néanmoins les performances obtenues avec l' ew reste très médiocre. Il est loin de contenir l'intégralité de l'information.

V ème partie : expériences dans l'espace des barycentres du ways et du train

Cette espace est globalement très performant mais il est légèrement moins bon que l'espace défini par les barycentres du train et ce de manière. Sur deux classes, on perd 1% d'efficacité en moyenne. Il reste néanmoins meilleur que le full dans 40% des cas.

Cette baisse de la performance est inexpliqué. Il est possible que le bruit rajouter ne viennent pas de l'espace des barycentres du ways mais de la portion en dehors en dehors de ces deux espace rajouter par leur somme.

Il convient de regarder si en fait l'espace des barycentres du shot ne contient pas plus d'informations que celui du ways.

VI ème partie : comparaison des espace engendré par les barycentres du ways, du shot labellisée et du shot et des queries.

(exp menait avec 2 ways et 30 images par classe et 30 à classer)

On a repérer que l'espace générer par les barycentres du ways (C'est-à-dire les barycentres de toute la base de donnée répartie par classes) contenait de l'information mais également du bruit.

On va donc la comparait à l'espace générer uniquement parmi les données du shots. On va générer deux espaces : un générer avec uniquement les données labellisée et un autre générer avec les données labellisée et non labellisée (on triche en utilisant les labels des données non labellisée).

Les résultats sont sans appel : les informations sont contenue dans l'espace du shot (et non des données globales). En effet, l'efficacité augmente en moyenne de 20% en utilisant juste les données

labellisée.

Ce dernier atteint presque les performances de l'espace sans projection avec une variance de perf légèrement supérieur.

L'espace avec l'ensemble des données du shot est encore plus performant (+5% de performance par rapport à l'espace originel variance de la perf divisée par 10) C'est le meilleur espace 73% du temps. On peut donc en conclure que les informations sont contenue visiblement dans cette espace et ceux avec très peu de bruit.

pistes de recherche

- comment varie la quantité d'information contenue dans les espaces définis par les barycentres du train et ceux du ways. (nb de classes dans le ways?)
- Dans quel espaces un réseau de neurone stocke les informations.
- Comment identifier la composante commune de deux vecteurs.
- Explication théorique sur pourquoi les informations sont dans cette espace.

Stratégie à essayer :

la stratégie de la double sélection :

- Avec l'espace full on donne un label à toutes les données
- On sélectionne l'espace défini par les barycentres de ces données labellisée
- On ré-attribut les labels en utilisant cette espace
- On peut ré-sélectionner l'espace défini par les barycentres de ces données labellisée et continuer à l'infini.

Piste d'amélioration du code :

- créer une bibliothèque qui recoupe toutes les fonctions pour faire les calculs
- normaliser les noms (plusieurs fonctions font exactement la même chose mais sont adaptés à une normalisation de nom précise)
- recouper les fonctions d'affichage des résultats.

Ceci devrais permettre de faire des expériences très facilement et de le rendre beaucoup plus lisible

Pour éviter de devoir re-générer des features chaque fois qu'on change un paramètre tel que le nombre de réalisations. Il faut que les nom des objets ne prenne en compte que les paramètres qui influe sur la nature de l'objet.